

Descomposición Lagrangiana

Técnicas de Descomposición en Optimización

Relajación Lagrangiana · Dual Lagrangiano · Método del Subgradiente · Recuperación Primal · Aplicaciones

Por P. Hurtado · 2025

Índice

1. Motivación y Contexto	1
Por qué descomponer	2
Estructura explotable	2
2. Formulación del Problema	2
Forma canónica con restricciones complicantes	3
Variables de acoplamiento	3
3. Relajación Lagrangiana	3
Construcción de la función Lagrangiana	4
Problema Lagrangiano (subproblema)	4
4. Dual Lagrangiano	4
Función dual Lagrangiana	5
Problema Dual Lagrangiano	5
Condiciones de dualidad fuerte	6
5. Método del Subgradiente	6
Subdifferential de la función dual	7
Algoritmo del subgradiente	7
Convergencia	8
6. Recuperación de Solución Primal	8
El problema de la brecha primal-dual	8
Técnicas de recuperación	9
7. Interpretación Económica	9
Los multiplicadores como precios	9
Descomposición por agentes	10
8. Aplicaciones	10
Localización de instalaciones (UFL)	10
Ruteo de vehículos (VRP)	10
Unit Commitment en sistemas de potencia	10
9. Limitaciones y Alternativas	10
Limitaciones del método del subgradiente	11
Alternativas y extensiones	11

Sección 1: Motivación y Contexto

Por qué descomponer

Muchos problemas de optimización de gran escala poseen una *estructura de bloque*: la mayoría de las restricciones involucran variables de un solo subsistema, pero existe un conjunto reducido de restricciones que *acoplan* todos los subsistemas entre sí. Resolver el problema monolíticamente puede ser computacionalmente prohibitivo; la descomposición explota esa estructura para reducir el problema a subproblemas más pequeños y manejables.

Definición 1.1 · Restricción complicante

Una restricción $h_i(x) = 0$ (o ≤ 0) se denomina *complicante* si, al eliminarla, el problema se descompone en subproblemas independientes. Formalmente, si $x = (x_1, \dots, x_K)$ y la restricción vincula variables de distintos bloques x_k , es una restricción complicante.

La dificultad computacional de un MIP (problema entero-mixto) suele ser NP-difícil. Cuando la estructura de bloque es explotable, los subproblemas resultantes pueden resolverse en paralelo y de forma más eficiente que el problema original.

Estructura explotable

Definición 1.2 · Estructura de bloque

Se dice que el problema tiene *estructura de bloque acoplada* si su matriz de restricciones puede escribirse como:

$$\begin{pmatrix} A & & & \\ B_1 & & & \\ & B_2 & & \\ & & \ddots & \\ & & & B_K \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_K \end{pmatrix} = \begin{pmatrix} b \\ b_1 \\ b_2 \\ \vdots \\ b_K \end{pmatrix}$$

donde A son las filas de restricciones complicantes (que involucran a todos los bloques) y B_k son bloques diagonales independientes.

Ejemplo 1.1 · Problema de localización de instalaciones (UFL)

En el problema de localización no capacitado, las variables $y_j \in \{0, 1\}$ indican si la instalación j está abierta, y $x_{ij} \geq 0$ es la fracción de demanda del cliente i servida por la instalación j . La restricción $\sum_j x_{ij} = 1$ para cada cliente i acopla todas las instalaciones y es la restricción complicante natural. Al relajarla, el problema se separa por instalación.

Sección 2: Formulación del Problema

Forma canónica con restricciones complicantes

Definición 2.1 · Problema primal (P)

Sea el problema de optimización:

$$\begin{aligned} \text{(P)} \quad & \min_x c^\top x \\ \text{s.a.} \quad & Ax = b \quad (\text{restricciones complicantes}) \\ & x \in X \quad (\text{restricciones de bloque}) \end{aligned} \tag{2.1}$$

donde $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ y $X \subseteq \mathbb{R}^n$ es un conjunto *factible* (posiblemente no convexo, e.g., $X = \{0, 1\}^n$).

Proposición 2.1 · Factibilidad de X

Asumimos que X es no vacío, compacto (o que el problema es acotado sobre X), y que su estructura interna permite resolverlo de forma eficiente (e.g., X es un politopo o admite relajación convexa tratable).

Si $X = X_1 \times X_2 \times \dots \times X_K$ (producto cartesiano de conjuntos por bloque) y $c = (c_1, \dots, c_K)$, $x = (x_1, \dots, x_K)$, entonces al eliminar las restricciones $Ax = b$, el problema se descompone en K subproblemas independientes:

$$\min_{x_k \in X_k} c_k^\top x_k, \quad k = 1, \dots, K.$$

Variables de acoplamiento

Definición 2.2 · Variables de acoplamiento

Las *variables de acoplamiento* son aquellas que aparecen en las restricciones complicantes $Ax = b$. Su presencia en múltiples bloques es la razón por la que el problema no se descompone directamente.

Ejemplo 2.1 · Flujo multi-commodity

En un problema de flujo en red multi-commodity, cada commodity k tiene su propio vector de flujo f^k . La restricción de capacidad de arco $\sum_k f_{ij}^k \leq u_{ij}$ acopla todos los commodities a través del arco (i, j) : es la restricción complicante. Si se relaja, cada commodity se resuelve con su propio problema de shortest-path.

Sección 3: Relajación Lagrangiana

Construcción de la función Lagrangiana

Definición 3.1 · Función Lagrangiana

Dados los *multiplicadores Lagrangianos* $\lambda \in \mathbb{R}^m$, la *función Lagrangiana* de (P) es:

$$\mathcal{L}(x, \lambda) = c^\top x + \lambda^\top (Ax - b) = (c + A^\top \lambda)^\top x - \lambda^\top b.$$

Observar que $\mathcal{L}$ es lineal en λ para x fijo, y lineal en x para λ fijo.

Proposición 3.1 · Validez de la relajación

Para todo $\lambda \in \mathbb{R}^m$ y todo $x \in X$ que satisfaga $Ax = b$:

$$\mathcal{L}(x, \lambda) = c^\top x + \lambda^\top \underbrace{(Ax - b)}_{=0} = c^\top x.$$

Por lo tanto, $\min_{x \in X, Ax=b} \mathcal{L}(x, \lambda) \leq \min_{x \in X, Ax=b} c^\top x = v(P)$.

△ Atención

La relajación Lagrangiana *no* es la misma que la relajación lineal (LP relaxation). La relajación LP relaja la integridad de x ; la relajación Lagrangiana relaja las restricciones complicantes $Ax = b$ incorporándolas a la función objetivo, manteniendo $x \in X$ (que puede incluir integridad).

Problema Lagrangiano (subproblema)

Definición 3.2 · Subproblema Lagrangiano LR(λ)

Para un λ fijo, el *problema Lagrangiano* es:

$$\text{LR}(\lambda) : \quad q(\lambda) = \min_{x \in X} \mathcal{L}(x, \lambda) = \min_{x \in X} [(c + A^\top \lambda)^\top x] - \lambda^\top b.$$

Si $X = X_1 \times \cdots \times X_K$ y c, A son conformes con esa partición:

$$q(\lambda) = \sum_{k=1}^K \min_{x_k \in X_k} [(c_k + A_k^\top \lambda)^\top x_k] - \lambda^\top b,$$

donde el problema se descompone en K subproblemas independientes.

Proposición 3.2 · Cota inferior válida

Para todo $\lambda \in \mathbb{R}^m$: $q(\lambda) \leq v(P)$.

Demostración

Sea x^* una solución óptima de (P). Entonces $x^* \in X$ y $Ax^* = b$. Por lo tanto:

$$q(\lambda) = \min_{x \in X} \mathcal{L}(x, \lambda) \leq \mathcal{L}(x^*, \lambda) = c^\top x^* + \lambda^\top (Ax^* - b) = c^\top x^* = v(P).$$

□

Sección 4: Dual Lagrangiano

Función dual Lagrangiana

Definición 4.1 · Función dual $q(\lambda)$

La *función dual Lagrangiana* es $q : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{-\infty\}$ definida por:

$$q(\lambda) = \inf_{x \in X} \mathcal{L}(x, \lambda).$$

Proposición 4.1 · Concavidad de q

$q(\lambda)$ es una función *cóncava* de λ , independientemente de si X es convexo o no.

Demostración

Para $\lambda_1, \lambda_2 \in \mathbb{R}^m$ y $\alpha \in [0, 1]$:

$$\begin{aligned} q(\alpha\lambda_1 + (1-\alpha)\lambda_2) &= \inf_{x \in X} \mathcal{L}(x, \alpha\lambda_1 + (1-\alpha)\lambda_2) \\ &= \inf_{x \in X} [\alpha\mathcal{L}(x, \lambda_1) + (1-\alpha)\mathcal{L}(x, \lambda_2)] \\ &\geq \alpha \inf_{x \in X} \mathcal{L}(x, \lambda_1) + (1-\alpha) \inf_{x \in X} \mathcal{L}(x, \lambda_2) \\ &= \alpha q(\lambda_1) + (1-\alpha) q(\lambda_2). \end{aligned}$$

Esto prueba que q es cóncava (el ínfimo de funciones afines en λ es cóncavo). □

q es cóncava pero generalmente no diferenciable: puede tener kinks donde la solución óptima del subproblema cambia. Sin embargo, q es subdiferenciable en todos los puntos de su dominio efectivo.

Problema Dual Lagrangiano

Definición 4.2 · Problema Dual (D)

El *problema dual Lagrangiano* busca la mejor cota inferior:

$$(D) \quad v(D) = \max_{\lambda \in \mathbb{R}^m} q(\lambda) = \max_{\lambda \in \mathbb{R}^m} \min_{x \in X} \mathcal{L}(x, \lambda).$$

Teorema 4.2 · Dualidad débil

Siempre se cumple $v(D) \leq v(P)$.

Demostración

Inmediata de la Proposición 3.2: $q(\lambda) \leq v(P)$ para todo λ , y por ende $v(D) = \max_{\lambda} q(\lambda) \leq v(P)$. □

Definición 4.3 · Brecha de dualidad

La *brecha de dualidad* es $v(P) - v(D) \geq 0$.

Condiciones de dualidad fuerte**Teorema 4.3 · Dualidad fuerte para LP**

Si X es un poliedro (i.e., (P) es un programa lineal), entonces $v(D) = v(P)$ (no hay brecha de dualidad).

Proposición 4.4 · Cota de la relajación Lagrangiana para MIP

Para un MIP donde X contiene restricciones de integridad, la relajación Lagrangiana puede ser *más fuerte* que la relajación LP:

$$v(\text{LP-relax}) \leq v(D) \leq v(P).$$

La desigualdad $v(\text{LP-relax}) \leq v(D)$ se tiene cuando las restricciones complicantes relajadas son las que generan la brecha integridad-LP.

△ Atención

En general, $v(D) < v(P)$ para MIP (brecha de dualidad positiva). Esto significa que incluso resolviendo el dual exactamente, no obtenemos directamente la solución óptima primal del MIP; se necesita una heurística primal adicional.

Ejemplo 4.1 · Comparación de cotas — Knapsack 2D

Considere un problema de knapsack con $n = 5$ ítems, 2 restricciones de capacidad y $x \in \{0, 1\}^5$. Al relajar la segunda restricción de capacidad con λ :

Método	Cota inferior	Observación
LP-relajación	42.1	Soluciones fraccionarias
Relajación Lagrangiana	44.3	Mantiene integridad en X
Solución MIP óptima	45.0	Brecha LR: 1.5 %

La relajación Lagrangiana aporta una cota más ajustada que la LP-relajación.

Sección 5: Método del Subgradiente

Subdifferential de la función dual

Definición 5.1 · Subgradiente de q

Un vector $\mathbf{g} \in \mathbb{R}^m$ es un *subgradiente* de q en λ si:

$$q(\lambda') \leq q(\lambda) + \mathbf{g}^\top (\lambda' - \lambda) \quad \forall \lambda' \in \mathbb{R}^m.$$

El conjunto de todos los subgradientes en λ es el *subdifferential* $\partial q(\lambda)$.

Proposición 5.1 · Cálculo del subgradiente

Si $x^*(\lambda) \in \arg \min_{x \in X} \mathcal{L}(x, \lambda)$, entonces $\mathbf{g} = Ax^*(\lambda) - b$ es un subgradiente de q en λ .

Demostración

Para cualquier $\lambda' \in \mathbb{R}^m$:

$$\begin{aligned} q(\lambda') &= \min_{x \in X} \mathcal{L}(x, \lambda') \leq \mathcal{L}(x^*(\lambda), \lambda') \\ &= (c + A^\top \lambda')^\top x^*(\lambda) - \lambda'^\top b \\ &= (c + A^\top \lambda)^\top x^*(\lambda) - \lambda^\top b + (A^\top (\lambda' - \lambda))^\top x^*(\lambda) - (\lambda' - \lambda)^\top b \\ &= q(\lambda) + \lambda^\top b + (Ax^*(\lambda) - b)^\top (\lambda' - \lambda). \end{aligned}$$

Identificando con la definición: $\mathbf{g} = Ax^*(\lambda) - b$. □

El subgradiente $\mathbf{g}^k = Ax^k - b$ mide el grado de infactibilidad de la solución x^k del subproblema respecto a las restricciones complicantes. Si $\mathbf{g}^k = 0$, la solución es factible para (P) .

Algoritmo del subgradiente

Definición 5.2 · Iteración del subgradiente

En la iteración k , el multiplicador se actualiza como:

$$\lambda^{k+1} = \lambda^k + t_k \mathbf{g}^k, \quad \mathbf{g}^k = Ax^k - b.$$

Dado que maximizamos q (cóncava), nos movemos en la dirección del subgradiente (ascenso).

Definición 5.3 · Reglas de paso t_k

Existen tres reglas clásicas:

1. **Paso fijo:** $t_k = \alpha > 0$ (converge a un entorno del óptimo, no exactamente).
2. **Paso decreciente:** $\sum_{k=0}^{\infty} t_k = \infty$ y $\sum_{k=0}^{\infty} t_k^2 < \infty$, e.g., $t_k = c/\sqrt{k+1}$ (convergencia garantizada a $v(D)$).
3. **Paso de Polyak:** $t_k = \frac{\alpha_k (\bar{v} - q(\lambda^k))}{\|\mathbf{g}^k\|^2}$, donde $\bar{v}$ es una cota superior de $v(P)$ y $\alpha_k \in (0, 2]$.

El paso de Polyak es el más usado en la práctica. Requiere conocer (o estimar) una cota superior $\bar{v} \geq v(P)$, que se obtiene de heurísticas primales. Con $\alpha_k \equiv 1$ el método es el de Shor (1985).

El pseudocódigo del algoritmo es:

Algoritmo del Subgradiente

```

1: Inicializar  $\lambda^0 \leftarrow \mathbf{0}$ ,  $LB \leftarrow -\infty$ ,  $UB \leftarrow +\infty$ ,  $k \leftarrow 0$ 
2: repeat
3:   Resolver  $x^k \leftarrow \arg \min_{x \in X} (c + A^\top \lambda^k)^\top x$ 
4:    $q^k \leftarrow (c + A^\top \lambda^k)^\top x^k - (\lambda^k)^\top b$ 
5:    $LB \leftarrow \max(LB, q^k)$ 
6:   Calcular/actualizar cota superior UB con heurística primal sobre  $x^k$ 
7:    $\mathbf{g}^k \leftarrow Ax^k - b$ 
8:    $t_k \leftarrow \alpha_k \cdot (UB - q^k) / \|\mathbf{g}^k\|^2$  (paso de Polyak)
9:    $\lambda^{k+1} \leftarrow \lambda^k + t_k \mathbf{g}^k$ 
10:   $k \leftarrow k + 1$ 
11: until  $|UB - LB|/|LB| < \varepsilon$  o  $\|\mathbf{g}^k\| < \delta$  o  $k \geq K_{\max}$ 

```

Convergencia**Teorema 5.2 · Convergencia del método del subgradiente**

Con paso decreciente $t_k = c/\sqrt{k}$:

$$\limsup_{k \rightarrow \infty} q(\lambda^k) = v(D).$$

Con paso de Polyak ($\alpha_k \rightarrow 0$, $\sum \alpha_k = \infty$): la secuencia $\{q(\lambda^k)\}$ converge a $v(D)$.

Proposición 5.3 · No monotonicidad

La secuencia $\{q(\lambda^k)\}$ no es monotónicamente creciente en general. Es posible que $q(\lambda^{k+1}) < q(\lambda^k)$. Por eso se registra $LB = \max_k q(\lambda^k)$.

△ Atención

El método del subgradiente puede zigzaguear y converger lentamente. En instancias grandes, miles de iteraciones pueden ser necesarias. Los *bundle methods* son una alternativa que acumula información subgradiente para estabilizar la convergencia.

Sección 6: Recuperación de Solución Primal**El problema de la brecha primal-dual**

La solución $x^k = x^*(\lambda^k)$ del subproblema Lagrangiano satisface $x^k \in X$ pero generalmente no satisface las restricciones complicantes $Ax^k = b$. Esto es: x^k es infactible para (P).

Proposición 6.1 · Condición de optimalidad primal

Si existe λ^* tal que: (1) $x^*(\lambda^*) \in X$, (2) $Ax^*(\lambda^*) = b$, y (3) $\lambda^{*\top}(Ax^*(\lambda^*) - b) = 0$ (complementariedad), entonces $x^*(\lambda^*)$ es óptima para (P) y $v(D) = v(P)$ (no hay brecha).

Técnicas de recuperación

Definición 6.1 · Promediado de soluciones

La heurística de promediado define:

$$\bar{x}^K = \frac{1}{K} \sum_{k=1}^K x^k \quad \text{o} \quad \bar{x}^K = \frac{\sum_k t_k x^k}{\sum_k t_k}.$$

Bajo condiciones de regularidad (Nedic & Bertsekas, 2001), $\bar{x}^K$ converge al óptimo dual, pero puede ser infactible o fraccionario para MIP.

Definición 6.2 · Proyección al conjunto factible

Dada $\bar{x}$, se resuelve el problema de factibilización:

$$\min_{x: Ax=b, x \in X} \|x - \bar{x}\|^2.$$

Esto proyecta $\bar{x}$ al conjunto factible de (P), obteniendo una solución primal candidata.

En la práctica, la cota superior (UB) se obtiene aplicando una heurística primal ad-hoc a cada solución x^k : e.g., asignación greedy, rounding, o resolución de un MIP pequeño con x^k como punto de inicio.

Sección 7: Interpretación Económica

Los multiplicadores como precios

Definición 7.1 · Precio sombra

El multiplicador óptimo λ_i^* es el *precio sombra* del recurso i : si el RHS b_i aumenta en una unidad, el valor óptimo $v(D)$ aumenta en aproximadamente λ_i^* .

Proposición 7.1 · Complementariedad

En el óptimo dual λ^* (cuando no hay brecha), se satisface la condición de complementariedad:

$$\lambda_i^* (Ax^*)_i - \lambda_i^* b_i = 0 \quad \forall i.$$

Es decir: si la restricción i es inactiva en x^* , entonces $\lambda_i^* = 0$.

Descomposición por agentes

Cuando $X = X_1 \times \cdots \times X_K$, el subproblema Lagrangiano se descompone en K subproblemas independientes. Cada subproblema k optimiza:

$$\min_{x_k \in X_k} (c_k + A_k^\top \lambda)^\top x_k,$$

que puede interpretarse como la decisión óptima del agente k bajo los precios λ . El coordinador central actualiza λ según el subgradiente (desequilibrio de recursos), y cada agente responde optimizando bajo los nuevos precios.

Ejemplo 7.1 · Sistema eléctrico desacoplado

En un sistema eléctrico con N generadores y T períodos, relajando las restricciones de balance de potencia $\sum_n p_{nt} = D_t$, el multiplicador λ_t es el *precio de la energía* en el período t . Cada generador n resuelve su propio problema de *unit commitment* con costos modificados $(c_n - \lambda_t)$, de forma totalmente independiente.

Sección 8: Aplicaciones

Localización de instalaciones (UFL)

Definición 8.1 · Formulación UFL

$$\min \sum_j f_j y_j + \sum_{i,j} c_{ij} x_{ij} \quad \text{s.a.} \quad \sum_j x_{ij} = 1 \quad \forall i, \quad x_{ij} \leq y_j \quad \forall i, j, \quad y_j \in \{0, 1\}, \quad x_{ij} \geq 0.$$

Al relajar $\sum_j x_{ij} = 1$ con multiplicadores λ_i , el subproblema se descompone por instalación j :

$$\min_{y_j \in \{0,1\}} \left[f_j y_j + \sum_i \max(0, c_{ij} - \lambda_i) \right].$$

Ruteo de vehículos (VRP)

En VRP, al relajar las restricciones de cobertura de clientes con multiplicadores λ_i (uno por cliente), los subproblemas son problemas de shortest path independientes por vehículo. El subgradiente mide cuántos clientes quedan sin cubrir (o cubiertos en exceso).

Unit Commitment en sistemas de potencia

Definición 8.2 · Formulación UC

El problema de unit commitment minimiza el costo de operación de N generadores en T períodos, sujeto a restricciones de ramping, mínimo tiempo encendido/apagado y balance de potencia:

$$\sum_n p_{nt} = D_t \quad \forall t \quad (\text{restricción complicante}).$$

Al relajar el balance con λ_t , cada unidad n resuelve un MILP pequeño con costo por período $(c_n - \lambda_t)p_{nt}$.

Sección 9: Limitaciones y Alternativas

Limitaciones del método del subgradiente

△ Atención

- Convergencia lenta en la práctica: puede requerir miles de iteraciones.
- No se garantiza la factibilidad de la solución primal sin una heurística adicional.
- La brecha de dualidad puede ser no nula para MIP: $v(D) < v(P)$.
- El método del subgradiente no verifica optimalidad local; puede estancarse sin haber llegado al óptimo dual.

Alternativas y extensiones

Definición 9.1 · Bundle methods (métodos de haz)

Los *bundle methods* acumulan los subgradiientes de iteraciones anteriores para construir un *modelo lineal por partes* de q . Resuelven un QP en cada iteración para obtener una dirección de ascenso estabilizada. Convergen más rápido que el subgradiente puro, pero con mayor costo por iteración.

Definición 9.2 · Descomposición de Dantzig-Wolfe

Es el dual de la descomposición Lagrangiana en cierto sentido: trabaja en el espacio primal mediante *generación de columnas*. El problema maestro es el problema dual en variables de precio, y los subproblemas generan columnas (puntos extremos de $\text{conv}(X_k)$). Cuando los subproblemas son LPs, ambas descomposiciones son equivalentes.

Proposición 9.1 · Relación entre descomposiciones

Para problemas con estructura de bloque y X poliedro, la descomposición Lagrangiana (resolviendo el dual) y la descomposición de Dantzig-Wolfe (generación de columnas en el primal) producen la misma cota $v(D) = v(\text{LP-relax})$.

La descomposición de Benders (ver apunte complementario) puede verse como la “dual” de la descomposición Lagrangiana cuando se fijan variables complicantes (binarias) en el maestro y el subproblema es un LP.

Referencias principales:

- Held & Karp (1970) — Uso de relajación Lagrangiana en TSP.
- Fisher (1981) — “The Lagrangian Relaxation Method for Solving Integer Programming Problems”. *Management Science*.
- Shor (1985) — *Minimization Methods for Non-Differentiable Functions*. Springer.
- Nedic & Bertsekas (2001) — Convergencia del método del subgradiente. *Mathematical Programming*.
- Lemaréchal (2001) — Bundle methods. *Handbook of Applied Optimization*.