

Resumen de Probabilidad

Modelos Estocásticos

Espacio muestral · Probabilidad · Variables aleatorias · Distribuciones · Vectores aleatorios · Proceso de Poisson

Por P. Hurtado · 2026

Estas notas siguen el enfoque medida-teórico de Kolmogorov. Se asume familiaridad con análisis real (límites, series, integrales de Lebesgue a nivel introductorio). Notación: Ω espacio muestral, $\mathcal{F}$ σ -álgebra, P medida de probabilidad, X variable aleatoria.

Índice

1. Espacio de Probabilidad ($\Omega, \mathcal{F}, P$)	3
1.1 · Experimento, espacio muestral y eventos	3
1.2 · Sigma-álgebra	4
1.3 · Medida de probabilidad	4
1.4 · Recap de combinatoria	6
2. Probabilidad Condicional e Independencia	7
2.1 · Probabilidad condicional	8
2.2 · Independencia	9
3. Variables Aleatorias	9
3.1 · Definición medida-teórica	10
3.2 · Función de distribución acumulada (FDA)	11
3.3 · Variables discretas y continuas	11
3.4 · Esperanza y varianza	12
4. Distribuciones de Probabilidad Comunes	12
4.1 · Tabla resumen	13
4.2 · Distribución Bernoulli	13
4.3 · Distribución Binomial	14
4.4 · Distribución Geométrica	14
4.5 · Distribución Poisson	15
4.6 · Distribución Uniforme	16
4.7 · Distribución Exponencial	17
4.8 · Distribución Normal	18
4.9 · Relaciones entre distribuciones	18
5. Vectores Aleatorios y Distribuciones Conjuntas	18
5.1 · Vectores aleatorios	19
5.2 · Caso general n -variado	20
5.3 · Caso bivariado ($n = 2$)	22
5.4 · Caso discreto	23
5.5 · Caso continuo	26
5.6 · Esperanza condicional	29
6. Proceso de Poisson	30
6.1 · Procesos estocásticos y de conteo	30
6.2 · Incrementos independientes y estacionarios	31
6.3 · Proceso de Poisson homogéneo	33
6.4 · Tiempos entre eventos	34
6.5 · Competencia de tasa	35
6.6 · Tiempo de la n -ésima llegada	36
6.7 · Procesos de Poisson bifurcados (<i>thinning</i>)	36
6.8 · Suma (superposición) de procesos de Poisson	37
6.9 · Distribución condicional del primer evento	38

Leyenda de colores

Cada bloque de contenido se identifica visualmente por color, según su naturaleza:

	Definición	Concepto formal con nombre y notación. Marco verde claro.
	Teorema/Proposición	Resultado demostrable a partir de las definiciones. Marco azul.
	Demostración	Argumento que justifica un teorema/proposición. Marco morado.
	Ejemplo	Aplicación concreta o caso ilustrativo. Marco gris.
	Nota	Observación, intuición o comentario complementario. Marco ámbar.
	Atención	Advertencia sobre un error común o sutileza. Marco rojo.
	Sección	Encabezado principal del módulo. Fondo azul oscuro.
	Subsección	Subdivisión temática dentro de una sección. Fondo azul claro.

Sección 1: Espacio de Probabilidad $(\Omega, \mathcal{F}, P)$

1.1 · Experimento, espacio muestral y eventos

Definición 1.1 · Experimento aleatorio

Un **experimento aleatorio** es todo procedimiento u observación cuyo resultado no puede predecirse con certeza antes de realizarlo, pero que cumple:

1. El conjunto de resultados posibles es conocido *a priori*.
2. Cada realización (*ensayo* o *prueba*) produce exactamente un resultado.
3. Es *repetible* bajo condiciones esencialmente idénticas, exhibiendo regularidad estadística en frecuencias relativas a largo plazo.

Se contrasta con un **experimento determinista**, en el que las mismas condiciones iniciales producen siempre el mismo resultado.

Ejemplo 1.1 · Experimentos aleatorios típicos

Lanzar una moneda, tirar un dado, medir el tiempo de espera de un cliente en una cola, contar el número de llamadas a un call center en una hora, observar el precio de cierre diario de una acción.

Definición 1.2 · Espacio muestral

El **espacio muestral** Ω asociado a un experimento aleatorio es el conjunto de todos los resultados posibles de dicho experimento. Cada elemento $\omega \in \Omega$ se llama *resultado* o *punto muestral*.

Un **evento** A es cualquier subconjunto $A \subseteq \Omega$.

Ejemplo 1.2 · Lanzamiento de dos dados

$\Omega = \{(i, j) : i, j \in \{1, 2, 3, 4, 5, 6\}\}$, $|\Omega| = 36$.

Evento “suma igual a 7”: $A = \{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\}$, $|A| = 6$.

Por la regla clásica: $P(A) = 6/36 = 1/6$.

Definición 1.3 · Operaciones entre eventos

Sean $A, B \subseteq \Omega$ eventos. Se definen:

- **Unión:** $A \cup B = \{\omega \in \Omega : \omega \in A \text{ o } \omega \in B\}$ (ocurre A o B , o ambos).
- **Intersección:** $A \cap B = \{\omega \in \Omega : \omega \in A \text{ y } \omega \in B\}$ (ocurren ambos).
- **Complemento:** $A^c = \{\omega \in \Omega : \omega \notin A\}$ (no ocurre A).
- **Diferencia:** $A \setminus B = A \cap B^c$ (ocurre A pero no B).

A y B son **disjuntos** (mutuamente excluyentes) si $A \cap B = \emptyset$.

Leyes de De Morgan: $(A \cup B)^c = A^c \cap B^c$, $(A \cap B)^c = A^c \cup B^c$.




Diagrama de Venn: relaciones entre eventos A, B dentro de Ω .

Definición 1.4 · Conjunto potencia

El **conjunto potencia** de Ω , denotado 2^Ω o $\mathcal{P}(\Omega)$, es la colección de todos los subconjuntos de Ω :

$$2^\Omega = \mathcal{P}(\Omega) = \{A : A \subseteq \Omega\}.$$

En particular $\emptyset \in 2^\Omega$ y $\Omega \in 2^\Omega$.

Si Ω es finito con $|\Omega| = n$, entonces $|2^\Omega| = 2^n$ (de ahí la notación). El conjunto potencia es el universo más grande posible de eventos sobre Ω y constituye siempre una σ -álgebra (la más fina).

1.2 · Sigma-álgebra

Una σ -**álgebra** (o *tribu*) es la estructura matemática que selecciona *cuáles* subconjuntos de Ω admiten asignación de probabilidad. Intuitivamente, es el *catálogo de eventos observables*: la colección de aquellos subconjuntos sobre los que la pregunta “¿cuál es la probabilidad de que ocurra?” tiene respuesta bien definida.

¿Por qué no usar simplemente 2^Ω ? Cuando Ω es no numerable (p. ej. $\Omega = \mathbb{R}$), no existe una medida de probabilidad consistente sobre todos los subconjuntos: existen conjuntos no medibles (conjuntos de Vitali, paradoja de Banach-Tarski). La σ -álgebra restringe el dominio a eventos para los cuales P sí puede definirse de forma coherente con los axiomas de Kolmogorov.

Para Ω finito o numerable sí se usa $\mathcal{F} = 2^\Omega$ sin problemas.

Formalmente, una σ -álgebra es una familia de subconjuntos cerrada bajo las operaciones básicas (complemento y uniones *numerables*), que además contiene al espacio total. El prefijo “ σ -” enfatiza la cerradura bajo operaciones *numerables* (no solo finitas): esto es lo que permite manejar límites y series, esenciales en probabilidad.

Definición 1.5 · σ -álgebra

Una familia $\mathcal{F} \subseteq 2^\Omega$ es una σ -**álgebra** si:

1. $\Omega \in \mathcal{F}$
2. $A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$ (cerrada bajo complemento)
3. $\{A_n\}_{n \geq 1} \subseteq \mathcal{F} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$ (cerrada bajo uniones numerables)

Los elementos de $\mathcal{F}$ se llaman **eventos medibles**.

Se derivan: $\emptyset \in \mathcal{F}$; cerrada bajo intersecciones numerables; cerrada bajo diferencias. La σ -álgebra más pequeña es $\{\emptyset, \Omega\}$; la más grande es 2^Ω (conjunto potencia).


1.3 · Medida de probabilidad**Definición 1.6 · Medida de probabilidad (Kolmogorov, 1933)**

Una función $P : \mathcal{F} \rightarrow [0, 1]$ es una **medida de probabilidad** si:


- (K1) $P(A) \geq 0 \quad \forall A \in \mathcal{F}$ (no negatividad)
- (K2) $P(\Omega) = 1$ (normalización)
- (K3) $P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n)$ para $A_i \cap A_j = \emptyset \quad \forall i \neq j$ (σ -aditividad)

La terna $(\Omega, \mathcal{F}, P)$ es el **espacio de probabilidad**.

***σ -aditividad vs. partición.** La σ -aditividad (K3) aplica a cualquier colección disjunta $\{A_n\}$; su unión no tiene por qué ser Ω . Una **partición** es un caso particular: una familia disjunta que además cubre todo Ω , es decir, $\bigcup_n A_n = \Omega$. En ese caso, $\sum_n P(A_n) = P(\Omega) = 1$.*

 **σ -aditividad**

$$P\left(\bigsqcup_n A_n\right) = \sum_n P(A_n) \leq 1$$

**Partición**

$$\bigsqcup_n B_n = \Omega \Rightarrow \sum_n P(B_n) = 1$$

Izquierda: eventos disjuntos cuya unión no llena Ω (basta para aplicar K3). Derecha: partición, donde los disjuntos cubren todo Ω y sus probabilidades suman 1.

Proposición 1.1 · Propiedades básicas

Para todo $A, B \in \mathcal{F}$:

1. $P(\emptyset) = 0$
2. $P(A^c) = 1 - P(A)$
3. $A \subseteq B \Rightarrow P(A) \leq P(B)$
4. $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ (inclusión y exclusión)
5. $P(A) \in [0, 1]$

Técnica clave. Las cinco propiedades son consecuencias directas de los axiomas K1–K3. El truco recurrente es descomponer un evento en piezas disjuntas y aplicar la σ -aditividad (K3) sobre esa descomposición.

Demostración

(1) $P(\emptyset) = 0$. Escribir $\Omega = \Omega \sqcup \emptyset \sqcup \emptyset \sqcup \dots$. Por K3: $P(\Omega) = P(\Omega) + \sum_{n \geq 1} P(\emptyset)$. Restando $P(\Omega)$ (finito por K2) y usando K1 ($P(\emptyset) \geq 0$): $P(\emptyset) = 0$.

(2) $P(A^c) = 1 - P(A)$. $\Omega = A \sqcup A^c$ (disjuntos), luego por K3: $1 = P(A) + P(A^c)$. Despejar.

(3) $A \subseteq B \Rightarrow P(A) \leq P(B)$. Si $A \subseteq B$, entonces $B = A \sqcup (B \setminus A)$ (disjuntos). Por K3: $P(B) = P(A) + P(B \setminus A) \geq P(A)$, pues $P(B \setminus A) \geq 0$ por K1.

(4) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. Descomponer ambos lados en piezas disjuntas:

$$\begin{aligned} A \cup B &= A \sqcup (B \setminus A) & \Rightarrow P(A \cup B) &= P(A) + P(B \setminus A), \\ B &= (A \cap B) \sqcup (B \setminus A) & \Rightarrow P(B \setminus A) &= P(B) - P(A \cap B). \end{aligned}$$

Sustituyendo: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

(5) $P(A) \in [0, 1]$. $P(A) \geq 0$ por K1. Como $A \subseteq \Omega$, por (3) y K2: $P(A) \leq P(\Omega) = 1$. □

Teorema 1.2 · Principio de inclusión y exclusión

Sea $\{A_1, \dots, A_n\} \subseteq \mathcal{F}$ una colección finita de eventos. Entonces:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n (-1)^{k+1} \sum_{\substack{S \subseteq \{1, \dots, n\} \\ |S|=k}} P\left(\bigcap_{i \in S} A_i\right).$$

Expandiendo los primeros términos:

$$P\left(\bigcup_i A_i\right) = \sum_i P(A_i) - \sum_{i < j} P(A_i \cap A_j) + \sum_{i < j < k} P(A_i \cap A_j \cap A_k) - \dots + (-1)^{n+1} P(A_1 \cap \dots \cap A_n).$$

Idea intuitiva. Sumar $P(A_1) + \dots + P(A_n)$ sobreestima $P(\bigcup A_i)$ porque las intersecciones se cuentan varias veces. Restando los pares ($\sum P(A_i \cap A_j)$) se compensa, pero ahora las triples quedan mal contadas; se vuelven a sumar, etc. El signo alterna y los términos se cancelan exactamente.

Demostración

Inducción sobre n .

Caso base $n = 2$. Es la propiedad (4) ya demostrada: $P(A_1 \cup A_2) = P(A_1) + P(A_2) - P(A_1 \cap A_2)$.

Paso inductivo $(n - 1) \Rightarrow n$. Sea $B = \bigcup_{i=1}^{n-1} A_i$ y supongamos la fórmula válida para $n - 1$ eventos. Por el caso base aplicado a B y A_n :

$$P(B \cup A_n) = P(B) + P(A_n) - P(B \cap A_n). \quad (\star)$$

Por hipótesis de inducción (HI):

$$P(B) = \sum_{k=1}^{n-1} (-1)^{k+1} \sum_{\substack{S \subseteq \{1, \dots, n-1\} \\ |S|=k}} P\left(\bigcap_{i \in S} A_i\right).$$

Por distributividad: $B \cap A_n = \bigcup_{i=1}^{n-1} (A_i \cap A_n)$. Aplicando la HI a los $n - 1$ eventos $\{A_i \cap A_n\}_{i=1}^{n-1}$:

$$P(B \cap A_n) = \sum_{k=1}^{n-1} (-1)^{k+1} \sum_{\substack{S \subseteq \{1, \dots, n-1\} \\ |S|=k}} P\left(A_n \cap \bigcap_{i \in S} A_i\right).$$

Sustituyendo en $(\star)$ y reagrupando términos por el tamaño k del subconjunto de índices, se obtiene la fórmula para n . $\square$

Desigualdades de Bonferroni. Las sumas parciales del lado derecho alternan como cotas: tomando solo el primer término se obtiene la cota superior (subaditividad) $P(\bigcup A_i) \leq \sum P(A_i)$; con dos términos se obtiene la cota inferior $P(\bigcup A_i) \geq \sum P(A_i) - \sum_{i < j} P(A_i \cap A_j)$, y así sucesivamente.

1.4 · Recap de combinatoria

Cuando Ω es finito con resultados *equiprobables*, la **regla clásica** entrega:

$$P(A) = \frac{|A|}{|\Omega|}, \quad A \subseteq \Omega.$$

El cálculo de probabilidades se reduce entonces a *contar*: cuántos resultados favorables y cuántos posibles.

Definición 1.7 · Principio multiplicativo

Si un procedimiento se realiza en k etapas y la etapa i -ésima admite n_i resultados posibles (independientes de las anteriores), el número total de resultados es:

$$n_1 \cdot n_2 \cdots n_k = \prod_{i=1}^k n_i.$$

Ejemplo 1.3 · Placas patentes

Una patente de 4 letras seguidas de 2 dígitos admite $26^4 \cdot 10^2 = 45,697,600$ combinaciones distintas (con repetición permitida).

Definición 1.8 · Permutaciones y variaciones

De un conjunto de n elementos distintos:

- **Permutación de los n elementos** (orden total): $P_n = n! = n \cdot (n - 1) \cdots 2 \cdot 1$.
- **Variaciones sin repetición** (secuencias ordenadas de $k \leq n$):

$$V(n, k) = \frac{n!}{(n - k)!} = n(n - 1)(n - 2) \cdots (n - k + 1).$$

- **Variaciones con repetición** (secuencias de longitud k , repetición permitida): $V_R(n, k) = n^k$.

Definición 1.9 · Combinaciones

Subconjuntos de tamaño k tomados de un conjunto de n elementos (*el orden no importa*):

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}, \quad 0 \leq k \leq n.$$

Propiedades:

- Simetría: $\binom{n}{k} = \binom{n}{n-k}$.
- Bordes: $\binom{n}{0} = \binom{n}{n} = 1$.
- Regla de Pascal: $\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$.
- Teorema del binomio: $(x+y)^n = \sum_{k=0}^n \binom{n}{k} x^k y^{n-k}$.

Combinaciones con repetición (multiconjuntos de tamaño k con n tipos disponibles):

$$CR(n, k) = \binom{n+k-1}{k} \quad (\text{stars and bars}).$$

¿Qué fórmula usar? Antes de calcular, identifica dos preguntas:

- ¿Importa el orden? Sí $\rightarrow$ variación/permutación. No $\rightarrow$ combinación.
- ¿Se permite repetir? Sí $\rightarrow$ con repetición. No $\rightarrow$ sin repetición.

Tipo	Orden	Repetición	Fórmula
Permutación de n	sí	no	$n!$
Variación $V(n, k)$	sí	no	$\frac{n!}{(n-k)!}$
Variación con repetición	sí	sí	n^k
Combinación $\binom{n}{k}$	no	no	$\frac{n!}{k!(n-k)!}$
Combinación con repetición	no	sí	$\binom{n+k-1}{k}$

Ejemplo 1.4 · Aplicación: regla clásica + combinatoria

Planteamiento. De una baraja estándar de 52 cartas se reparte una mano de 5 cartas al azar. ¿Cuál es la probabilidad de que la mano contenga exactamente los 4 ases?

(1) Definir el experimento y el espacio muestral. Cada “mano” es un subconjunto de 5 cartas escogidas de 52. Como la mano se identifica solo por *qué* cartas contiene (el orden de reparto no influye en las reglas del juego), trabajamos con **combinaciones**, no variaciones:

$$|\Omega| = \binom{52}{5} = \frac{52!}{5!47!} = 2\,598\,960 \quad (\text{manos posibles, sin orden, sin repetición}).$$

Asumimos que el reparto es uniforme: cada una de esas $\binom{52}{5}$ manos tiene la misma probabilidad. Aplica entonces la regla clásica $P(A) = |A|/|\Omega|$.

(2) Definir el evento. Sea $A = \{\text{la mano contiene los 4 ases}\}$. Una mano en A se construye en dos pasos independientes:

- Elegir los 4 ases: hay $\binom{4}{4} = 1$ forma (los cuatro ases son obligatorios).
- Elegir la 5ª carta entre las 48 no-ases restantes: $\binom{48}{1} = 48$ formas.

Por el principio multiplicativo:

$$|A| = \binom{4}{4} \binom{48}{1} = 1 \cdot 48 = 48.$$

(3) Calcular la probabilidad.

$$P(A) = \frac{|A|}{|\Omega|} = \frac{48}{2\,598\,960} \approx 1.85 \times 10^{-5}.$$

(4) Interpretación. Aproximadamente 1 de cada 54,145 manos contiene los cuatro ases.

Sección 2: Probabilidad Condicional e Independencia

2.1 · Probabilidad condicional

Definición 2.1 · Probabilidad condicional

Para $A, B \in \mathcal{F}$ con $P(B) > 0$:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

La función $P(\cdot | B) : \mathcal{F} \rightarrow [0, 1]$ es en sí misma una medida de probabilidad sobre $(\Omega, \mathcal{F})$.

Intuitivamente: al conocer que ocurrió B , el espacio muestral efectivo se reduce a B y se re-normaliza dividiendo por $P(B)$.

Teorema 2.1 · Ley de probabilidad total

Sea $\{B_1, \dots, B_n\}$ una partición de Ω con $P(B_i) > 0$. Entonces:

$$P(A) = \sum_{i=1}^n P(A | B_i) P(B_i) \quad \forall A \in \mathcal{F}.$$

Demostración

Como $\{B_1, \dots, B_n\}$ es una partición de Ω :

$$A = A \cap \Omega = A \cap \left(\bigsqcup_{i=1}^n B_i \right) = \bigsqcup_{i=1}^n (A \cap B_i),$$

donde la última igualdad usa la distributividad de $\cap$ sobre $\sqcup$, y los $A \cap B_i$ son disjuntos porque los B_i lo son. Por σ -aditividad (K3):

$$P(A) = \sum_{i=1}^n P(A \cap B_i).$$

Por la definición de probabilidad condicional, $P(A \cap B_i) = P(A | B_i) P(B_i)$ (válida pues $P(B_i) > 0$). Sustituyendo:

$$P(A) = \sum_{i=1}^n P(A | B_i) P(B_i).$$

□

Teorema 2.2 · Teorema de Bayes


Sean $A, B \in \mathcal{F}$ con $P(A) > 0$ y $P(B) > 0$. Entonces:

$$P(B | A) = \frac{P(A | B) P(B)}{P(A)}.$$

Si $P(A)$ no se conoce directamente, se obtiene por probabilidad total con la partición $\{B, B^c\}$:

$$P(B | A) = \frac{P(A | B) P(B)}{P(A | B) P(B) + P(A | B^c) P(B^c)}.$$

$P(B)$: probabilidad *a priori*. $P(B | A)$: probabilidad *a posteriori*.

Árbol de probabilidad condicional con partición $\{B_1, B_2\}$.**Ejemplo 2.1 · Prueba diagnóstica (Bayes en acción)****Notación.** Sean los eventos:

- B = “la persona está enferma”.
- A = “el test da positivo”.

Datos del problema:

- Prevalencia: $P(B) = 0.01$ (el 1 % de la población está enferma).
- Sensibilidad: $P(A | B) = 0.95$ (95 % de los enfermos dan positivo).
- Especificidad: $P(A^c | B^c) = 0.90$ (90 % de los sanos dan negativo).

De la especificidad: $P(A | B^c) = 1 - 0.90 = 0.10$ (tasa de falsos positivos).**Pregunta:** si una persona da positivo, ¿cuál es la probabilidad de que esté enferma? Es decir, calcular $P(B | A)$.**Paso 1.** Calcular $P(A)$ por probabilidad total con la partición $\{B, B^c\}$:

$$P(A) = P(A | B) P(B) + P(A | B^c) P(B^c) = 0.95 \cdot 0.01 + 0.10 \cdot 0.99 = 0.0095 + 0.099 = 0.1085.$$

Paso 2. Aplicar Bayes:

$$P(B | A) = \frac{P(A | B) P(B)}{P(A)} = \frac{0.95 \cdot 0.01}{0.1085} = \frac{0.0095}{0.1085} \approx 0.0875.$$

Interpretación. Aunque el test tiene 95 % de sensibilidad, solo el ~ 8.8 % de quienes dan positivo están realmente enfermos: el ~ 91 % son *falsos positivos*. Esta es la *paradoja del valor predictivo positivo*: cuando una enfermedad es rara, la población sana es mucho más grande y aunque su tasa de error sea baja, genera más positivos en números absolutos.**2.2 · Independencia****Definición 2.2 · Independencia de eventos** $A, B \in \mathcal{F}$ son **independientes** ($A \perp B$) si:

$$P(A \cap B) = P(A) P(B).$$

Una familia $\{A_i\}_{i \in I}$ es **mutuamente independiente** si para todo $J \subseteq I$ finito:

$$P\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} P(A_j).$$

△ AtenciónIndependencia mutua es más fuerte que independencia por pares. Existen familias donde todos los pares son independientes pero la familia completa no lo es (contraejemplo: dados de Bernstein con $\Omega = \{1, 2, 3, 4\}$, P uniforme).

Sección 3: Variables Aleatorias

3.1 · Definición medida-teórica

Definición 3.1 · σ -álgebra de Borel y conjuntos borelianos

La σ -álgebra de Borel sobre $\mathbb{R}$, denotada $\mathcal{B}(\mathbb{R})$, es la *más pequeña* σ -álgebra que contiene a todos los intervalos:

$$\mathcal{B}(\mathbb{R}) = \sigma(\{(a, b] : a < b, a, b \in \mathbb{R}\}).$$

Sus elementos se llaman **conjuntos borelianos** (o *borelianos*). Por construcción, $\mathcal{B}(\mathbb{R})$ contiene a todos los:

- intervalos abiertos (a, b) , cerrados $[a, b]$, semi-abiertos $(a, b]$ y $[a, b)$;
- rayos $(-\infty, a]$, (a, ∞) , etc.;
- conjuntos abiertos y cerrados de $\mathbb{R}$;
- uniones e intersecciones *numerables* de los anteriores;
- complementos de cualquier boreliano.

En la práctica, todo subconjunto de $\mathbb{R}$ que aparece naturalmente (intervalos, puntos, uniones contables, etc.) es boreliano.


¿Por qué no usar todos los subconjuntos de $\mathbb{R}$? Igual que con la σ -álgebra general, en $\mathbb{R}$ existen conjuntos “patológicos” (no medibles, como los conjuntos de Vitali) sobre los cuales no se puede definir una medida de probabilidad consistente. $\mathcal{B}(\mathbb{R})$ es el “contenedor” suficientemente rico para todos los eventos de interés y suficientemente restrictivo para excluir los problemáticos.

Definición 3.2 · Variable aleatoria

Dado $(\Omega, \mathcal{F}, P)$, una **variable aleatoria** es una función medible $X : \Omega \rightarrow \mathbb{R}$, es decir:

$$\forall B \in \mathcal{B}(\mathbb{R}) : X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{F}.$$

Equivalentemente, basta verificar que $\{\omega : X(\omega) \leq x\} \in \mathcal{F}$ para todo $x \in \mathbb{R}$.



X lleva $\omega \in \Omega$ a $\mathbb{R}$; la pre-imagen de cualquier boreliano debe pertenecer a $\mathcal{F}$.

3.2 · Función de distribución acumulada (FDA)

Definición 3.3 · Función de distribución acumulada (FDA)

La **función de distribución acumulada (FDA)** de X es:

$$F_X(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

Proposición 3.1 · Propiedades de la FDA

Toda FDA F_X satisface las siguientes tres propiedades:

- (1) **Monótona no decreciente:** $x \leq y \Rightarrow F(x) \leq F(y)$.
 - *Por qué:* si $x \leq y$, entonces $\{X \leq x\} \subseteq \{X \leq y\}$. Por monotonía de P : $P(X \leq x) \leq P(X \leq y)$.
 - *Intuición:* la FDA *acumula* probabilidad de izquierda a derecha; al avanzar nunca puede “perder” masa.
- (2) **Continua por la derecha:** $\lim_{t \downarrow x} F(t) = F(x)$.
 - *Notación.* $t \downarrow x$ significa que t se acerca a x **desde la derecha** ($t > x$ y $t \rightarrow x$). Equivale a $\lim_{t \rightarrow x^+} F(t)$.
 - *Por qué (demostración).* Si $t_n \downarrow x$, los eventos $\{X \leq t_n\}$ forman una sucesión decreciente cuya intersección es $\{X \leq x\}$. Por continuidad de P para sucesiones decrecientes: $\lim P(X \leq t_n) = P(X \leq x) = F(x)$.
 - *Intuición con saltos.* En un punto de salto x_0 :
 - Por la izquierda: $\lim_{t \uparrow x_0} F(t) = F(x_0^-)$ (valor *abajo* del salto).
 - Por la derecha: $\lim_{t \downarrow x_0} F(t) = F(x_0)$ (valor *arriba* del salto).
 La propiedad (2) dice que F “salta y se queda arriba”.
 - *Tamaño del salto:* $F(x_0) - F(x_0^-) = P(X = x_0)$.
- (3) **Límites:** $\lim_{x \rightarrow -\infty} F(x) = 0$ y $\lim_{x \rightarrow +\infty} F(x) = 1$.
 - *Por qué:* cuando $x \rightarrow -\infty$, los eventos $\{X \leq x\}$ decrecen a $\emptyset$. Cuando $x \rightarrow +\infty$, crecen a Ω . Por continuidad de P : $P(\emptyset) = 0$, $P(\Omega) = 1$.

Recíproco. Toda función $F : \mathbb{R} \rightarrow [0, 1]$ que satisfaga (1), (2) y (3) es la FDA de *alguna* variable aleatoria. Por tanto, la FDA caracteriza completamente la distribución de X .

3.3 · Variables discretas y continuas

Definición 3.4 · Variable aleatoria discreta y función de masa (PMF)

X es **discreta** si toma valores en un conjunto numerable $\{x_1, x_2, \dots\}$. Su **función de masa de probabilidad (PMF)** es:

$$p_X(x_k) = P(X = x_k) \geq 0, \quad \sum_k p_X(x_k) = 1.$$

Definición 3.5 · Variable aleatoria continua y función de densidad (PDF)

X es **continua** si existe una **función de densidad de probabilidad (PDF)** $f_X : \mathbb{R} \rightarrow [0, \infty)$ tal que:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt, \quad \int_{-\infty}^{\infty} f_X(t) dt = 1.$$

Para X continua: $P(X = x) = 0$ para todo $x \in \mathbb{R}$.

Definición 3.6 · Soporte de una variable aleatoria

El **soporte** de X , denotado I_X , es el conjunto de valores que X toma con probabilidad positiva:

$$I_X = \begin{cases} \{x_k : p_X(x_k) > 0\} & \text{si } X \text{ es discreta,} \\ \{x \in \mathbb{R} : f_X(x) > 0\} & \text{si } X \text{ es continua.} \end{cases}$$

En lo que sigue, sumas e integrales se restringen a I_X .

3.4 · Esperanza y varianza

Definición 3.7 · Esperanza

Discreta: $\mathbb{E}[X] = \sum_{x \in I_X} x p_X(x).$

Continua: $\mathbb{E}[X] = \int_{I_X} x f_X(x) dx.$

Si $g : \mathbb{R} \rightarrow \mathbb{R}$ medible: $\mathbb{E}[g(X)] = \sum_{x \in I_X} g(x) p_X(x)$ o $\int_{I_X} g(x) f_X(x) dx.$ (*Ley del estadístico inconsciente*)

Proposición 3.2 · Propiedades de la esperanza

Sean X, Y variables aleatorias con esperanza finita y $a, b, c \in \mathbb{R}$ constantes.

1. **Constante:** $\mathbb{E}[c] = c.$
2. **Linealidad:** $\mathbb{E}[aX + bY] = a \mathbb{E}[X] + b \mathbb{E}[Y].$ Vale siempre, no requiere independencia.
3. **Monotonía:** si $X \leq Y$ casi seguramente, entonces $\mathbb{E}[X] \leq \mathbb{E}[Y].$
4. **No negatividad:** si $X \geq 0$ casi seguramente, entonces $\mathbb{E}[X] \geq 0.$
5. **Desigualdad triangular:** $|\mathbb{E}[X]| \leq \mathbb{E}[|X|].$
6. **Producto bajo independencia:** si $X \perp Y$, entonces $\mathbb{E}[XY] = \mathbb{E}[X] \mathbb{E}[Y].$

Linealidad es la propiedad más utilizada en práctica: permite descomponer esperanzas de sumas en sumas de esperanzas aunque las variables sean dependientes.

Definición 3.8 · Varianza

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

Desviación estándar: $\sigma_X = \sqrt{\text{Var}(X)}.$

Proposición 3.3 · Propiedades de la varianza

Sean X, Y variables aleatorias con varianza finita y $a, b \in \mathbb{R}$ constantes.

1. **No negatividad:** $\text{Var}(X) \geq 0$, con $\text{Var}(X) = 0$ si y solo si X es constante c.s.
2. **Constante:** $\text{Var}(c) = 0.$
3. **Traslación (invariancia):** $\text{Var}(X + b) = \text{Var}(X).$
4. **Escalamiento:** $\text{Var}(aX) = a^2 \text{Var}(X).$
5. **Transformación afín:** $\text{Var}(aX + b) = a^2 \text{Var}(X).$
6. **Suma (caso general):** $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$, donde $\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X] \mathbb{E}[Y].$
7. **Suma bajo independencia:** si $X \perp Y$: $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$ Más general: $\text{Var}(\sum X_i) = \sum \text{Var}(X_i)$ si todos son independientes.

Cuidado: a diferencia de la esperanza, la varianza no es lineal. $\text{Var}(X + Y) \neq \text{Var}(X) + \text{Var}(Y)$ en general — solo bajo independencia (o, más débilmente, descorrelación $\text{Cov}(X, Y) = 0$). La desviación estándar sí escala linealmente: $\sigma_{aX} = |a| \sigma_X.$

Sección 4: Distribuciones de Probabilidad Comunes

4.1 · Tabla resumen

Distribución	Parámetros	Soporte	$\mathbb{E}[X]$	$\text{Var}(X)$	MGF
Bernoulli(p)	$p \in (0, 1)$	$\{0, 1\}$	p	$p(1-p)$	$1 - p + pe^t$
Binomial(n, p)	$n \in \mathbb{N}, p \in (0, 1)$	$\{0, \dots, n\}$	np	$np(1-p)$	$(1 - p + pe^t)^n$
Geométrica(p)	$p \in (0, 1)$	$\mathbb{N}^+$	$1/p$	$(1-p)/p^2$	$\frac{pe^t}{1 - (1-p)e^t}$
Poisson(λ)	$\lambda > 0$	$\mathbb{N}_0$	λ	λ	$e^{\lambda(e^t-1)}$
Uniforme(a, b)	$a < b$	$[a, b]$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{e^{tb} - e^{ta}}{t(b-a)}$
Exponencial(λ)	$\lambda > 0$	$[0, \infty)$	$1/\lambda$	$1/\lambda^2$	$\frac{\lambda}{\lambda-t}, t < \lambda$
Normal(μ, σ^2)	$\mu \in \mathbb{R}, \sigma > 0$	$\mathbb{R}$	μ	σ^2	$e^{\mu t + \sigma^2 t^2/2}$

Mapa de decisión rápida.

- ¿Cuento o mido? Cuento $\rightarrow$ discreta. Mido tiempo/distancia/cantidad continua $\rightarrow$ continua.
- ¿Número fijo de intentos n ? Sí $\rightarrow$ Binomial. No, hasta el primer éxito $\rightarrow$ Geométrica. No, eventos a tasa por unidad $\rightarrow$ Poisson.
- ¿Tiempo entre eventos? $\rightarrow$ Exponencial.
- ¿Sin preferencia en un rango? $\rightarrow$ Uniforme.
- ¿Suma de muchos efectos? $\rightarrow$ Normal (por TCL).

4.2 · Distribución Bernoulli

Definición 4.1 · Distribución Bernoulli

$X \sim \text{Bernoulli}(p)$ con $p \in (0, 1)$ modela un único ensayo con dos resultados. Soporte $I_X = \{0, 1\}$, PMF:

$$p_X(k) = p^k(1-p)^{1-k}, \quad k \in I_X.$$

Equivalentemente: $P(X = 1) = p$, $P(X = 0) = 1 - p$. **Momentos:** $\mathbb{E}[X] = p$, $\text{Var}(X) = p(1-p)$.

Demostración


Verificamos que la PMF suma 1:

$$\sum_{k=0}^1 p^k(1-p)^{1-k} = (1-p) + p = 1.$$

□

¿Cuándo usar? Un solo experimento con dos resultados mutuamente excluyentes. Ladrillo elemental: la Binomial y la Geométrica se construyen como sucesiones de Bernoullis i.i.d.

Ejemplo: lanzar una moneda; pregunta sí/no en encuesta.



PMF de Bernoulli para $p = 0.3$ (sesgada) y $p = 0.5$ (justa).

4.3 · Distribución Binomial

Definición 4.2 · Distribución Binomial

$X \sim \text{Bin}(n, p)$ con $n \in \mathbb{N}$, $p \in (0, 1)$ cuenta el número de éxitos en n ensayos Bernoulli(p) independientes. Soporte $I_X = \{0, 1, \dots, n\}$, PMF:

$$p_X(k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k \in I_X.$$

Equivalentemente, $X = \sum_{i=1}^n Y_i$ con $Y_i \sim \text{Bernoulli}(p)$ i.i.d. **Momentos:** $\mathbb{E}[X] = np$, $\text{Var}(X) = np(1-p)$.

Demostración


Por el teorema del binomio aplicado a $(p + (1-p))^n$:

$$\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = (p + (1-p))^n = 1^n = 1.$$

□

¿Cuándo usar? Cuando se realizan n ensayos Bernoulli independientes con la misma p y se cuenta el total de éxitos.

Ejemplo: # caras en 10 lanzamientos; # defectuosas en una muestra de 100 piezas.



PMF de Binomial($n = 10$). Con $p = 0.5$ es simétrica; con $p \neq 0.5$ se sesga hacia np .

4.4 · Distribución Geométrica

Definición 4.3 · Distribución Geométrica

$X \sim \text{Geom}(p)$ con $p \in (0, 1)$ cuenta el número de ensayos Bernoulli(p) i.i.d. hasta el primer éxito (incluido). Soporte $I_X = \{1, 2, 3, \dots\}$, PMF:

$$p_X(k) = p(1-p)^{k-1}, \quad k \in I_X.$$

Momentos: $\mathbb{E}[X] = 1/p$, $\text{Var}(X) = (1-p)/p^2$.

Demostración

Reindexando $j = k - 1$ y usando la serie geométrica:

$$\sum_{k=1}^{\infty} p(1-p)^{k-1} = p \sum_{j=0}^{\infty} (1-p)^j = p \cdot \frac{1}{1-(1-p)} = p \cdot \frac{1}{p} = 1.$$

□

¿Cuándo usar? Cuando se repiten ensayos Bernoulli y se cuenta cuántos ensayos hacen falta hasta el primer éxito (no hay tope n).

Ejemplo: # lanzamientos hasta la primera cara; # productos hasta el primero defectuoso.

Proposición 4.1 · Pérdida de memoria (caso discreto)

$X \sim \text{Geom}(p)$ si y sólo si:

$$P(X > m + n \mid X > m) = P(X > n) \quad \forall m, n \in \mathbb{N}_0.$$

Es la *única* distribución discreta con esta propiedad (análoga discreta de la Exponencial).

Demostración

($\Rightarrow$) La *función de supervivencia* es $P(X > k) = (1 - p)^k$. Como $m + n \geq m$, $\{X > m + n\} \subseteq \{X > m\}$, luego:

$$P(X > m + n \mid X > m) = \frac{(1 - p)^{m+n}}{(1 - p)^m} = (1 - p)^n = P(X > n). \quad \checkmark$$

($\Leftarrow$) Sea $G(k) = P(X > k)$ con $G(0) = 1$. La propiedad equivale a $G(m+n) = G(m)G(n)$. Por inducción, $G(k) = G(1)^k = q^k$. La PMF resulta $p_X(k) = q^{k-1}(1 - q) = (1 - p)^{k-1}p$ con $p = 1 - q$. $\square$


Ejemplo 4.1 · Pérdida de memoria en acción (Geométrica)

Cada pieza es defectuosa con probabilidad $p = 0.1$. Sea $X = \#$ de piezas inspeccionadas hasta la primera defectuosa. Entonces $X \sim \text{Geom}(0.1)$ con $\mathbb{E}[X] = 10$.

Pregunta: ya inspeccionaste 5 piezas y todas resultaron buenas. ¿Cuál es la probabilidad de inspeccionar al menos 3 piezas más sin encontrar defectuosa?

Solución: $P(X > 8 \mid X > 5) = P(X > 3) = (0.9)^3 = 0.729$.

Interpretación. Las 5 inspecciones previas no aportan información: la probabilidad de inspeccionar otras 3 sin defectuosa es la misma que empezar de cero.



PMF de Geométrica: decrece geométricamente.

4.5 · Distribución Poisson**Definición 4.4 · Distribución Poisson**

$X \sim \text{Poisson}(\lambda)$ con $\lambda > 0$ cuenta eventos raros que ocurren a tasa constante en un intervalo. Soporte $I_X = \mathbb{N}_0$, PMF:

$$p_X(k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k \in I_X.$$

Momentos: $\mathbb{E}[X] = \lambda$, $\text{Var}(X) = \lambda$ (*equidispersión*).


Demostración

Usando la *serie de Taylor* de la exponencial $e^\lambda = \sum_{k=0}^{\infty} \lambda^k / k!$:

$$\sum_{k=0}^{\infty} \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \cdot e^\lambda = 1.$$

$\square$

¿Cuándo usar? Cuando se cuentan eventos que ocurren independientemente a una tasa constante en tiempo o espacio. Límite de $\text{Bin}(n, \lambda/n)$ cuando $n \rightarrow \infty$.
 Ejemplo: # llamadas/hora a un call center; # decaimientos radiactivos/seg.



PMF de Poisson para $\lambda \in \{1, 3, 7\}$.

4.6 · Distribución Uniforme

Definición 4.5 · Distribución Uniforme

$X \sim \text{Unif}(a, b)$ con $a < b$ tiene soporte $I_X = [a, b]$ y densidad constante:

$$f_X(x) = \frac{1}{b-a}, \quad x \in I_X, \quad F_X(x) = \frac{x-a}{b-a}.$$

Momentos: $\mathbb{E}[X] = (a+b)/2$, $\text{Var}(X) = (b-a)^2/12$.


Demostración

$$\int_a^b \frac{1}{b-a} dx = \frac{b-a}{b-a} = 1.$$

□

¿Cuándo usar? Cuando todo punto del intervalo $[a, b]$ es igualmente probable.

Aplicación crítica: la $\text{Unif}(0, 1)$ es la base computacional para generar cualquier distribución por transformada inversa: $F^{-1}(U) \sim F$.



4.7 · Distribución Exponencial

Definición 4.6 · Distribución Exponencial

$X \sim \text{Exp}(\lambda)$ con $\lambda > 0$ tiene soporte $I_X = [0, \infty)$ y:

$$f_X(x) = \lambda e^{-\lambda x}, \quad x \in I_X, \quad F_X(x) = 1 - e^{-\lambda x}.$$

Momentos: $\mathbb{E}[X] = 1/\lambda$, $\text{Var}(X) = 1/\lambda^2$.

Demostración

$$\int_0^\infty \lambda e^{-\lambda x} dx = [-e^{-\lambda x}]_0^\infty = 1. \quad \square$$

¿Cuándo usar? Tiempo continuo de espera entre eventos sucesivos en un proceso de Poisson de tasa λ . También para vidas útiles sin envejecimiento.

Ejemplo: tiempo entre llegadas de clientes; tiempo hasta la falla de un componente.

Proposición 4.2 · Propiedad de pérdida de memoria

$X \sim \text{Exp}(\lambda)$ si y sólo si:

$$P(X > s + t \mid X > s) = P(X > t) \quad \forall s, t \geq 0.$$

Es la *única* distribución continua con esta propiedad.

Demostración

($\Rightarrow$) La supervivencia es $\bar{F}_X(x) = e^{-\lambda x}$. Como $\{X > s + t\} \subseteq \{X > s\}$:

$$P(X > s + t \mid X > s) = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t). \quad \checkmark$$


($\Leftarrow$) Sea $G(x) = P(X > x)$. La propiedad da $G(s + t) = G(s)G(t)$ (ecuación de Cauchy multiplicativa). Bajo continuidad de G , las únicas soluciones son $G(x) = e^{-\lambda x}$. $\square$

Ejemplo 4.2 · Pérdida de memoria en acción

Call center con $\lambda = 4$ llamadas/hora ($1/\lambda = 15$ min). Llevas 10 min sin llamadas. ¿Probabilidad de esperar al menos 5 min más?

$$P(X > s + t \mid X > s) = P(X > t) = e^{-4/12} = e^{-1/3} \approx 0.7165.$$

El tiempo ya esperado *no aporta información*.



4.8 · Distribución Normal

Definición 4.7 · Distribución Normal

$X \sim \mathcal{N}(\mu, \sigma^2)$ tiene soporte $I_X = \mathbb{R}$ y densidad:

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.$$

Normal estándar $Z \sim \mathcal{N}(0, 1)$: $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$, FDA: $\Phi(z)$.

Estandarización: $Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$. **Momentos:** $\mathbb{E}[X] = \mu$, $\text{Var}(X) = \sigma^2$.


Demostración

Cambio de variable $u = (x - \mu)/\sigma$, $du = dx/\sigma$:

$$\int_{-\infty}^{\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/(2\sigma^2)} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-u^2/2} du = 1.$$

Donde se usó la *integral de Gauss* $\int_{-\infty}^{\infty} e^{-u^2/2} du = \sqrt{2\pi}$ (cuya prueba pasa a coordenadas polares). $\square$

¿Cuándo usar? La variable resulta de la suma de muchos efectos pequeños e independientes (Teorema Central del Límite).
Propiedad clave: cerrada bajo combinaciones lineales: si $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ independientes, $\sum a_i X_i \sim \mathcal{N}(\sum a_i \mu_i, \sum a_i^2 \sigma_i^2)$.



4.9 · Relaciones entre distribuciones

Conexiones entre las distribuciones de la Sección 4

- **Bernoulli** → **Binomial**: $\text{Bin}(n, p)$ es la suma de n Bernoulli(p) i.i.d. Caso particular: $\text{Bin}(1, p) = \text{Bernoulli}(p)$.
- **Bernoulli** → **Geométrica**: $\text{Geom}(p)$ cuenta cuántos ensayos Bernoulli(p) hacen falta para el primer éxito.
- **Binomial** → **Poisson**: $\text{Bin}(n, \lambda/n) \xrightarrow{n \rightarrow \infty} \text{Poisson}(\lambda)$.
- **Poisson** ↔ **Exponencial**: en un proceso de Poisson, los tiempos entre llegadas son $\text{Exp}(\lambda)$ i.i.d.
- **Geométrica** ↔ **Exponencial**: análoga discreta y continua.
- **Suma de Poissons**: $\text{Poisson}(\lambda_1) + \text{Poisson}(\lambda_2) = \text{Poisson}(\lambda_1 + \lambda_2)$.
- **Suma de Normales**: cerrada bajo combinaciones lineales independientes.
- **TCL** → **Normal**: $\text{Bin}(n, p) \approx \mathcal{N}(np, np(1-p))$ y $\text{Poisson}(\lambda) \approx \mathcal{N}(\lambda, \lambda)$ para parámetros grandes.
- **Uniforme** → **cualquier distribución**: si $U \sim \text{Unif}(0, 1)$ y F es una FDA, entonces $F^{-1}(U) \sim F$.

Sección 5: Vectores Aleatorios y Distribuciones Conjuntas

5.1 · Vectores aleatorios


Definición 5.1 · Vector aleatorio

Un **vector aleatorio** de dimensión n es una tupla $\mathbf{X} = (X_1, X_2, \dots, X_n)$ donde cada X_i es una variable aleatoria definida sobre el mismo espacio de probabilidad $(\Omega, \mathcal{F}, P)$. Equivalentemente, $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ medible.

Un vector aleatorio modela varias mediciones simultáneas sobre el mismo experimento.

Ejemplos: (altura, peso) de una persona; resultados de tres lanzamientos de un dado; (tiempo de espera, número de clientes) en una cola.

Las componentes pueden depender entre sí: estudiar cada X_i por separado no captura toda la información del vector.



Un vector aleatorio $\mathbf{X} = (X, Y)$ asigna a cada $\omega \in \Omega$ un par $(X(\omega), Y(\omega)) \in \mathbb{R}^2$.

5.2 · Caso general n -variado

Definición 5.2 · FDA conjunta (caso general)

Para un vector aleatorio $(X_1, \dots, X_n)$, la **FDA conjunta** es:

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n), \quad (x_1, \dots, x_n) \in \mathbb{R}^n.$$

Definición 5.3 · FDA marginal (caso general)

Sea $J = \{i_1, \dots, i_k\} \subseteq \{1, \dots, n\}$ un subconjunto de índices. La **FDA marginal** del subvector $(X_{i_1}, \dots, X_{i_k})$ se obtiene tomando límite $\rightarrow +\infty$ en *todas las variables que no están en J* :

$$F_{X_{i_1}, \dots, X_{i_k}}(x_{i_1}, \dots, x_{i_k}) = \lim_{x_j \rightarrow \infty, j \notin J} F_{X_1, \dots, X_n}(x_1, \dots, x_n).$$

Regla general para marginales: para obtener la marginal del subvector $\mathbf{X}_J$, elimina las variables fuera de J :

- En la **FDA**: hacerlas $\rightarrow +\infty$.
- En la **PMF**: sumar sobre todo su soporte (caso discreto).
- En la **PDF**: integrar sobre todo su soporte (caso continuo).

La conjunta determina unívocamente todas las marginales (univariadas, bivariadas, etc.), pero NO al revés.

Ejemplo 5.1 · Marginales de un vector trivariado continuo

Planteamiento. Sea (X, Y, Z) un vector aleatorio continuo con PDF conjunta:

$$f_{X,Y,Z}(x, y, z) = \begin{cases} 8xyz & \text{si } (x, y, z) \in [0, 1]^3, \\ 0 & \text{en otro caso.} \end{cases}$$

Vamos a calcular las marginales en distintas dimensiones y verificar consistencia.

(1) Verificación de normalización. Como las variables se separan en producto, podemos integrar cada una de forma independiente:

$$\iiint_{[0,1]^3} 8xyz \, dx \, dy \, dz = 8 \cdot \int_0^1 x \, dx \cdot \int_0^1 y \, dy \cdot \int_0^1 z \, dz = 8 \cdot \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = 1. \checkmark$$

Por tanto $f_{X,Y,Z}$ es una PDF válida.

(2) Marginal bivariada de (X, Y) : “eliminamos” la variable z integrando sobre todo su soporte $[0, 1]$:

$$f_{X,Y}(x, y) = \int_0^1 8xyz \, dz = 8xy \cdot \left[\frac{z^2}{2} \right]_0^1 = 8xy \cdot \frac{1}{2} = 4xy, \quad (x, y) \in [0, 1]^2.$$

Justificación: la marginal $f_{X,Y}$ describe la densidad del par (X, Y) sin importar qué valor tomó Z ; por eso “acumulamos” (integramos) sobre todos los z posibles.

(3) Marginal univariada de X : podemos obtenerla integrando $f_{X,Y}$ sobre y :

$$f_X(x) = \int_0^1 4xy \, dy = 4x \cdot \left[\frac{y^2}{2} \right]_0^1 = 4x \cdot \frac{1}{2} = 2x, \quad x \in [0, 1].$$

Por simetría, $f_Y(y) = 2y$ y $f_Z(z) = 2z$.

(4) Consistencia con la integral directa. La marginal de X también se obtiene integrando la conjunta sobre y y z a la vez (sin pasar por $f_{X,Y}$):

$$f_X(x) = \int_0^1 \int_0^1 8xyz \, dy \, dz = 8x \cdot \int_0^1 y \, dy \cdot \int_0^1 z \, dz = 8x \cdot \frac{1}{2} \cdot \frac{1}{2} = 2x. \checkmark$$

Justificación: obtener f_X de la conjunta $f_{X,Y,Z}$ o pasar antes por la bivariada $f_{X,Y}$ da el mismo resultado, porque la integración de Fubini-Tonelli permite hacer las integrales en cualquier orden.

(5) Verificación de que las marginales son válidas: $\int_0^1 2x \, dx = [x^2]_0^1 = 1. \checkmark$

(6) ¿Son X, Y, Z independientes? Verificamos si la conjunta factoriza como producto de marginales:

$$f_X(x) f_Y(y) f_Z(z) = 2x \cdot 2y \cdot 2z = 8xyz = f_{X,Y,Z}(x, y, z). \checkmark$$

Sí factoriza, luego X, Y, Z son *mutuamente independientes*, cada una con densidad $2u$ sobre $[0, 1]$ (que favorece valores cercanos a 1).

Lección clave. Para extraer cualquier marginal:

- identifica las variables a conservar (subconjunto J);
- integra la conjunta sobre el resto, usando los soportes correspondientes.

El resultado no depende del orden en que integres las variables eliminadas.

5.3 · Caso bivariado ($n = 2$)

Particularizamos a $n = 2$ por su importancia y por permitir visualización directa.

Definición 5.4 · FDA conjunta y marginales (caso bivariado)

Para un vector (X, Y) :

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y), \quad (x, y) \in \mathbb{R}^2.$$

Las **FDA marginales** se obtienen tomando límite en la otra variable:


$$F_X(x) = \lim_{y \rightarrow \infty} F_{X,Y}(x, y), \quad F_Y(y) = \lim_{x \rightarrow \infty} F_{X,Y}(x, y).$$

Proposición 5.1 · Propiedades de la FDA bivariada


$F_{X,Y} : \mathbb{R}^2 \rightarrow [0, 1]$ satisface:

1. **Monótona no decreciente** en cada variable.
2. **Continua por la derecha** en cada variable.
3. **Límites:** $F_{X,Y}(x, y) \rightarrow 0$ si $x \rightarrow -\infty$ o $y \rightarrow -\infty$; $\rightarrow 1$ si $x, y \rightarrow +\infty$ simultáneamente.
4. **Probabilidad sobre rectángulo:** para $a_1 < a_2$, $b_1 < b_2$,

$$P(a_1 < X \leq a_2, b_1 < Y \leq b_2) = F(a_2, b_2) - F(a_1, b_2) - F(a_2, b_1) + F(a_1, b_1).$$



La FDA conjunta $F_{X,Y}(x_0, y_0)$ asigna probabilidad al cuadrante inferior-izquierdo con esquina en (x_0, y_0) .



Las marginales f_X y f_Y son las proyecciones de la densidad conjunta sobre cada eje.

△ Atención

Las marginales no determinan la conjunta. Conocer F_X y F_Y por separado no permite reconstruir $F_{X,Y}$. La conjunta agrega información sobre la *estructura de dependencia* entre las componentes. Dos vectores con las mismas marginales pueden tener conjuntas distintas.

5.4 · Caso discreto

Cuando X, Y son v.a. discretas con valores en conjuntos numerables I_X e I_Y , la conjunta queda caracterizada por una *función de masa*.

Definición 5.5 · Función de masa conjunta (PMF conjunta)

La **PMF conjunta** de (X, Y) es:

$$p_{X,Y}(x, y) = P(X = x, Y = y), \quad (x, y) \in I_X \times I_Y.$$

Cumple: $p_{X,Y}(x, y) \geq 0$ y $\sum_{x \in I_X} \sum_{y \in I_Y} p_{X,Y}(x, y) = 1$.

Definición 5.6 · Función de masa marginal (PMF marginal)

Las **PMF marginales** se obtienen *sumando* sobre la otra variable:

$$p_X(x) = \sum_{y \in I_Y} p_{X,Y}(x, y), \quad p_Y(y) = \sum_{x \in I_X} p_{X,Y}(x, y).$$

Definición 5.7 · FDA conjunta (caso discreto)

La **FDA conjunta** en el caso discreto se obtiene sumando la PMF en el cuadrante inferior-izquierdo:

$$F_{X,Y}(x, y) = \sum_{x_i \leq x} \sum_{y_j \leq y} p_{X,Y}(x_i, y_j).$$

Recíprocamente, la PMF se recupera por diferencias finitas de la FDA.

Ejemplo 5.2 · Dos dados: PMF conjunta y marginales

Planteamiento. Se lanzan dos dados justos de 6 caras de manera independiente. Definimos:

- X = resultado del primer dado, $X \in I_X = \{1, 2, 3, 4, 5, 6\}$.
- Y = resultado del segundo dado, $Y \in I_Y = \{1, 2, 3, 4, 5, 6\}$.

El espacio muestral conjunto es $I_X \times I_Y$ con $|I_X \times I_Y| = 36$ pares posibles.

(1) PMF conjunta. Como los lanzamientos son *independientes* y cada cara es equiprobable ($p_X(i) = 1/6$, $p_Y(j) = 1/6$), la PMF conjunta factoriza:

$$p_{X,Y}(i, j) = P(X = i, Y = j) = P(X = i) \cdot P(Y = j) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36}, \quad (i, j) \in I_X \times I_Y.$$

Justificación: la independencia permite descomponer la conjunta en producto de marginales. Si los dados estuvieran “cargados” o pegados (no independientes), no podríamos hacer esto.

(2) Verificación de normalización. La PMF debe sumar 1:

$$\sum_{i=1}^6 \sum_{j=1}^6 p_{X,Y}(i, j) = 36 \cdot \frac{1}{36} = 1. \quad \checkmark$$

(3) Marginal de X . “Eliminamos” Y sumando sobre todos sus valores:

$$p_X(i) = \sum_{j=1}^6 p_{X,Y}(i, j) = \underbrace{\frac{1}{36} + \frac{1}{36} + \cdots + \frac{1}{36}}_{6 \text{ veces}} = \frac{6}{36} = \frac{1}{6}, \quad i \in \{1, \dots, 6\}.$$

Por simetría, $p_Y(j) = 1/6$. *Justificación:* sumar la fila i -ésima recorre todas las opciones de Y dado $X = i$, dejando solo la masa de probabilidad asociada a $X = i$ (sin importar qué tomó Y).

(4) Verificación de marginal válida: $\sum_{i=1}^6 p_X(i) = 6 \cdot 1/6 = 1. \quad \checkmark$

(5) Probabilidad sobre un evento. Calculemos $P(X + Y = 7)$ (clave en juegos de dados): los pares (i, j) con $i + j = 7$ son

$(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)$ — 6 pares disjuntos.

Por aditividad de la PMF:

$$P(X + Y = 7) = \sum_{(i,j): i+j=7} p_{X,Y}(i, j) = 6 \cdot \frac{1}{36} = \frac{1}{6} \approx 0.167.$$

(6) FDA conjunta evaluada. Por ejemplo $F_{X,Y}(3, 4) = P(X \leq 3, Y \leq 4)$: son $3 \cdot 4 = 12$ pares, luego $F_{X,Y}(3, 4) = 12/36 = 1/3$.

(7) ¿Recuperan las marginales la conjunta? Verifiquemos: $p_X(i)p_Y(j) = (1/6)(1/6) = 1/36 = p_{X,Y}(i, j)$. *✓ En este caso sí*, porque sabemos que X e Y son independientes. En general, las marginales no determinan la conjunta.

Lección clave. Cuando X, Y son independientes, la PMF conjunta es el producto de marginales y todo el cálculo se simplifica. Las marginales se obtienen sumando filas (para X) o columnas (para Y) en la cuadrícula de probabilidades.

		X (primer dado)						
		$p_Y(j)$	1	2	3	4	5	6
Y (segundo dado)	6	$\frac{1}{6}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
	5	$\frac{1}{6}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
	4	$\frac{1}{6}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
	3	$\frac{1}{6}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
	2	$\frac{1}{6}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
	1	$\frac{1}{6}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
		$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$p_X(i)$

PMF conjunta del par (X, Y) (cuadrícula central, todas $1/36$). Las marginales (barras laterales) se obtienen sumando cada fila o columna.

Definición 5.8 · PMF condicional (caso discreto)

Para $x \in I_X$ con $p_X(x) > 0$, la **PMF condicional** de Y dado $X = x$ es:

$$p_{Y|X}(y | x) = P(Y = y | X = x) = \frac{p_{X,Y}(x, y)}{p_X(x)}, \quad y \in I_Y.$$

Cumple: $p_{Y|X}(y | x) \geq 0$ y $\sum_{y \in I_Y} p_{Y|X}(y | x) = 1$ (es una PMF válida como función de y , fijando x).

Intuición. La condicional $p_{Y|X}(\cdot | x)$ rebanada la PMF conjunta a lo largo de la fila $X = x$ y la renormaliza dividiendo por $p_X(x)$ (la masa total de esa fila). Es la PMF de Y dentro del subuniverso donde $X = x$.

Ejemplo 5.3 · Suma de dos dados condicionada al primero

Sean X = primer dado, Y = segundo dado (independientes, justos), y $S = X + Y$ la suma. Calculemos la PMF condicional de S dado X .

(1) **Conjunta de (X, S) :** para que $S = s$ dado $X = x$, debe ser $Y = s - x$, y eso ocurre si $s - x \in \{1, \dots, 6\}$. Luego:

$$p_{X,S}(x, s) = P(X = x, Y = s - x) = \begin{cases} \frac{1}{36} & x \in \{1, \dots, 6\}, s - x \in \{1, \dots, 6\}, \\ 0 & \text{en otro caso.} \end{cases}$$

(2) **PMF condicional de S dado $X = x$:**

$$p_{S|X}(s | x) = \frac{p_{X,S}(x, s)}{p_X(x)} = \frac{1/36}{1/6} = \frac{1}{6}, \quad s \in \{x+1, x+2, \dots, x+6\}.$$

Es decir, dado $X = x$, la suma S es uniforme en $\{x+1, \dots, x+6\}$ (un desplazamiento de la distribución de Y).

(3) **Caso concreto:** si $X = 4$, entonces $S \in \{5, 6, 7, 8, 9, 10\}$ con probabilidad $1/6$ cada uno. Por ejemplo, $P(S = 7 | X = 4) = 1/6$.

(4) **Verificación:** $\sum_{s=x+1}^{x+6} p_{S|X}(s | x) = 6 \cdot 1/6 = 1$. ✓

		X					
		1	2	3	4	5	6
Y	6	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
	5	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
	4	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
	3	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
	2	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$
	1	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$

→ **fila $X = 4$:** $\Rightarrow p_{Y|X}(y | 4) = \frac{1}{6}$
 masa total $1/6$ (uniforme en $\{1, \dots, 6\}$)

Condicionar a $X = 4$ “rebanar” la fila correspondiente y renormaliza su masa total ($1/6$) para obtener la PMF condicional de Y (uniforme en $\{1, \dots, 6\}$, como era de esperarse por independencia).

5.5 · Caso continuo

Cuando (X, Y) admite una función de densidad, la conjunta queda caracterizada por una *función de densidad*.

Definición 5.9 · Función de densidad conjunta (PDF conjunta)

(X, Y) es **continuo** si existe $f_{X,Y} : \mathbb{R}^2 \rightarrow [0, \infty)$ tal que:

$$F_{X,Y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(s, t) \, dt \, ds.$$

Cumple: $f_{X,Y}(x, y) \geq 0$ y $\iint_{\mathbb{R}^2} f_{X,Y}(x, y) \, dx \, dy = 1$.

Probabilidad sobre un conjunto: $P((X, Y) \in B) = \iint_B f_{X,Y}(x, y) \, dx \, dy$.

Definición 5.10 · Función de densidad marginal (PDF marginal)

Las **PDF marginales** se obtienen *integrando* sobre la otra variable:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dy, \quad f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dx.$$

Definición 5.11 · FDA conjunta (caso continuo)

La FDA se obtiene como integral doble de la PDF (definición misma de continuidad). Recíprocamente, donde $F_{X,Y}$ es diferenciable, la PDF se recupera por derivación:

$$f_{X,Y}(x, y) = \frac{\partial^2 F_{X,Y}(x, y)}{\partial x \partial y}.$$

Ejemplo 5.4 · Uniforme en el cuadrado unitario

Planteamiento. Sea (X, Y) un punto elegido uniformemente al azar en el cuadrado $[0, 1]^2$. “Uniforme” significa que ningún subregión del cuadrado está privilegiada: la probabilidad de que el punto caiga en una región es proporcional a su *área*.

(1) PDF conjunta. La densidad uniforme sobre $[0, 1]^2$ es constante:

$$f_{X,Y}(x, y) = \begin{cases} 1 & 0 \leq x \leq 1, 0 \leq y \leq 1, \\ 0 & \text{en otro caso.} \end{cases}$$

Justificación: la PDF debe ser tal que $\iint f_{X,Y} = 1$; con soporte de área 1 (cuadrado unitario), la densidad constante que cumple esto es $f \equiv 1$ sobre el cuadrado.

(2) Verificación de normalización.

$$\iint_{\mathbb{R}^2} f_{X,Y}(x, y) dx dy = \iint_{[0,1]^2} 1 dx dy = \int_0^1 \int_0^1 1 dy dx = \int_0^1 1 dx = 1. \checkmark$$

(3) Marginal de X . “Eliminamos” Y integrando sobre todo su rango:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy = \int_0^1 1 dy = 1, \quad x \in [0, 1].$$

Justificación: para cada x fijo en $[0, 1]$, Y recorre $[0, 1]$ uniformemente y contribuye total 1. Fuera de $[0, 1]$, la conjunta es 0 y la marginal también.

Por simetría, $f_Y(y) = 1$ para $y \in [0, 1]$. Por tanto:

$$X \sim \text{Unif}(0, 1), \quad Y \sim \text{Unif}(0, 1).$$

(4) FDA conjunta. Para $(x, y) \in [0, 1]^2$:

$$F_{X,Y}(x, y) = \int_0^x \int_0^y 1 dt ds = x \cdot y.$$

Verificación: $f_{X,Y}(x, y) = \partial^2 F_{X,Y} / (\partial x \partial y) = 1. \checkmark$

(5) Probabilidad sobre un conjunto: $P(X^2 + Y^2 \leq 1/4)$. La región $B = \{(x, y) : x^2 + y^2 \leq 1/4\}$ intersectada con $[0, 1]^2$ es el cuarto de círculo de radio $1/2$ en el primer cuadrante. Como la densidad es 1:

$$P((X, Y) \in B) = \iint_B f_{X,Y} dx dy = \text{área}(B) = \frac{1}{4} \cdot \pi \left(\frac{1}{2}\right)^2 = \frac{\pi}{16} \approx 0.1963.$$

Justificación: con densidad uniforme $f \equiv 1$ sobre el cuadrado unitario, la probabilidad de cualquier subregión es su área. Esto es la traducción continua de la “regla clásica” $P(A) = |A|/|\Omega|$.


(6) ¿Son X e Y independientes? Verificamos si la conjunta factoriza:

$$f_X(x) f_Y(y) = 1 \cdot 1 = 1 = f_{X,Y}(x, y) \quad \text{en } [0, 1]^2. \checkmark$$

Sí factoriza, luego X e Y son *independientes*.

(7) Probabilidad de que $X > Y$. Por simetría, $P(X > Y) = 1/2$. Verificación directa: el evento $\{X > Y\}$ es el triángulo bajo la diagonal en $[0, 1]^2$, de área $1/2$.

Lección clave. Para una distribución uniforme en una región $R \subseteq \mathbb{R}^2$ con área finita, la PDF conjunta es $f = 1/\text{área}(R)$ sobre R , y la probabilidad de un sub-evento B es $\text{área}(B \cap R)/\text{área}(R)$. Las marginales se obtienen integrando: para cada x , calcular la longitud del corte vertical del soporte.



Soporte de $(X, Y) \sim \text{Unif}([0, 1]^2)$ (área 1). Región sombreada ámbar: $\{X^2 + Y^2 \leq 1/4\}$, cuya probabilidad es su área: $\pi/16$.

△ Atención

Independencia $\neq$ Descorrelación. Si X, Y son independientes, su covarianza es 0 y la PDF/PMF conjunta factoriza: $f_{X,Y} = f_X \cdot f_Y$. Pero el recíproco *no* es cierto en general: dos variables pueden tener covarianza 0 *sin* ser independientes (caso clásico: $Y = X^2$ con $X \sim \text{Unif}(-1, 1)$). La factorización de la conjunta es la prueba estricta de independencia.

Definición 5.12 · PDF condicional (caso continuo)

Para x con $f_X(x) > 0$, la **PDF condicional** de Y dado $X = x$ es:

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)}, \quad y \in \mathbb{R}.$$

Cumple: $f_{Y|X}(y | x) \geq 0$ y $\int_{\mathbb{R}} f_{Y|X}(y | x) dy = 1$ (es una PDF válida *como función de y*, fijando x).

Intuición. La condicional $f_{Y|X}(\cdot | x)$ es la rebanada vertical de la densidad conjunta en $X = x$, renormalizada para integrar 1. Es la densidad de Y cuando ya sabemos que $X = x$.

Cuidado con $P(X = x) = 0$: en el caso continuo, condicionar a un punto exacto requiere esta definición como límite, no como cociente directo de probabilidades.

Ejemplo 5.5 · Uniforme en un triángulo

Sea (X, Y) uniforme sobre el triángulo $T = \{(x, y) : 0 \leq y \leq x \leq 1\}$.

(1) **PDF conjunta.** El área del triángulo es $1/2$, luego:

$$f_{X,Y}(x, y) = \begin{cases} 2 & 0 \leq y \leq x \leq 1, \\ 0 & \text{en otro caso.} \end{cases}$$

(2) **Marginal de X .** Para $x \in [0, 1]$, integrando y sobre el rango válido $[0, x]$:

$$f_X(x) = \int_0^x 2 dy = 2x.$$

Es una densidad triangular que favorece valores grandes de X .


(3) **PDF condicional de Y dado $X = x$.** Para $x \in (0, 1]$:

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)} = \frac{2}{2x} = \frac{1}{x}, \quad y \in [0, x].$$

Es decir, $Y | X = x \sim \text{Unif}(0, x)$: dado el primer valor $X = x$, Y se distribuye uniformemente en $[0, x]$.

(4) **Verificación.** $\int_0^x \frac{1}{x} dy = \frac{1}{x} \cdot x = 1$. ✓

(5) **Caso concreto.** Si $X = 0.7$, entonces $Y \sim \text{Unif}(0, 0.7)$, con densidad $f_{Y|X}(y | 0.7) = 1/0.7 \approx 1.43$ sobre $[0, 0.7]$.



PDF condicional: la rebanada vertical en $X = 0.7$ tiene altura 2 y largo 0.7, luego masa 1.4. Renormalizando (dividiendo por $f_X(0.7) = 1.4$) se obtiene una distribución uniforme en $[0, 0.7]$.

5.6 · Esperanza condicional

La **esperanza condicional** $\mathbb{E}[Y | X = x]$ es la esperanza de Y usando la distribución condicional $p_{Y|X}(\cdot | x)$ o $f_{Y|X}(\cdot | x)$. Como función de x , define una variable aleatoria $\mathbb{E}[Y | X]$ que “predice” Y a partir de X .

Definición 5.13 · Esperanza condicional (caso discreto)

Si (X, Y) es discreto y $p_X(x) > 0$:

$$\mathbb{E}[Y | X = x] = \sum_{y \in I_Y} y \cdot p_{Y|X}(y | x) = \frac{1}{p_X(x)} \sum_{y \in I_Y} y \cdot p_{X,Y}(x, y).$$

Definición 5.14 · Esperanza condicional (caso continuo)

Si (X, Y) es continuo y $f_X(x) > 0$:

$$\mathbb{E}[Y | X = x] = \int_{\mathbb{R}} y \cdot f_{Y|X}(y | x) dy = \frac{1}{f_X(x)} \int_{\mathbb{R}} y \cdot f_{X,Y}(x, y) dy.$$

Como variable aleatoria. Definiendo $\mathbb{E}[Y | X]$ por la fórmula $\mathbb{E}[Y | X](\omega) = \mathbb{E}[Y | X = X(\omega)]$, la esperanza condicional es ella misma una v.a. función de X . Su valor esperado es justamente $\mathbb{E}[Y]$ (ver propiedad de la torre).

Proposición 5.2 · Propiedades de la esperanza condicional

Sean X, Y v.a., $g : \mathbb{R} \rightarrow \mathbb{R}$ medible y $a, b \in \mathbb{R}$ constantes. Entonces:

1. **Linealidad:** $\mathbb{E}[aY_1 + bY_2 | X] = a \mathbb{E}[Y_1 | X] + b \mathbb{E}[Y_2 | X]$.
2. **Constante:** $\mathbb{E}[c | X] = c$ para toda constante c .
3. **Función de la condición (sale fuera):** $\mathbb{E}[g(X) Y | X] = g(X) \mathbb{E}[Y | X]$. En particular $\mathbb{E}[g(X) | X] = g(X)$.
4. **Independencia:** si $X \perp Y$, entonces $\mathbb{E}[Y | X] = \mathbb{E}[Y]$ (constante).
5. **Propiedad de la torre (tower property):**

$$\mathbb{E}[\mathbb{E}[Y | X]] = \mathbb{E}[Y].$$

Esta es la *ley de la esperanza total* en su forma más general.

6. **Monotonía:** si $Y_1 \leq Y_2$ casi seguramente, $\mathbb{E}[Y_1 | X] \leq \mathbb{E}[Y_2 | X]$.

Ejemplo 5.6 · Esperanza condicional en el triángulo

Continuamos con (X, Y) uniforme en $T = \{0 \leq y \leq x \leq 1\}$. Vimos que $Y | X = x \sim \text{Unif}(0, x)$, luego:

$$\mathbb{E}[Y | X = x] = \frac{0 + x}{2} = \frac{x}{2}, \quad x \in [0, 1].$$

Por tanto, como variable aleatoria, $\mathbb{E}[Y | X] = X/2$.

Verificación por la torre. Calculamos $\mathbb{E}[Y]$ de dos maneras:

- **Por la torre:** $\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y | X]] = \mathbb{E}[X/2]$. Recordando que $f_X(x) = 2x$, $\mathbb{E}[X] = \int_0^1 x \cdot 2x \, dx = 2/3$. Luego $\mathbb{E}[Y] = (1/2) \cdot (2/3) = 1/3$.
- **Directo:** $\mathbb{E}[Y] = \int_0^1 y \cdot f_Y(y) \, dy$ con $f_Y(y) = 2(1-y)$: $\mathbb{E}[Y] = \int_0^1 y \cdot 2(1-y) \, dy = \int_0^1 (2y - 2y^2) \, dy = 1 - 2/3 = 1/3$. ✓

Ambos métodos coinciden.

Resumen: Conjunta $\rightarrow$ Marginal: suma/integración. PMF/PDF $\leftrightarrow$ FDA: suma/integración o derivación. Marginal $\nrightarrow$ Conjunta: falta info de dependencia.

Condicionales: rebanan la conjunta y renormalizan. $\mathbb{E}[Y | X]$ es v.a. función de X ; la torre ($\mathbb{E}[\mathbb{E}[Y | X]] = \mathbb{E}[Y]$) permite calcular $\mathbb{E}[Y]$ “por capas”.

Sección 6: Proceso de Poisson**6.1 · Procesos estocásticos y de conteo****Definición 6.1 · Proceso estocástico**

Un **proceso estocástico** es una familia de variables aleatorias $\{X(t), t \in T\}$ definidas sobre el mismo espacio de probabilidad, con T conjunto de índices (típicamente tiempo).


- Si $T = \{0, 1, 2, \dots\}$: tiempo discreto.
- Si $T = [0, \infty)$: tiempo continuo.

Definición 6.2 · Proceso de conteo

$\{N(t), t \geq 0\}$ es un **proceso de conteo** si:

1. $N(t) \in \mathbb{N}_0$.
2. $N(t)$ es no decreciente.
3. Para $s < t$, $N(t) - N(s) = \#$ eventos en $(s, t]$.

Típicamente $N(0) = 0$.



6.2 · Incrementos independientes y estacionarios

Un **incremento** $N(t) - N(s)$ del proceso es el número de eventos ocurridos en el intervalo $(s, t]$. Las dos propiedades siguientes describen *cómo se relacionan* los incrementos sobre distintos intervalos.


Definición 6.3 · Incrementos independientes

$\{N(t)\}$ tiene **incrementos independientes** si para cualquier partición $0 \leq t_0 < t_1 < t_2 < \dots < t_k$, las variables aleatorias

$$N(t_1) - N(t_0), \quad N(t_2) - N(t_1), \quad \dots, \quad N(t_k) - N(t_{k-1})$$

son *mutuamente independientes*.

Interpretación: lo que ocurre en un intervalo *no aporta información* sobre lo que ocurre en cualquier otro intervalo *disjunto*. Cada intervalo es un “mundo aparte” estadísticamente.




Incrementos independientes: el conteo en $(s, t]$ no informa sobre el conteo en $(u, v]$ (intervalos disjuntos). Cada intervalo es “un mundo aparte”.

Definición 6.4 · Incrementos estacionarios

$\{N(t)\}$ tiene **incrementos estacionarios** si la distribución de $N(t + s) - N(t)$ depende solo de la longitud s del intervalo, no de su posición t :

$$N(t + s) - N(t) \stackrel{d}{=} N(s) - N(0), \quad \forall t, s \geq 0.$$

Interpretación: la “tasa” del proceso es *constante en el tiempo*; intervalos de la misma longitud tienen la misma distribución de conteos sin importar dónde estén colocados.



Incrementos estacionarios: tres intervalos de la misma longitud s ubicados en posiciones distintas; sus conteos tienen idéntica distribución. En un proceso de Poisson de tasa λ , todos $\sim \text{Poisson}(\lambda s)$.

Diferencia clave. Las dos propiedades describen cosas distintas:


- **Independientes:** dos intervalos disjuntos cualesquiera *no se influyen*.
- **Estacionarios:** el mismo intervalo trasladado *mantiene su distribución*.

Un proceso puede tener una sin la otra. El proceso de Poisson homogéneo las cumple ambas; el proceso de Poisson no-homogéneo (con tasa $\lambda(t)$ variable) tiene incrementos independientes pero no estacionarios.

Tres escenarios al trabajar con dos intervalos. Para un proceso de Poisson de tasa $\lambda = 2/\text{min}$, fijamos dos intervalos y analizamos sus incrementos según la posición relativa. La regla general: *descomponer en piezas disjuntas, aplicar incrementos independientes, sumar Poissons*.

Ejemplo 6.1 · Caso 1: intervalos disjuntos

Intervalos: $(0, 3]$ y $(5, 8]$ minutos. $\lambda = 2/\text{min}$.



Análisis. Como $(0, 3] \cap (5, 8] = \emptyset$, los incrementos son *independientes*:


$$N_A := N(3) - N(0) \sim \text{Poisson}(\lambda \cdot 3) = \text{Poisson}(6), \quad N_B := N(8) - N(5) \sim \text{Poisson}(6), \quad N_A \perp N_B.$$

Conjunta. La probabilidad de un evento conjunto factoriza:

$$P(N_A = 2, N_B = 4) = P(N_A = 2) \cdot P(N_B = 4) = \frac{6^2 e^{-6}}{2!} \cdot \frac{6^4 e^{-6}}{4!} \approx 0.0446 \cdot 0.1339 \approx 0.0060.$$

Ejemplo 6.2 · Caso 2: intervalos que se intersectan

Intervalos: $(0, 5]$ y $(3, 8]$ minutos (se solapan en $(3, 5]$). $\lambda = 2/\text{min}$.



Estrategia: descomponer en tres piezas disjuntas.

$$A := N(3) - N(0), \quad B := N(5) - N(3), \quad C := N(8) - N(5).$$

Por incrementos independientes y estacionarios:

$$A \sim \text{Poisson}(6), \quad B \sim \text{Poisson}(4), \quad C \sim \text{Poisson}(6), \quad A, B, C \text{ mutuamente independientes.}$$

Luego:

- $N(5) - N(0) = A + B \sim \text{Poisson}(10)$ (suma de Poissons indep.).
- $N(8) - N(3) = B + C \sim \text{Poisson}(10)$.
- **NO son independientes:** comparten B . La covarianza es:


$$\text{Cov}(A + B, B + C) = \text{Var}(B) = 4.$$

Probabilidad conjunta. Para calcular $P(N(5) - N(0) = k_1, N(8) - N(3) = k_2)$ hay que sumar sobre los valores compartidos de B :

$$P(A + B = k_1, B + C = k_2) = \sum_{b=0}^{\min(k_1, k_2)} P(B = b) P(A = k_1 - b) P(C = k_2 - b).$$

Ejemplo 6.3 · Caso 3: un intervalo dentro del otro

Intervalos: $(0, 8]$ contiene a $(2, 5]$. $\lambda = 2/\text{min}$.



Estrategia: descomponer en tres piezas disjuntas.

$$A_1 := N(2) - N(0), \quad A_2 := N(5) - N(2), \quad A_3 := N(8) - N(5).$$

Por incrementos independientes y estacionarios:

$$A_1 \sim \text{Poisson}(4), \quad A_2 \sim \text{Poisson}(6), \quad A_3 \sim \text{Poisson}(6), \quad \text{mutuamente independientes.}$$

Luego:

- Conteo del intervalo grande: $N(8) - N(0) = A_1 + A_2 + A_3 \sim \text{Poisson}(16)$.
- Conteo del intervalo pequeño: $N(5) - N(2) = A_2 \sim \text{Poisson}(6)$.
- **NO son independientes:** el grande *contiene* al pequeño, luego $N(8) - N(0) \geq N(5) - N(2)$ siempre. La covarianza: $\text{Cov}(A_1 + A_2 + A_3, A_2) = \text{Var}(A_2) = 6$.
- Pero la *diferencia* grande – pequeño = $A_1 + A_3 \sim \text{Poisson}(10)$ *sí* es independiente de A_2 = pequeño. Las piezas *fuera* del interior son independientes del interior.

Receta universal. Frente a varios intervalos relacionados:

1. Identifica las piezas atómicas disjuntas (los intervalos más pequeños que generan todo lo demás por uniones).
2. Por estacionariedad, cada pieza es Poisson de tasa $\lambda \cdot (\text{longitud})$.
3. Por independencia de incrementos, las piezas atómicas son mutuamente independientes.
4. Cualquier conteo de interés se expresa como suma de piezas; las sumas de Poissons independientes son Poissons.
5. La dependencia entre dos conteos compuestos se mide por las piezas compartidas.

6.3 · Proceso de Poisson homogéneo**Definición 6.5 · Proceso de Poisson homogéneo**

$\{N(t)\}$ es un **proceso de Poisson** con tasa $\lambda > 0$ si:

1. $N(0) = 0$.
2. Tiene incrementos independientes.
3. $N(t+s) - N(t) \sim \text{Poisson}(\lambda s)$.

Proposición 6.1 · Distribución de $N(t)$

En un proceso de Poisson con tasa $\lambda > 0$, para todo $t \geq 0$:

$$N(t) \sim \text{Poisson}(\lambda t).$$

En particular:

$$P(N(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}, \quad k \in \mathbb{N}_0, \quad \mathbb{E}[N(t)] = \text{Var}(N(t)) = \lambda t.$$

Demostración

De la propiedad (1), $N(0) = 0$. Aplicando la propiedad (3) con $s := t$ y $t := 0$:

$$N(t) - N(0) \sim \text{Poisson}(\lambda t),$$

pero $N(t) - N(0) = N(t) - 0 = N(t)$, de donde $N(t) \sim \text{Poisson}(\lambda t)$.

Los momentos $\mathbb{E}[N(t)] = \text{Var}(N(t)) = \lambda t$ se siguen de las propiedades de la distribución Poisson (equidispersión, Sección 4.5). $\square$

Interpretación: en un intervalo de longitud t , el número de eventos sigue Poisson con parámetro λt . Por tanto en promedio ocurren λt eventos en un intervalo de longitud t , lo que justifica llamar a λ la tasa (eventos por unidad de tiempo).


6.4 · Tiempos entre eventos

Proposición 6.2 · $T_i \sim \text{Exponencial}$

En un proceso de Poisson de tasa λ , los tiempos entre eventos $T_1, T_2, \dots$ son i.i.d. $\sim \text{Exp}(\lambda)$.

Demostración

$P(T_1 > t) = P(N(t) = 0) = e^{-\lambda t}$, luego $T_1 \sim \text{Exp}(\lambda)$. Por incrementos independientes y estacionarios, T_2 es independiente de T_1 y también $\text{Exp}(\lambda)$. Inducción completa. $\square$



Tiempos entre llegadas T_k y tiempos de las n -ésimas llegadas S_n .

△ Atención

Pérdida de memoria es contraintuitivo. Si llevas 10 min esperando un evento $\text{Exp}(\lambda)$ sin que ocurra, la probabilidad de esperar otros 5 min es *la misma* que esperar 5 min desde cero. NO te “acercas” al evento por haber esperado. Este es el modelo de *fallo aleatorio puro* (sin desgaste). Si el sistema tiene envejecimiento real (componentes que se deterioran, baterías que se gastan), la Exponencial NO es apropiada — se necesita una distribución con tasa de fallo creciente como Weibull.

6.5 · Competencia de tasa

Proposición 6.3 · Competencia entre dos procesos de Poisson

Sean N_1, N_2 procesos independientes con tasas λ_1, λ_2 . Para los primeros eventos $T^{(i)}$:

1. $T = \min(T^{(1)}, T^{(2)}) \sim \text{Exp}(\lambda_1 + \lambda_2)$.
2. $P(T^{(1)} < T^{(2)}) = \lambda_1 / (\lambda_1 + \lambda_2)$.

Demostración

$P(T > t) = e^{-\lambda_1 t} e^{-\lambda_2 t} = e^{-(\lambda_1 + \lambda_2)t}$. Por integración: $P(T^{(1)} < T^{(2)}) = \int_0^\infty \lambda_1 e^{-\lambda_1 t} e^{-\lambda_2 t} dt = \lambda_1 / (\lambda_1 + \lambda_2)$. $\square$

Ejemplo 6.4 · Dos cajas en un banco

Llegan clientes de dos tipos a un banco, de manera independiente:

- Tipo A (caja preferencial) a tasa $\lambda_A = 6/\text{hora}$.
- Tipo B (caja regular) a tasa $\lambda_B = 4/\text{hora}$.

(1) **Tiempo hasta el próximo cliente (cualquier tipo):** $T = \min(T^{(A)}, T^{(B)}) \sim \text{Exp}(6 + 4) = \text{Exp}(10)$. Por tanto:

$$\mathbb{E}[T] = \frac{1}{\lambda_A + \lambda_B} = \frac{1}{10} \text{ h} = 6 \text{ min.}$$


(2) **Probabilidad de que el próximo sea de tipo A :**

$$P(T^{(A)} < T^{(B)}) = \frac{\lambda_A}{\lambda_A + \lambda_B} = \frac{6}{10} = 0.6.$$

(3) **Probabilidad de esperar más de 5 minutos:**

$$P(T > 5/60) = e^{-10 \cdot 5/60} = e^{-5/6} \approx 0.435.$$

(4) **Interpretación:** la mezcla de los dos procesos actúa como un solo proceso de Poisson con tasa suma. Cada cliente que llega es independientemente tipo A con probabilidad $\lambda_A / (\lambda_A + \lambda_B) = 0.6$ o tipo B con 0.4, sin importar las llegadas previas.



6.6 · Tiempo de la n -ésima llegada

Proposición 6.4 · $S_n \sim \text{Erlang}$

$S_n = T_1 + \dots + T_n \sim \text{Erlang}(n, \lambda)$:

$$f_{S_n}(t) = \frac{\lambda^n t^{n-1} e^{-\lambda t}}{(n-1)!}, \quad t \geq 0.$$

$$\mathbb{E}[S_n] = n/\lambda, \quad \text{Var}(S_n) = n/\lambda^2.$$

Demostración

Conexión clave: $\{S_n \leq t\} = \{N(t) \geq n\}$ (la n -ésima llegada ocurre antes de t si y solo si han ocurrido al menos n eventos hasta t). Entonces:

$$F_{S_n}(t) = P(N(t) \geq n) = \sum_{k=n}^{\infty} \frac{(\lambda t)^k e^{-\lambda t}}{k!}.$$

Derivando respecto a t y simplificando (los términos se cancelan en cascada):

$$f_{S_n}(t) = \frac{\lambda^n t^{n-1} e^{-\lambda t}}{(n-1)!}.$$

□

Ejemplo 6.5 · Tiempo hasta la quinta llamada

En un call center con tasa $\lambda = 5$ llamadas/min, el tiempo S_5 hasta la quinta llamada sigue una $\text{Erlang}(5, 5)$.


Tiempo medio: $\mathbb{E}[S_5] = 5/5 = 1$ min.

Varianza: $\text{Var}(S_5) = 5/25 = 0.2$ min², $\sigma = \sqrt{0.2} \approx 0.447$ min.

Probabilidad de esperar a lo más 1 min:

$$P(S_5 \leq 1) = P(N(1) \geq 5) = 1 - \sum_{k=0}^4 \frac{5^k e^{-5}}{k!} \approx 0.560.$$

Hay aproximadamente un 56 % de probabilidad de que las primeras cinco llamadas ocurran dentro del primer minuto.



6.7 · Procesos de Poisson bifurcados (*thinning*)

Proposición 6.5 · Bifurcación

Sea $\{N(t)\}$ un proceso de Poisson de tasa λ . Cada evento se clasifica independientemente como tipo 1 (prob. p) o tipo 2 (prob. $1-p$). Entonces N_1 y N_2 son procesos de Poisson **independientes** con tasas λp y $\lambda(1-p)$.

Sorpresa: aunque comparten el mismo proceso original, los procesos resultantes son independientes.

Ejemplo 6.6 · Tienda con compradores y curiosos


Llegan personas a una tienda como un proceso de Poisson de tasa $\lambda = 20/\text{hora}$. Cada persona compra con probabilidad $p = 0.3$, independientemente de las demás.

(1) Bifurcación:

- Compradores: proceso de Poisson de tasa $\lambda p = 20 \cdot 0.3 = 6/\text{hora}$.
- No compradores: proceso de Poisson de tasa $\lambda(1-p) = 20 \cdot 0.7 = 14/\text{hora}$.
- Ambos procesos son *independientes*.

(2) Número esperado de compradores en 2 horas: $6 \cdot 2 = 12$.**(3) Probabilidad de exactamente 5 compradores en 1 hora:** $P(N_1(1) = 5) = \frac{6^5 e^{-6}}{5!} \approx 0.161$.**(4) Independencia en acción:** si en una hora hubo 14 no-compradores (mucho más de los 14 esperados, $\text{Var}(=) 14$), no aporta información sobre cuántos compradores hubo — los procesos son completamente desacoplados.**△ Atención**

Sorpresa de la independencia. Aunque N_1 y N_2 se construyen del *mismo* proceso original (claramente $N_1(t) + N_2(t) = N(t)$ en cada instante), resultan estadísticamente independientes. Esto contradice la intuición de “si suben los compradores, deben bajar los curiosos” — esa intuición aplicaría si fijáramos $N(t)$, pero no la fijamos. La elegancia del proceso de Poisson es que las fluctuaciones de cada tipo se compensan exactamente para que ambos sean Poisson independientes.

**6.8 · Suma (superposición) de procesos de Poisson****Proposición 6.6 · Superposición**


Si $N_1, \dots, N_k$ son procesos de Poisson independientes con tasas $\lambda_1, \dots, \lambda_k$, entonces $N(t) = \sum_i N_i(t)$ es Poisson de tasa $\sum_i \lambda_i$.

Demostración

Verificamos las tres propiedades del proceso de Poisson:

1. $N(0) = \sum N_i(0) = 0$.
2. Cada N_i tiene incrementos independientes, y entre procesos son independientes $\Rightarrow$ los incrementos de N también lo son.
3. Para un intervalo de longitud s : $N_i(t+s) - N_i(t) \sim \text{Poisson}(\lambda_i s)$. Por aditividad de Poissons independientes: $N(t+s) - N(t) \sim \text{Poisson}(\sum \lambda_i s)$.

□



Superposición: dos procesos independientes se combinan en uno con tasa suma. Es la operación inversa de la bifurcación.

Ejemplo 6.7 · Llamadas combinadas

Un call center recibe llamadas de dos sucursales independientes: sucursal 1 a tasa $\lambda_1 = 3/\text{min}$, sucursal 2 a tasa $\lambda_2 = 5/\text{min}$.

- (1) **Tasa total:** el flujo combinado es Poisson de tasa $\lambda = 8/\text{min}$.
- (2) **Llamadas en 10 min:** $N(10) \sim \text{Poisson}(80)$, $\mathbb{E}[N(10)] = 80$.
- (3) **Tiempo entre llamadas (cualquier sucursal):** $\text{Exp}(8)$, media $1/8 \text{ min} = 7.5 \text{ s}$.
- (4) **Probabilidad de que la próxima llamada sea de la sucursal 1:** $\lambda_1/(\lambda_1 + \lambda_2) = 3/8 = 0.375$.

6.9 · Distribución condicional del primer evento**Proposición 6.7 · $T_1 \mid N(t) = 1$ es uniforme**

En un proceso de Poisson de tasa λ , dado $N(t) = 1$:

$$T_1 \mid N(t) = 1 \sim \text{Unif}(0, t).$$

Demostración

Para $0 \leq s \leq t$:

$$P(T_1 \leq s \mid N(t) = 1) = \frac{P(T_1 \leq s, N(t) = 1)}{P(N(t) = 1)}.$$

El evento $\{T_1 \leq s, N(t) = 1\}$ es “hubo exactamente 1 evento en $(0, s]$ y 0 eventos en $(s, t]$ ”. Por incrementos independientes:

$$P(T_1 \leq s, N(t) = 1) = P(N(s) = 1) \cdot P(N(t) - N(s) = 0) = \lambda s e^{-\lambda s} \cdot e^{-\lambda(t-s)} = \lambda s e^{-\lambda t}.$$

Y $P(N(t) = 1) = \lambda t e^{-\lambda t}$. Dividiendo:

$$P(T_1 \leq s \mid N(t) = 1) = \frac{\lambda s e^{-\lambda t}}{\lambda t e^{-\lambda t}} = \frac{s}{t}.$$

Esa es la FDA de $\text{Unif}(0, t)$. □

Ejemplo 6.8 · Ubicación del único cliente


En una estación de servicio, los clientes llegan como Poisson($\lambda = 2/\text{hora}$). Sabemos que en 1 hora llegó exactamente 1 cliente. ¿En qué momento?

Por la proposición, $T_1 \mid N(1) = 1 \sim \text{Unif}(0, 1)$.

- Probabilidad de que llegara en los primeros 20 minutos: $20/60 = 1/3 \approx 0.333$.
- Probabilidad de que llegara entre los minutos 30 y 45: $(45 - 30)/60 = 0.25$.
- Tiempo esperado de llegada: $\mathbb{E}[T_1 \mid N(1) = 1] = 1/2 \text{ hora} = 30 \text{ min}$.

Observación: aunque *a priori* $T_1 \sim \text{Exp}(2)$ (con media $1/2 = 30 \text{ min}$), al condicionar a que ocurrió exactamente uno en $(0, 1]$, el tiempo se vuelve uniformemente distribuido en el intervalo — ya no exponencial.

Generalización: dado $N(t) = n$, los n tiempos son los estadísticos de orden de n uniformes i.i.d. en $(0, t)$.



Conexiones clave del módulo

- $\text{Bin}(n, \lambda/n) \xrightarrow{n \rightarrow \infty} \text{Poisson}(\lambda)$ (eventos raros)
- $\text{Poisson}(\lambda) \xrightarrow{\lambda \rightarrow \infty} \mathcal{N}(\lambda, \lambda)$ (normalidad asintótica)
- Geométrica $\Leftrightarrow$ Exponencial (pérdida de memoria)
- Tiempos entre llegadas Poisson $\sim \text{Exp}(\lambda)$ i.i.d. (proceso de Poisson)
- $S_n \sim \text{Erlang}(n, \lambda)$ (tiempo de la n -ésima llegada)
- FDA F_X determina la ley de X