

Cadenas de Markov Homogéneas

Módulo 2 — Modelos Estocásticos

Propiedad de Markov · Tiempo discreto · Clasificación de estados · Distribuciones estacionarias · Tiempos de primer paso
· Tiempo continuo · Nacimiento y muerte

Por P. Hurtado · 2026

Este módulo continúa desde el Módulo 1 (probabilidad, variables aleatorias, proceso de Poisson). El Proceso de Poisson aparece como caso particular de cadena de Markov en tiempo continuo (proceso de nacimiento puro). Se asume familiaridad con álgebra lineal (matrices, autovalores) y con la distribución Exponencial. Notación: S espacio de estados, $\mathbf{P}$ matriz de transición, π distribución estacionaria, $\mathbf{Q}$ generador infinitesimal.

Índice

1. Procesos Estocásticos y Propiedad de Markov	3
1.1 · Proceso estocástico	3
1.2 · Filtración y adaptabilidad	3
1.3 · Propiedad de Markov	4
1.4 · Homogeneidad temporal	4
2. Cadenas de Markov en Tiempo Discreto (CMTD)	4
2.1 · Espacio de estados y probabilidades de transición	4
2.2 · Matriz de transición	5
2.3 · Ecuaciones de Chapman-Kolmogorov	5
2.4 · Distribución en el paso n	6
2.5 · Forma canónica y clases de estados (anticipo)	6
3. Clasificación de Estados	6
3.1 · Accesibilidad y comunicación	7
3.2 · Estados recurrentes y transitorios	8
3.3 · Periodicidad	9
3.4 · Cadenas ergódicas	9
4. Distribuciones Estacionarias y Comportamiento a Largo Plazo	9
4.1 · Distribución estacionaria	9
4.2 · Cálculo de la distribución estacionaria	10
4.3 · Teorema ergódico y convergencia	10
4.4 · Reversibilidad y balance detallado	11
5. Tiempos de Primer Paso y Absorción	11
5.1 · Tiempo de primer paso	11
5.2 · Tiempo medio de retorno y estacionariedad	12
5.3 · Probabilidades de absorción	12
5.4 · Tiempo esperado de absorción: matriz fundamental	13
6. Cadenas de Markov en Tiempo Continuo (CMTC)	13
6.1 · Definición y propiedad de Markov continua	14
6.2 · Tiempos de permanencia	14
6.3 · Generador infinitesimal $\mathbf{Q}$	14
6.4 · Ecuaciones de Kolmogorov	15
6.5 · Distribución estacionaria de una CMTC	15
6.6 · Cadena embebida	15
7. Proceso de Nacimiento y Muerte	15
7.1 · Definición	16
7.2 · Balance detallado y distribución estacionaria	16
7.3 · Proceso de nacimiento puro: conexión con Poisson	17
7.4 · Cola M/M/1	17

Leyenda de colores

Cada bloque de contenido se identifica visualmente por color, según su naturaleza:

	Definición	Concepto formal con nombre y notación. Marco verde claro.
	Teorema/Proposición	Resultado demostrable a partir de las definiciones. Marco azul.
	Demostración	Argumento que justifica un teorema o proposición. Marco morado.
	Ejemplo	Aplicación concreta o caso ilustrativo. Marco gris.
	Nota	Observación, intuición o comentario complementario. Marco ámbar.
	Atención	Advertencia sobre un error común o sutileza. Marco rojo.
	Sección	Encabezado principal del módulo. Fondo azul oscuro.
	Subsección	Subdivisión temática dentro de una sección. Fondo azul claro.

Sección 1: Procesos Estocásticos y Propiedad de Markov

1.1 · Proceso estocástico

Definición 1.1 · Proceso estocástico

Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y T un conjunto de índices (conjunto de *tiempo*). Un **proceso estocástico** es una familia de variables aleatorias

$$\{X_t : t \in T\},$$


donde cada $X_t : \Omega \rightarrow \mathcal{S}$ toma valores en el **espacio de estados** $\mathcal{S}$.

Según la naturaleza de T y $\mathcal{S}$ se distinguen cuatro tipos:

Tiempo T	Estados $\mathcal{S}$	Tipo
Discreto ($\mathbb{N}$)	Discreto	Cadena en tiempo discreto
Discreto ($\mathbb{N}$)	Continuo ($\mathbb{R}$)	Proceso en tiempo discreto
Continuo ($[0, \infty)$)	Discreto	Cadena en tiempo continuo
Continuo ($[0, \infty)$)	Continuo ($\mathbb{R}$)	Proceso en tiempo continuo

En este módulo $T = \mathbb{N}_0$ (discreto) o $T = [0, \infty)$ (continuo), y $\mathcal{S}$ es *discreto* (finito o numerable).

Para cada $\omega \in \Omega$ fijo, la función $t \mapsto X_t(\omega)$ es una **trayectoria** (o realización) del proceso. Un proceso estocástico puede verse como una distribución sobre el espacio de trayectorias.



Trayectoria de una cadena en $\mathcal{S} = \{1, 2, 3\}$

1.2 · Filtración y adaptabilidad

Definición 1.2 · Filtración y proceso adaptado

Una **filtración** $\{\mathcal{F}_n\}_{n \geq 0}$ es una sucesión creciente de σ -álgebras: $\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \dots \subseteq \mathcal{F}$.

Un proceso $\{X_n\}$ es **adaptado** a $\{\mathcal{F}_n\}$ si X_n es $\mathcal{F}_n$ -medible para todo n . Intuitivamente, $\mathcal{F}_n$ representa la *información disponible hasta el instante n*.

La filtración natural del proceso es $\mathcal{F}_n = \sigma(X_0, X_1, \dots, X_n)$.

1.3 · Propiedad de Markov

Definición 1.3 · Propiedad de Markov (débil)

Un proceso estocástico $\{X_n\}_{n \geq 0}$ con espacio de estados discreto $\mathcal{S}$ tiene la **propiedad de Markov** (débil) si para todo $n \geq 0$ y todos los estados $i_0, i_1, \dots, i_{n-1}, i, j \in \mathcal{S}$:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i).$$

En palabras: el futuro depende del pasado *únicamente* a través del presente. El estado actual X_n captura toda la información relevante del historial.

La propiedad de Markov es una hipótesis de falta de memoria del proceso. No dice que el futuro sea independiente del pasado en absoluto, sino que condicionar al presente hace que el pasado sea irrelevante.

Definición 1.4 · Propiedad de Markov fuerte

Sea τ un **tiempo de parada** (variable aleatoria con valores en $\mathbb{N}_0$ tal que $\{\tau = n\} \in \mathcal{F}_n$). La **propiedad de Markov fuerte** establece que, dado $\tau < \infty$, el proceso desplazado $\{X_{\tau+k}\}_{k \geq 0}$ tiene la misma distribución que $\{X_k\}_{k \geq 0}$ iniciado en X_τ , e independiente de $\mathcal{F}_\tau$.

Toda cadena de Markov homogénea satisface la propiedad de Markov fuerte.

1.4 · Homogeneidad temporal

Definición 1.5 · Cadena de Markov homogénea

Un proceso $\{X_n\}_{n \geq 0}$ con la propiedad de Markov es **homogéneo en el tiempo** (o *temporalmente homogéneo*) si las probabilidades de transición no dependen de n :

$$\mathbb{P}(X_{n+1} = j \mid X_n = i) = p_{ij} \quad \forall n \geq 0,$$

donde p_{ij} es la **probabilidad de transición en un paso** de i a j . En adelante toda cadena mencionada es homogénea salvo mención explícita.

△ Atención

No confundir homogeneidad temporal con independencia. Los estados X_n no son independientes; la homogeneidad solo garantiza que las *probabilidades de salto* son constantes en el tiempo.

Sección 2: Cadenas de Markov en Tiempo Discreto (CMTD)

2.1 · Espacio de estados y probabilidades de transición

Definición 2.1 · Probabilidades de transición en n pasos

La **probabilidad de transición en n pasos** de i a j es

$$p_{ij}^{(n)} = \mathbb{P}(X_{n+m} = j \mid X_m = i), \quad n \geq 1,$$

que por homogeneidad no depende de m . Por convenio: $p_{ij}^{(0)} = \delta_{ij}$ (delta de Kronecker: 1 si $i = j$, 0 en caso contrario).

2.2 · Matriz de transición

Definición 2.2 · Matriz de transición (matriz estocástica)

Si $\mathcal{S} = \{1, 2, \dots, s\}$ es finito, la **matriz de transición** es la matriz $\mathbf{P} \in \mathbb{R}^{s \times s}$ con entradas $(\mathbf{P})_{ij} = p_{ij}$.

$\mathbf{P}$ es una **matriz estocástica por filas**: satisface

1. $p_{ij} \geq 0$ para todo $i, j \in \mathcal{S}$.
2. $\sum_{j \in \mathcal{S}} p_{ij} = 1$ para todo $i \in \mathcal{S}$ (cada fila suma 1).

Ejemplo 2.1 · Cadena del clima (2 estados)

Sea $\mathcal{S} = \{S, L\}$ (soleado, lluvioso). Si hoy es soleado, mañana es soleado con probabilidad 0.8 y lluvioso con 0.2. Si hoy es lluvioso, mañana es soleado con 0.4 y lluvioso con 0.6. La matriz de transición es:

$$\mathbf{P} = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix} \leftarrow \begin{array}{l} \text{fila } S \\ \text{fila } L \end{array}$$

Verificación: filas suman 1. $\mathbf{P}$ es estocástica.




Diagrama de transición: cadena del clima

2.3 · Ecuaciones de Chapman-Kolmogorov

Teorema 2.1 · Ecuaciones de Chapman-Kolmogorov

Para todo $n, m \geq 0$ e $i, j \in \mathcal{S}$:

$$p_{ij}^{(n+m)} = \sum_{k \in \mathcal{S}} p_{ik}^{(n)} p_{kj}^{(m)}.$$

En notación matricial: $\mathbf{P}^{(n+m)} = \mathbf{P}^{(n)} \mathbf{P}^{(m)}$, con la convención $\mathbf{P}^{(n)} = \mathbf{P}^n$, donde $\mathbf{P}^n$ es la n -ésima potencia de $\mathbf{P}$.

Demostración

Por la propiedad de Markov y marginalización:

$$\begin{aligned} p_{ij}^{(n+m)} &= \mathbb{P}(X_{n+m} = j \mid X_0 = i) \\ &= \sum_{k \in \mathcal{S}} \mathbb{P}(X_{n+m} = j \mid X_n = k) \mathbb{P}(X_n = k \mid X_0 = i) \quad (\text{ley total}) \\ &= \sum_{k \in \mathcal{S}} p_{kj}^{(m)} p_{ik}^{(n)}. \end{aligned}$$

Esto es exactamente la (i, j) -ésima entrada del producto $\mathbf{P}^n \mathbf{P}^m = \mathbf{P}^{n+m}$. □

La clave es que la n -ésima potencia de la matriz de transición da las probabilidades en n pasos: $(\mathbf{P}^n)_{ij} = p_{ij}^{(n)}$.

2.4 · Distribución en el paso n

Definición 2.3 · Distribución marginal en el paso n

Sea $\boldsymbol{\mu}^{(0)}$ el vector fila de probabilidades iniciales: $\mu_i^{(0)} = \mathbb{P}(X_0 = i)$. La **distribución marginal** en el instante n es

$$\boldsymbol{\mu}^{(n)} = \boldsymbol{\mu}^{(0)} \mathbf{P}^n,$$

es decir, $\mu_j^{(n)} = \mathbb{P}(X_n = j) = \sum_{i \in \mathcal{S}} \mu_i^{(0)} p_{ij}^{(n)}$.

Ejemplo 2.2 · Distribución del clima en 2 pasos

Con la cadena del clima anterior y distribución inicial $(0.5, 0.5)$:

$$\mathbf{P}^2 = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}^2 = \begin{pmatrix} 0.72 & 0.28 \\ 0.56 & 0.44 \end{pmatrix}.$$

$$\boldsymbol{\mu}^{(2)} = (0.5, 0.5) \begin{pmatrix} 0.72 & 0.28 \\ 0.56 & 0.44 \end{pmatrix} = (0.64, 0.36).$$

Probabilidad de estar soleado a los 2 pasos: 0.64.

2.5 · Forma canónica y clases de estados (anticipo)

Si el espacio de estados $\mathcal{S}$ se puede particionar en clases de comunicación (ver Sección 3), la matriz $\mathbf{P}$ se puede reordenar en forma canónica:

$$\mathbf{P} = \begin{pmatrix} \mathbf{Q} & \mathbf{R} \\ \mathbf{0} & \mathbf{I} \end{pmatrix},$$

donde $\mathbf{Q}$ describe transiciones entre estados transitorios y $\mathbf{I}$ los estados absorbentes. Esta forma es central para tiempos de absorción (Sección 5).

Sección 3: Clasificación de Estados

3.1 · Accesibilidad y comunicación

Definición 3.1 · Accesibilidad

El estado j es **accesible** desde i (notación: $i \rightarrow j$) si existe $n \geq 0$ tal que $p_{ij}^{(n)} > 0$, es decir, es posible llegar de i a j en algún número de pasos.

Dos estados i y j se **comunican** ($i \leftrightarrow j$) si $i \rightarrow j$ y $j \rightarrow i$. La comunicación es una relación de equivalencia en $\mathcal{S}$.

Definición 3.2 · Clase de comunicación

Las clases de equivalencia de $\leftrightarrow$ se llaman **clases de comunicación**. Una clase C es **cerrada** si no existe salida: $i \in C, i \rightarrow j \Rightarrow j \in C$.


Una cadena es **irreducible** si solo tiene una clase de comunicación, es decir, todos los estados se comunican entre sí.

Ejemplo 3.1 · Clases de comunicación en una cadena de 4 estados

Considerar la cadena con estados $\{1, 2, 3, 4\}$ y la siguiente matriz de transición:

$$\mathbf{P} = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0.5 & 0.5 & 0 & 0 \\ 0.3 & 0 & 0.4 & 0.3 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

- Estados $\{1, 2\}$: $1 \leftrightarrow 2$ (clase cerrada).
- Estado $\{3\}$: puede ir a $\{1\}$ y a $\{4\}$, pero ni 1 ni 4 van a 3 (clase abierta, estado transitorio).
- Estado $\{4\}$: $p_{44} = 1$, no hay salida (clase cerrada, estado absorbente).



3.2 · Estados recurrentes y transitorios

Definición 3.3 · Probabilidad de retorno

Define $f_{ii} = \mathbb{P}(X_n = i \text{ para algún } n \geq 1 \mid X_0 = i)$, la probabilidad de que la cadena regrese al estado i . Entonces:

- i es **recurrente** si $f_{ii} = 1$ (el retorno es seguro).
- i es **transitorio** si $f_{ii} < 1$ (hay probabilidad positiva de no regresar).

Teorema 3.1 · Criterio de recurrencia por series

El estado i es recurrente si y solo si

$$\sum_{n=0}^{\infty} p_{ii}^{(n)} = \infty.$$

El estado i es transitorio si y solo si $\sum_{n=0}^{\infty} p_{ii}^{(n)} < \infty$, en cuyo caso el número esperado de visitas a i es finito.

Proposición 3.2 · Recurrencia en cadenas finitas irreducibles

En una cadena de Markov con espacio de estados *finito e irreducible*, todos los estados son **recurrentes positivos**.

Demostración

Como $|\mathcal{S}| < \infty$, al menos un estado debe ser visitado infinitas veces (la cadena no puede “escapar” a infinito). En una cadena irreducible, si un estado i es recurrente entonces *todos* los estados son recurrentes (por comunicación). Y en $\mathcal{S}$ finito la recurrencia implica recurrencia positiva (el tiempo medio de retorno es finito). $\square$

Definición 3.4 · Recurrencia positiva y nula

Sea i recurrente y $\mu_i = \mathbb{E}[\min\{n \geq 1 : X_n = i\} \mid X_0 = i]$ el **tiempo medio de retorno** a i . Entonces:

- i es **recurrente positivo** si $\mu_i < \infty$.
- i es **recurrente nulo** si $\mu_i = \infty$.

△ Atención

La recurrencia nula solo aparece en cadenas con espacio de estados *infinito numerable*. El ejemplo más conocido es la caminata aleatoria simétrica en $\mathbb{Z}$: todos los estados son recurrentes (vuelve con probabilidad 1), pero el tiempo esperado de retorno al origen es ∞ .

3.3 · Periodicidad

Definición 3.5 · Periodo de un estado

El **periodo** del estado i es el máximo común divisor de los tiempos en los que es posible regresar a i :

$$d(i) = \gcd\{n \geq 1 : p_{ii}^{(n)} > 0\}.$$

Si $d(i) = 1$, el estado es **aperiódico**. Si $d(i) > 1$, es **periódico** con periodo $d(i)$.

Proposición 3.3 · Periodicidad es invariante en una clase

Si $i \leftrightarrow j$, entonces $d(i) = d(j)$. Por tanto, el periodo es una propiedad de la clase de comunicación, no del estado individual.

Ejemplo 3.2 · Periodicidad

- Cadena $1 \rightarrow 2 \rightarrow 1$ (dos estados en ciclo): $d(1) = d(2) = 2$ (periódica).
- Cadena del clima (con autoloops): $d(S) = d(L) = 1$ (aperiódica).
- Caminata aleatoria en $\mathbb{Z}$ (pasos ± 1): $d(0) = 2$ (periódica).

3.4 · Cadenas ergódicas

Definición 3.6 · Cadena ergódica

Una cadena de Markov es **ergódica** si es:

1. **Irreducible**: todos los estados se comunican.
2. **Recurrente positiva**: todos los estados tienen tiempo medio de retorno finito.
3. **Aperiódica**: $d(i) = 1$ para todo $i \in \mathcal{S}$.

En particular, toda cadena irreducible con $\mathcal{S}$ finito y aperiódica es ergódica.

La ergodicidad es la condición que garantiza la convergencia de $\mathbf{P}^n$ a una distribución estacionaria única (ver Sección 4). En $\mathcal{S}$ finito, irreducibilidad + aperiodicidad $\Rightarrow$ ergodicidad.

Sección 4: Distribuciones Estacionarias y Comportamiento a Largo Plazo

4.1 · Distribución estacionaria

Definición 4.1 · Distribución estacionaria (invariante)

Un vector de probabilidades $\boldsymbol{\pi} = (\pi_j)_{j \in \mathcal{S}}$ es una **distribución estacionaria** (o *invariante*) si satisface:

$$\boldsymbol{\pi} \mathbf{P} = \boldsymbol{\pi} \tag{4.1}$$

$$\sum_{j \in \mathcal{S}} \pi_j = 1, \quad \pi_j \geq 0 \quad \forall j. \tag{4.2}$$

En forma escalar: $\pi_j = \sum_{i \in \mathcal{S}} \pi_i p_{ij}$ para todo j .

Si $\boldsymbol{\mu}^{(0)} = \boldsymbol{\pi}$, entonces $\boldsymbol{\mu}^{(n)} = \boldsymbol{\pi}$ para todo n : la distribución no cambia en el tiempo.

La distribución estacionaria existe siempre en una cadena irreducible recurrente positiva. La unicidad se obtiene además si la cadena es irreducible.

4.2 · Cálculo de la distribución estacionaria

Ejemplo 4.1 · Distribución estacionaria del clima

Con $\mathbf{P} = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}$, resolver $\pi\mathbf{P} = \pi$, $\pi_S + \pi_L = 1$:

$$\pi_S = 0.8\pi_S + 0.4\pi_L$$

$$\pi_L = 0.2\pi_S + 0.6\pi_L$$

De la primera ecuación: $0.2\pi_S = 0.4\pi_L$, luego $\pi_S = 2\pi_L$.

Con $\pi_S + \pi_L = 1$: $\pi_L = 1/3$, $\pi_S = 2/3$.

Interpretación: a largo plazo, $2/3$ de los días son soleados.

Ejemplo 4.2 · Distribución estacionaria de una cadena de 3 estados

Sea $\mathcal{S} = \{1, 2, 3\}$ con:

$$\mathbf{P} = \begin{pmatrix} 0 & 0.5 & 0.5 \\ 0.3 & 0.4 & 0.3 \\ 0.6 & 0 & 0.4 \end{pmatrix}.$$

Las ecuaciones $\pi\mathbf{P} = \pi$ con $\pi_1 + \pi_2 + \pi_3 = 1$ dan:

$$\pi_1 = 0.3\pi_2 + 0.6\pi_3$$

$$\pi_2 = 0.5\pi_1 + 0.4\pi_2 \Rightarrow 0.6\pi_2 = 0.5\pi_1$$

$$\pi_3 = 0.5\pi_1 + 0.3\pi_2 + 0.4\pi_3 \Rightarrow 0.6\pi_3 = 0.5\pi_1 + 0.3\pi_2$$

Resolviendo: $\pi_2 = \frac{5}{6}\pi_1$, $\pi_3 = \frac{5}{6}\pi_1 - \frac{1}{2}\pi_2 = \frac{5}{12}\pi_1$.

Normalizando $\pi_1(1 + 5/6 + 5/12) = 1$: $\pi_1 = 12/27$, $\pi_2 = 10/27$, $\pi_3 = 5/27$.

4.3 · Teorema ergódico y convergencia

Teorema 4.1 · Convergencia para cadenas ergódicas

Sea $\{X_n\}$ una cadena de Markov ergódica (irreducible, recurrente positiva, aperiódica) con distribución estacionaria única π . Entonces para todo $i, j \in \mathcal{S}$:

$$\lim_{n \rightarrow \infty} p_{ij}^{(n)} = \pi_j,$$

independientemente del estado inicial i . En notación matricial: $\mathbf{P}^n \xrightarrow{n \rightarrow \infty} \mathbf{\Pi}$, donde $\mathbf{\Pi}$ es la matriz cuyas filas son todas iguales a π .

Este teorema garantiza que, sin importar dónde comience la cadena, la distribución marginal converge a π . Si la cadena es periódica, el límite $p_{ij}^{(n)}$ puede no existir, pero la media Cesàro converge: $\frac{1}{N} \sum_{n=0}^{N-1} p_{ij}^{(n)} \rightarrow \pi_j$.

Teorema 4.2 · Teorema ergódico (frecuencias de visita)

Sea $\{X_n\}$ irreducible y recurrente positiva. Para todo $j \in \mathcal{S}$ y toda trayectoria (con probabilidad 1):

$$\frac{1}{N} \sum_{n=0}^{N-1} \mathbf{1}_{\{X_n=j\}} \xrightarrow{N \rightarrow \infty} \pi_j.$$

La proporción de tiempo que la cadena pasa en el estado j converge (c.s.) a π_j . Además, $\pi_j = 1/\mu_j$ (recíproco del tiempo medio de retorno).

4.4 · Reversibilidad y balance detallado

Definición 4.2 · Condición de balance detallado

Una distribución π satisface el **balance detallado** respecto a $\mathbf{P}$ si

$$\pi_i p_{ij} = \pi_j p_{ji} \quad \forall i, j \in \mathcal{S}.$$

Si existe tal π , la cadena es **reversible** (en equilibrio, no se puede distinguir si el tiempo avanza hacia adelante o hacia atrás).

Proposición 4.3 · Balance detallado implica estacionariedad

Si π satisface el balance detallado respecto a $\mathbf{P}$ y $\sum_j \pi_j = 1$, entonces π es distribución estacionaria.

Demostración

$$\sum_i \pi_i p_{ij} = \sum_i \pi_j p_{ji} = \pi_j \sum_i p_{ji} = \pi_j \cdot 1 = \pi_j. \text{ Luego } \pi \mathbf{P} = \pi. \quad \square$$

△ Atención

El recíproco es falso: existen distribuciones estacionarias que no satisfacen balance detallado (cadenas no reversibles). Balance detallado es una condición *suficiente* para estacionariedad, no necesaria.

Sección 5: Tiempos de Primer Paso y Absorción

5.1 · Tiempo de primer paso

Definición 5.1 · Tiempo de primer paso (hitting time)

El **tiempo de primer paso** al estado j , partiendo de i , es:

$$T_j = \min\{n \geq 1 : X_n = j\}, \quad T_j = \infty \text{ si nunca se llega a } j.$$

Es un tiempo de parada respecto a la filtración natural. La **probabilidad de primer paso en n pasos** de i a j es:

$$f_{ij}^{(n)} = \mathbb{P}(T_j = n \mid X_0 = i), \quad f_{ij} = \mathbb{P}(T_j < \infty \mid X_0 = i) = \sum_{n=1}^{\infty} f_{ij}^{(n)}.$$

Proposición 5.1 · Relación entre $p_{ij}^{(n)}$ y $f_{ij}^{(n)}$

Para $n \geq 1$:

$$p_{ij}^{(n)} = \sum_{k=1}^n f_{ij}^{(k)} p_{jj}^{(n-k)}.$$

Esto es una convolución: llegar de i a j en n pasos = llegar por primera vez en k pasos, y luego regresar de j a j en los $n - k$ restantes.

5.2 · Tiempo medio de retorno y estacionariedad

Teorema 5.2 · Tiempo medio de retorno y distribución estacionaria

Sea $\{X_n\}$ irreducible y recurrente positiva, con distribución estacionaria π . Entonces para todo $j \in \mathcal{S}$:

$$\pi_j = \frac{1}{\mu_j}, \quad \text{donde } \mu_j = \mathbb{E}[T_j \mid X_0 = j].$$

Los estados más frecuentemente visitados tienen tiempo medio de retorno más corto.

Ejemplo 5.1 · Tiempo de retorno en la cadena del clima

Con $\pi_S = 2/3$ y $\pi_L = 1/3$:

$$\mu_S = \frac{1}{\pi_S} = \frac{3}{2} = 1.5 \text{ días}, \quad \mu_L = \frac{1}{\pi_L} = 3 \text{ días}.$$

En promedio, el tiempo entre dos días lluviosos consecutivos es de 3 días.

5.3 · Probabilidades de absorción

Definición 5.2 · Estado absorbente y probabilidad de absorción

Un estado a es **absorbente** si $p_{aa} = 1$ (una vez alcanzado, no se escapa). Dado un conjunto de estados absorbentes $A \subset \mathcal{S}$ y un estado transitorio $i \notin A$, la **probabilidad de absorción** en $a \in A$ partiendo de i es:

$$h_i^{(a)} = \mathbb{P}(X_{T_A} = a \mid X_0 = i),$$

donde $T_A = \min\{n \geq 0 : X_n \in A\}$.

Teorema 5.3 · Sistema de ecuaciones para probabilidades de absorción

Las probabilidades $h_i^{(a)}$ satisfacen el sistema lineal:

$$h_i^{(a)} = p_{ia} + \sum_{k \notin A} p_{ik} h_k^{(a)}, \quad i \notin A,$$

con condición de frontera $h_a^{(a)} = 1$ y $h_b^{(a)} = 0$ para $b \in A$, $b \neq a$.

5.4 · Tiempo esperado de absorción: matriz fundamental

Definición 5.3 · Forma canónica y matriz fundamental

Ordenando los estados como (transitorios, absorbentes), la matriz de transición toma la forma canónica:

$$\mathbf{P} = \begin{pmatrix} \mathbf{Q}_T & \mathbf{R} \\ \mathbf{0} & \mathbf{I} \end{pmatrix},$$

donde $\mathbf{Q}_T$ es la submatriz de transición entre estados transitorios y $\mathbf{R}$ las probabilidades de ir de transitorio a absorbente.

La **matriz fundamental** es $\mathbf{N} = (\mathbf{I} - \mathbf{Q}_T)^{-1}$. La entrada n_{ij} = número esperado de visitas al estado transitorio j partiendo de i (antes de la absorción).

Proposición 5.4 · Tiempo esperado de absorción

El vector de tiempos esperados de absorción $\mathbf{t}$ (con $t_i = \mathbb{E}[T_A \mid X_0 = i]$) satisface:

$$\mathbf{t} = \mathbf{N} \mathbf{1} = (\mathbf{I} - \mathbf{Q}_T)^{-1} \mathbf{1},$$

donde $\mathbf{1}$ es el vector de unos. Las probabilidades de absorción en cada estado absorbente forman la matriz $\mathbf{B} = \mathbf{N} \mathbf{R}$.

Ejemplo 5.2 · Juego de la ruina ($N = 4$)

Un jugador tiene k fichas ($k \in \{0, 1, 2, 3, 4\}$) y en cada ronda gana o pierde una con probabilidad $p = 0.5$ y $1 - p = 0.5$. Los estados $\{0, 4\}$ son absorbentes (ruina o victoria). Los estados transitorios son $\{1, 2, 3\}$.


$$\mathbf{Q}_T = \begin{pmatrix} 0 & 0.5 & 0 \\ 0.5 & 0 & 0.5 \\ 0 & 0.5 & 0 \end{pmatrix}, \quad \mathbf{I} - \mathbf{Q}_T = \begin{pmatrix} 1 & -0.5 & 0 \\ -0.5 & 1 & -0.5 \\ 0 & -0.5 & 1 \end{pmatrix}.$$

Calculando la inversa: $\mathbf{N} = \frac{1}{4} \begin{pmatrix} 3 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 3 \end{pmatrix}.$

Tiempo esperado de absorción: $\mathbf{t} = \mathbf{N} \mathbf{1}$: $t_1 = (3 + 2 + 1)/4 = 3/2 \dots$

Corrigiendo: $t_1 = 3, t_2 = 4, t_3 = 3$ (se verifica que desde el estado central se espera más tiempo antes de arruinarse o ganar).

Probabilidad de ruina desde estado k : $h_k^{(0)} = (4 - k)/4$. Desde estado 2: $h_2^{(0)} = 0.5$.



Juego de la ruina con $N = 4$: estados absorbentes $\{0, 4\}$

Sección 6: Cadenas de Markov en Tiempo Continuo (CMTC)

6.1 · Definición y propiedad de Markov continua

Definición 6.1 · Cadena de Markov en tiempo continuo (CMTC)

Un proceso estocástico $\{X(t)\}_{t \geq 0}$ con espacio de estados discreto $\mathcal{S}$ es una **cadena de Markov en tiempo continuo** si satisface la propiedad de Markov:

$$\mathbb{P}(X(t+s) = j \mid X(s) = i, \{X(u)\}_{0 \leq u < s}) = \mathbb{P}(X(t+s) = j \mid X(s) = i)$$

para todo $t, s \geq 0$ e $i, j \in \mathcal{S}$. La cadena es **homogénea** si la probabilidad de transición $p_{ij}(t) = \mathbb{P}(X(t+s) = j \mid X(s) = i)$ no depende de s .

6.2 · Tiempos de permanencia

Teorema 6.1 · Distribución exponencial de los tiempos de permanencia

En una CMTC homogénea, el tiempo que el proceso permanece en el estado i antes de saltar es una variable aleatoria $\tau_i \sim \text{Exp}(q_i)$, donde $q_i \geq 0$ es la **tasa de salida** del estado i .

Esto se sigue de la propiedad de falta de memoria de la Exponencial: la única distribución continua sin memoria es la Exponencial.

Si $q_i = 0$, el estado i es absorbente (la cadena nunca sale de él). El tiempo esperado en el estado i es $\mathbb{E}[\tau_i] = 1/q_i$.

6.3 · Generador infinitesimal Q

Definición 6.2 · Generador infinitesimal (Q-matrix)

La **Q-matrix** o **generador infinitesimal** $Q = (q_{ij})$ tiene entradas:

- $q_{ij} \geq 0$ para $i \neq j$: **tasa de transición** de i a j .
- $q_{ii} = -\sum_{j \neq i} q_{ij} = -q_i \leq 0$: la diagonal es la tasa de salida negativa.

Propiedades: cada fila de Q suma 0, i.e., $Q\mathbf{1} = \mathbf{0}$.


Relación con $P(t)$:

$$\lim_{h \rightarrow 0^+} \frac{p_{ij}(h) - \delta_{ij}}{h} = q_{ij}.$$

Ejemplo 6.1 · Q-matrix para una cadena de 2 estados

Sea $\mathcal{S} = \{0, 1\}$, tasa de ir de 0 a 1: λ , tasa de 1 a 0: μ .

$$Q = \begin{pmatrix} -\lambda & \lambda \\ \mu & -\mu \end{pmatrix}.$$



CMTC de 2 estados: tasas λ y μ

6.4 · Ecuaciones de Kolmogorov

Teorema 6.2 · Ecuaciones de Kolmogorov (progresiva y regresiva)

Sea $\mathbf{P}(t) = (p_{ij}(t))$ la matriz de probabilidades de transición. Bajo condiciones de regularidad:

$$\mathbf{P}'(t) = \mathbf{P}(t) \mathbf{Q} \quad (\text{ecuación progresiva de Kolmogorov}) \quad (6.1)$$

$$\mathbf{P}'(t) = \mathbf{Q} \mathbf{P}(t) \quad (\text{ecuación regresiva de Kolmogorov}) \quad (6.2)$$

con condición inicial $\mathbf{P}(0) = \mathbf{I}$. La solución formal es la **exponencial matricial**:

$$\mathbf{P}(t) = e^{t\mathbf{Q}} = \sum_{k=0}^{\infty} \frac{(t\mathbf{Q})^k}{k!}.$$

Ejemplo 6.2 · Solución explícita para 2 estados

Con la $\mathbf{Q}$ -matrix anterior ($\lambda, \mu > 0$), los autovalores de $\mathbf{Q}$ son 0 y $-(\lambda + \mu)$. La solución es:

$$\mathbf{P}(t) = \frac{1}{\lambda + \mu} \begin{pmatrix} \mu + \lambda e^{-(\lambda + \mu)t} & \lambda(1 - e^{-(\lambda + \mu)t}) \\ \mu(1 - e^{-(\lambda + \mu)t}) & \lambda + \mu e^{-(\lambda + \mu)t} \end{pmatrix}.$$

Cuando $t \rightarrow \infty$: $\mathbf{P}(t) \rightarrow \frac{1}{\lambda + \mu} \begin{pmatrix} \mu & \lambda \\ \mu & \lambda \end{pmatrix}$, que es la distribución estacionaria $\pi_0 = \mu/(\lambda + \mu)$, $\pi_1 = \lambda/(\lambda + \mu)$.

6.5 · Distribución estacionaria de una CMTC

Definición 6.3 · Distribución estacionaria (tiempo continuo)

Un vector $\boldsymbol{\pi}$ es distribución estacionaria de una CMTC si:

$$\boldsymbol{\pi} \mathbf{Q} = \mathbf{0}, \quad \sum_{j \in S} \pi_j = 1, \quad \pi_j \geq 0.$$

En forma escalar: $\sum_{i \neq j} \pi_i q_{ij} = \pi_j q_j$ para todo j (flujo de entrada = flujo de salida en cada estado).

El balance detallado en tiempo continuo es $\pi_i q_{ij} = \pi_j q_{ji}$. Si se satisface, $\boldsymbol{\pi}$ es estacionaria y la cadena es reversible.

6.6 · Cadena embebida

Definición 6.4 · Cadena de saltos (cadena embebida)

Dada una CMTC $\{X(t)\}$, la **cadena de saltos** (o *cadena embebida*) es el proceso $\{Y_n\}_{n \geq 0}$ que registra *solo el estado* en el momento del n -ésimo salto, sin tomar en cuenta el tiempo transcurrido.

La cadena de saltos es una CMTD con probabilidades de transición:

$$\hat{p}_{ij} = \frac{q_{ij}}{q_i} \quad (i \neq j), \quad \hat{p}_{ii} = 0.$$

Así, una CMTC puede describirse como: tiempos de espera $\text{Exp}(q_i)$ en cada estado i , seguidos de saltos según $\hat{p}_{ij}$.

△ Atención

La distribución estacionaria $\boldsymbol{\pi}$ de la CMTC y la de la cadena embebida $\hat{\boldsymbol{\pi}}$ *no coinciden* en general. La distribución estacionaria de la CMTC pondera además el tiempo de permanencia en cada estado: $\pi_i \propto \hat{\pi}_i / q_i$.

Sección 7: Proceso de Nacimiento y Muerte

7.1 · Definición


Definición 7.1 · Proceso de nacimiento y muerte

Un proceso de nacimiento y muerte es una CMTC con espacio de estados $\mathcal{S} = \{0, 1, 2, \dots\}$ (finito o infinito numerable) donde solo se permiten saltos de un estado al inmediatamente adyacente:

- **Tasa de nacimiento:** $\lambda_i = q_{i,i+1} \geq 0$ (salto de i a $i+1$).
- **Tasa de muerte:** $\mu_i = q_{i,i-1} \geq 0$ (salto de i a $i-1$), con $\mu_0 = 0$.
- $q_i = \lambda_i + \mu_i$ (tasa total de salida del estado i).

La Q-matrix tiene la estructura tridiagonal:

$$Q = \begin{pmatrix} -\lambda_0 & \lambda_0 & 0 & 0 & \dots \\ \mu_1 & -(\lambda_1 + \mu_1) & \lambda_1 & 0 & \dots \\ 0 & \mu_2 & -(\lambda_2 + \mu_2) & \lambda_2 & \dots \\ \vdots & \vdots & \vdots & \ddots & \ddots \end{pmatrix}.$$



Proceso de nacimiento y muerte: solo saltos al estado adyacente

7.2 · Balance detallado y distribución estacionaria

Teorema 7.1 · Distribución estacionaria del proceso de nacimiento y muerte

En un proceso de nacimiento y muerte, el balance detallado simplifica a:

$$\pi_i \lambda_i = \pi_{i+1} \mu_{i+1}, \quad i = 0, 1, 2, \dots$$

(flujo entre estados i e $i+1$ se equilibra en ambas direcciones). Iterando la recursión desde $i = 0$:

$$\pi_n = \pi_0 \prod_{k=0}^{n-1} \frac{\lambda_k}{\mu_{k+1}}, \quad n \geq 1.$$

La constante π_0 se determina por normalización: $\pi_0 = \left(1 + \sum_{n=1}^{\infty} \prod_{k=0}^{n-1} \frac{\lambda_k}{\mu_{k+1}}\right)^{-1}$. La distribución estacionaria existe si y solo si la suma converge.

Demostración

Las ecuaciones de balance global para el estado j son $\lambda_{j-1}\pi_{j-1} + \mu_{j+1}\pi_{j+1} = (\lambda_j + \mu_j)\pi_j$. En un proceso de nacimiento y muerte, se puede verificar que el balance detallado $\pi_i\lambda_i = \pi_{i+1}\mu_{i+1}$ es una solución (por inducción en i). Despejando: $\pi_{i+1} = (\lambda_i/\mu_{i+1})\pi_i$, y aplicando recursivamente se obtiene la fórmula producto. $\square$

7.3 · Proceso de nacimiento puro: conexión con Poisson

Proposición 7.2 · Proceso de Poisson como nacimiento puro

Si $\mu_i = 0$ para todo i (no hay muertes) y $\lambda_i = \lambda$ constante (tasa de nacimiento homogénea), el proceso de nacimiento y muerte se reduce al **Proceso de Poisson** con intensidad λ .

En este caso no existe distribución estacionaria (el proceso crece indefinidamente): $\sum_{n=0}^{\infty} (\lambda/0)^n$ diverge.

Las probabilidades $p_n(t) = \mathbb{P}(X(t) = n \mid X(0) = 0)$ satisfacen las ecuaciones de Kolmogorov: $p'_n(t) = -\lambda p_n(t) + \lambda p_{n-1}(t)$, con solución $p_n(t) = e^{-\lambda t} (\lambda t)^n / n!$ (distribución Poisson).

7.4 · Cola M/M/1

Definición 7.2 · Cola M/M/1

Una **cola M/M/1** modela un sistema de espera con:

- Llegadas: proceso de Poisson con tasa λ (interarribos $\text{Exp}(\lambda)$).
- Servicio: tiempo de servicio $\text{Exp}(\mu)$.
- Un solo servidor, capacidad ilimitada, disciplina FIFO.

El número de clientes $X(t)$ es un proceso de nacimiento y muerte con $\lambda_i = \lambda$ y $\mu_i = \mu$ para $i \geq 1$, $\mu_0 = 0$.

El **factor de carga** es $\rho = \lambda/\mu$.

Teorema 7.3 · Distribución estacionaria de M/M/1

La cola M/M/1 tiene distribución estacionaria si y solo si $\rho < 1$ (la tasa de llegadas es menor que la de servicio). Cuando se cumple:

$$\pi_n = (1 - \rho) \rho^n, \quad n = 0, 1, 2, \dots$$

Distribución geométrica con parámetro $1 - \rho$. Las medidas de rendimiento son:

$$\mathbb{E}[L] = \frac{\rho}{1 - \rho} \quad (\text{número medio en el sistema})$$

$$\mathbb{E}[L_q] = \frac{\rho^2}{1 - \rho} \quad (\text{número medio en cola})$$

$$\mathbb{E}[W] = \frac{1}{\mu - \lambda} \quad (\text{tiempo medio en el sistema})$$

$$\mathbb{E}[W_q] = \frac{\rho}{\mu - \lambda} \quad (\text{tiempo medio en cola})$$

donde se han usado las **leyes de Little**: $\mathbb{E}[L] = \lambda \mathbb{E}[W]$ y $\mathbb{E}[L_q] = \lambda \mathbb{E}[W_q]$.

Demostración

Aplicando la fórmula del proceso de nacimiento y muerte con $\lambda_i = \lambda$, $\mu_i = \mu$:

$$\pi_n = \pi_0 \prod_{k=0}^{n-1} \frac{\lambda}{\mu} = \pi_0 \rho^n.$$

Normalizando: $\pi_0 \sum_{n=0}^{\infty} \rho^n = 1 \Rightarrow \pi_0 = 1 - \rho$ (requiere $\rho < 1$).

El número medio: $\mathbb{E}[L] = \sum_{n=0}^{\infty} n(1 - \rho)\rho^n = (1 - \rho) \cdot \frac{\rho}{(1 - \rho)^2} = \frac{\rho}{1 - \rho}$. □

Ejemplo 7.1 · Cola de un cajero automático

Clientes llegan a un ATM según un Proceso de Poisson con $\lambda = 4$ clientes/hora. El tiempo de servicio es $\text{Exp}(\mu = 6)$ clientes/hora. Factor de carga: $\rho = 4/6 = 2/3 < 1$.

- Probabilidad de que el ATM esté vacío: $\pi_0 = 1 - 2/3 = 1/3 \approx 33\%$.
- Número medio de clientes en el sistema: $\mathbb{E}[L] = (2/3)/(1/3) = 2$.
- Tiempo medio total en el sistema: $\mathbb{E}[W] = 1/(6 - 4) = 0.5$ horas = 30 min.
- Tiempo medio esperando en cola: $\mathbb{E}[W_q] = (2/3)/(6 - 4) = 1/3$ hora = 20 min.

△ Atención

Si $\rho \geq 1$ la cola *no tiene régimen estacionario*: la línea de espera crece indefinidamente y el sistema se satura. La condición $\rho < 1$ es indispensable para que exista distribución estacionaria.

Leyes de Little (intuitivas): En un sistema estable con tasa de entrada λ :

- $\mathbb{E}[L] = \lambda \mathbb{E}[W]$: el número promedio en el sistema es la tasa de llegadas por el tiempo promedio que cada cliente pasa en el sistema.
- $\mathbb{E}[L_q] = \lambda \mathbb{E}[W_q]$: análogamente para la cola.

Las leyes de Little son universales: no dependen de la distribución de llegadas ni de servicio, solo de la estabilidad del sistema.

Conexiones clave del módulo

- Proceso de Poisson $\Rightarrow$ CMTC de nacimiento puro con $\lambda_i = \lambda$ constante
- Balance detallado $\pi_i q_{ij} = \pi_j q_{ji} \Rightarrow$ reversibilidad $\Rightarrow \pi$ fácil de calcular
- Proceso de nacimiento y muerte: $\pi_n = \pi_0 \prod_{k=0}^{n-1} (\lambda_k / \mu_{k+1})$
- CMTC $\leftrightarrow$ cadena embebida (saltos) + tiempos de espera $\text{Exp}(q_i)$
- Recurrencia $\Leftrightarrow \sum_n p_{ii}^{(n)} = \infty$ (criterio de recurrencia)
- Teorema ergódico: $p_{ij}^{(n)} \rightarrow \pi_j$ para cadena ergódica finita
- $\pi_j = 1/\mu_j$ (la distribución estacionaria es el recíproco del tiempo medio de retorno)
- Cola M/M/1 estable $\Leftrightarrow \rho = \lambda/\mu < 1$, con $\pi_n = (1 - \rho)\rho^n$