

Modelos Estocásticos - Cátedra profesor Dr.
Franco Basso

Gonzalo Rios

July 2023

Contents

1	Probabilidades	4
1.1	Conceptos Generales	4
1.2	Funciones	4
1.3	Medidas	5
1.4	Probabilidad Condicional	7
1.4.1	Propiedad de Bayes	7
1.4.2	Probabilidades Totales	8
1.4.3	Trabajo dirigido	8
2	Variable Aleatoria	9
2.1	Función de Distribución	9
2.1.1	Variable Aleatoria Continua	10
2.1.2	Variable Aleatoria Discreta	10
2.2	Función de Masa	10
2.3	Distribución de Bernoulli	11
2.4	Distribución Binomial	12
2.4.1	Aplicación Binomio de Newton	12
2.5	Distribución Geométrica	12
2.5.1	Aplicación Suma y Serie Geométrica	12
2.6	Distribución de Poisson	13
2.6.1	Aplicación Expansión de Taylor de Exponencial	13
2.7	Función de Probabilidad	13
2.8	Distribución Uniforme	13
2.8.1	Notación Indicatriz	13
2.8.2	Calculo de Función Distribución	14
2.9	Distribución Exponencial	15
2.9.1	Propiedad de Pérdida de Memoria	16
2.9.2	Competencia de Tasas	16
3	Teorema de Probabilidades Totales - Continuo	16
4	Esperanza y Varianza	16
4.1	Esperanza Discreta	16
4.2	Esperanza Continua	17
4.3	Varianza	17
4.3.1	Propiedades de la Esperanza y Varianza	17
4.4	Teorema Esperanza y Varianza	18
5	Vectores Aleatorios	18
5.1	Función de distribución conjunta	18
5.2	Función de distribución marginal	18
5.3	Función de Densidad Conjunta	18
5.4	Densidades Marginales	19
5.5	Función Conjunta de Masa	19

5.6	Función de Masa Marginal	20
5.6.1	Ejemplo Discreto	20
5.7	Variables Aleatorias Independientes	20
5.8	Densidad Condicional	20
5.9	Función de Masa Condicional	21
5.10	Esperanza Condicional	21
5.11	Probabilidades Totales para Esperanzas Condicionales	21
6	Procesos de Poisson	22
6.1	Proceso de Conteo	22
6.2	Incrementos Independientes	22
6.3	Incrementos Estacionarios	22
6.4	Proceso de Poisson Homogeneo	23
6.4.1	Ejemplo Proceso Poisson	23
6.5	Tiempos entre Eventos	23
6.6	Distribución de los Tiempos	23
6.7	Superposición de Procesos de Poisson	24
6.8	Procesos Bifurcados	25
6.9	Ejemplo Proceso Bifurcado	26
6.10	Recapitulación Procesos de Poisson	26
6.10.1	Continuación ejemplo	27
7	Cadenas de Markov a Tiempo Discreto	27
7.1	Transición en n etapas	29
7.2	Teorema de Chapman - Kolmogorov	30
7.3	Clasificación de Estados	30
7.4	Comunicación de Estados	30
7.4.1	Ejemplo Comunicación	31
7.5	Clases de Estados	32
7.5.1	Ejemplo Clases de Estados	32
7.6	Probabilidad de estado por primera vez en n pasos	33
7.7	Probabilidad de retorno por primera vez en n pasos	33
7.8	Probabilidad de retorno	33
7.8.1	Ejemplo probabilidad de retorno	34
7.9	Recurrencia y Transiencia	35
7.9.1	Visitas a un estado	35
7.9.2	Teorema de Caracterización de la Recurrencia	35
7.9.3	Recurrencia como propiedad de Clase	36
7.10	Periodo de un Estado	37
7.10.1	Ejemplo aplicación periodo de un estado	37
7.11	Tiempo esperado de retorno	38
7.12	Recurrencia Nula y Positiva	39
7.12.1	Propiedades de Recurrencia	39
7.12.2	Propiedad Cantidad Finita de Estados	39
7.13	Propiedades Limites	40
7.14	Probabilidades Estacionarias	40

7.14.1	Interpretación de las probabilidades estacionarias	40
8	Cadenas de Markov a Tiempo Continuo	41
8.1	Tiempos de Permanencia	41
8.2	Distribución Tiempos de Permanencia	41
8.3	Tasas de Transición	42
8.4	Ejemplo Notable - Procesos de Nacimiento - Muerto	42
8.5	Probabilidades de Transición Continuas	43
8.6	Teorema Chapman - Kolmogorov continuo	43
8.7	Ecuaciones Backward / Forward Kolmogorov	44
9	Sistemas de Espera	45
9.1	Sistema M/M/1	46
9.2	Teorema - ecuaciones de Little	48
9.2.1	Aplicación Little a Sistema M/M/1	49
9.3	Sistema M/M/S	49
9.3.1	Proceso Nacimiento - Muerto	50

1 Probabilidades

1.1 Conceptos Generales

Espacio Muestral: Se define un espacio muestral al conjunto de todos los resultados posibles de un experimento, se simboliza con Ω , ejemplo:

- Lanzar una moneda, $\Omega = \{Cara; Sello\} = \{C; S\}$
- Lanzamiento de un dado, $\Omega = \{1, 2, 3, 4, 5, 6\}$

Conjunto Potencia: Se define al conjunto potencia de Ω , $P(\Omega)$ como el conjunto cuyos elementos son todos los subconjuntos de Ω , formalmente esto es,

$$P(\Omega) = \{A : A \subseteq \Omega\} \rightarrow \forall x \in A, x \in \Omega$$

- Si $\Omega = \{C; S\}$, entonces $P(\Omega) = \{\{C\}; \{S\}; \{C; S\}; \{\emptyset\}\}$

Cardinalidad: Se define como cardinalidad a la cantidad de elementos en un conjunto.

$$|\Omega| = \#\Omega$$

- Para el caso anterior, $|\Omega| = 2$, $|P(\Omega)| = 4$.

En general se tiene $|P(\Omega)| = 2^{|\Omega|}$.

1.2 Funciones

La función izquierda de la Figura 1.2 es biyectiva ya que sus elementos tienen una relación 1 a 1 entre los conjuntos X e Y , la función de la derecha de la Figura 1.2 no es biyectiva ya que los elementos 2 y 5 de X tienen la misma llegada en el conjunto final Y . En general, si hay biyección existe la misma cardinalidad entre los elementos de los conjuntos.




Figure 1: Ejemplo funciones

Por ejemplo consideremos el conjunto formado por los números naturales incluyendo el 0 y el conjunto de los números enteros, y tomemos la siguiente tabla de elementos como ejemplo.

...	-3	-2	-1	0	1	2	3	...
...	6	4	2	0	1	3	5	...

Del ejemplo anterior notamos que podemos encontrar una función que asocie a ambos conjuntos mediante lo siguiente,

$$f(n) = \begin{cases} 0 & \text{if } n = 0 \\ -2n & \text{if } n < 0 \\ 2n - 1 & \text{if } n > 0 \end{cases}$$

Por lo anterior $f(n)$ es biyectiva, existiendo una relación 1 a 1 entre los conjuntos de números naturales y números enteros, ergo, tienen misma cantidad de elementos.

1.3 Medidas

Sigma - Álgebra: Se define una sigma-algebra (σ -álgebra), como una colección de eventos. Sea Ω un espacio muestral, diremos que $\mathcal{F}$ es una σ -álgebra sobre Ω ssi:

- $\emptyset, \Omega \in \mathcal{F}$.
- $\forall A \in \mathcal{F} \rightarrow A^c \in \mathcal{F}$.
- Sea $(A_n)_{n \in \mathbb{N}} : A_n \in \mathcal{F} \quad \forall n \in \mathbb{N}$, entonces $\cup_{n \in \mathbb{N}} A_n \in \mathcal{F}$

Es fácil ver que el $P(\Omega)$ y $\{\emptyset, \Omega\}$ son σ -álgebras, dado que, por ejemplo, el segundo cumple con la propiedad de contener a $\emptyset$, y además su complemento Ω está en el conjunto, finalmente la unión de elementos sigue estando en el conjunto.

Medida de probabilidad: Sea Ω un espacio muestral y $\mathcal{F} : \sigma$ -álgebra, definimos $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$.

- $P(\emptyset) = 0$.
- $P(\Omega) = 1$.
- Sean $(A_n)_{n \in \mathbb{N}} \subseteq \mathcal{F}$ familia disjunta de eventos $(A_{i,j}) \in \mathbb{N}, i \neq j$ $A_i \cap A_j = \emptyset$.

Con lo anterior,

$$\mathbb{P}\left(\bigcup_{n \in \mathbb{N}} A_n\right) = \sum_{n \in \mathbb{N}} \mathbb{P}(A_n)$$

Al triplete $(\Omega, \mathcal{F}, \mathbb{P})$ se le conoce como espacio de probabilidad, algunas propiedades de este triplete son las siguientes. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio muestral (e.p.), entonces,

$$\forall A \in \mathcal{F} : \mathbb{P}(A^c) = 1 - \mathbb{P}(A)$$

Demostración: Sea $A \in \mathcal{F}$, consideremos la familia disjunta $\{A, A^c\}$, por definición anterior tenemos que,

$$P(A \cup A^c) = P(A) + P(A^c)$$

$$P(A \cup A^c) = P(\Omega) = 1$$

$$1 = P(A) + P(A^c)$$

$$P(A^c) = 1 - P(A)$$

Se define $A \setminus B$ como $A \cap B^c$, que corresponde a todos los elementos de A que no están en B . Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad,

$$P(A \setminus B) = P(A) - P(A \cap B)$$

Demostración: Sea $A, B \in \mathcal{F}$. consideremos la familia $A \setminus B$ y $A \cap B$,

$$\{A \setminus B; A \cap B\}$$

$$(A \setminus B) \cap (A \cap B) = A \cap B^c \cap A \cap B = A \cap (B \cap B^c) = \emptyset$$

Luego, por la anterior familia disjunta, tenemos

$$P(A \setminus B \cup A \cap B) = P(A \setminus B) + P(A \cap B)$$

$$A \setminus B \cup A \cap B = A \cap B^c \cup A \cap B = A \cap (B^c \cup B) = A \cap \Omega = A$$

$$P(A) = P(A \setminus B) + P(A \cap B)$$

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio muestral, entonces se cumple que,

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Lo anterior se puede generalizar para más de dos conjuntos, entregando el principio de inclusión / exclusión.

$$\begin{aligned} P(A_1 \cup \dots \cup A_n) = & \sum_{i=1}^n P(A_i) + \sum_{i,j=1, i < j}^n P(A_i \cap A_j) + \sum_{i,j,k=1, i < j < k}^n P(A_i \cap A_j \cap A_k) + \dots \\ & + (-1)^{n+1} P\left(\bigcap_{i=1}^n A_i\right) \end{aligned}$$

1.4 Probabilidad Condicional

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, para $A, B \in \mathcal{F}$ tal que $P(B) > 0$, definimos la probabilidad condicional de la siguiente forma,

$$P(A/B) = \frac{P(A \cap B)}{P(B)}$$

Eventos independientes: Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, y sean $A, B \in \mathcal{F}$ diremos que A y B son independientes, esto es $A \perp B$ ssi:

$$P(A \cap B) = P(A)P(B)$$

Si $A \perp B$, entonces,

$$P(A/B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B)}{P(B)} = P(A)$$

Lo anterior se conoce como evento multiplicativo.

1.4.1 Propiedad de Bayes

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, y sean $A, B \in \mathcal{F}/P(A), P(B) > 0$

$$P(A/B) = P(B/A) \frac{P(A)}{P(B)}$$

Demostración: Sean $A, B \in \mathcal{F}$, tal que $P(A), P(B) > 0$, entonces se tiene que,

$$P(B/A) \frac{P(A)}{P(B)} = \frac{P(A \cap B)}{P(B)} \frac{P(A)}{P(B)} = \frac{P(A \cap B)}{P(B)} = P(A/B)$$

1.4.2 Probabilidades Totales

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad tal que permite infinitas particiones numerables, sea $(A_k)_{k \in \mathbb{N}} \subseteq \mathcal{F}$ una partición del universo, tal que $A_i \cap A_j \neq \emptyset, \forall i, j \in \mathbb{N}, i \neq j, \cup_{k \in \mathbb{N}} A_k = \Omega$, entonces,

$$\forall B \in \mathcal{F}, P(B) = \sum_{k \in \mathbb{N}} P(B/A_k)P(A_k)$$

Demostración: Consideremos la siguiente familia disjunta

$$\begin{aligned} \{B \cap A_k\}_{k \in \mathbb{N}} &= \{B \cap A_i \cap B \cap A_j\} = \{B \cap B \cap A_i \cap A_j\} = \emptyset \\ P\left(\bigcup_{k \in \mathbb{N}} (B \cap A_k)\right) &= \sum_{k \in \mathbb{N}} P(B \cap A_k) \end{aligned}$$

Por Teorema de Bayes tenemos que,

$$\begin{aligned} P(B/A_k) &= \frac{P(B \cap A_k)}{P(A_k)} \\ \bigcup_{k \in \mathbb{N}} (B \cap A_k) &= B \cap \left(\bigcup_{k \in \mathbb{N}} A_k\right) = B \cap \Omega = B \\ P(B) &= \sum_{k \in \mathbb{N}} P(B/A_k)P(A_k) \end{aligned}$$

1.4.3 Trabajo dirigido

Considere que un equipo de fútbol juega con la táctica 4-4-2, se sabe que la probabilidad que un defensa se lesione durante un partido es $1/8$, un medio-campo $1/5$ y un delantero $1/4$, el arquero no se lesiona, cuál es la probabilidad que un jugador se lesione.

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad tal que,

$$\begin{aligned} \Omega &= \{(a; 0); (a; 1); (m; 0); (m; 1); (d; 0); (d; 1); (del; 0); (del; 1)\} \\ \mathcal{F} &= P(\Omega) \end{aligned}$$

Sea $L =$ 'El jugador se lesiona', definido como $(A_k; 1), A_k \in \{a, d, m, del\}$, por ejemplo, $A_1 =$ el jugador es arquero $= \{(a; 0); (a; 1)\}$

$$P(\text{Jugador}) = \sum_{k \in A_k} P(\text{Jugador}/\text{Jugador}_k)P(\text{Jugador}_k)$$

$$P(\text{Jugador}) = \frac{4}{11} \frac{1}{8} + \frac{4}{11} \frac{1}{5} + \frac{2}{11} \frac{1}{4} + \frac{1}{11} 0 \approx 0.164$$

Ahora consideremos calcular la probabilidad que el jugador lesionado sea delantero.

$$P(\text{Delantero}/\text{Jugador}) = P(\text{Jugador}/\text{Delantero}) \frac{P(\text{Delantero})}{P(\text{Jugador})}$$

$$P(\text{Delantero/Jugador}) = \frac{1}{4} \frac{2/11}{0.164}$$

2 Variable Aleatoria

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, diremos que $X : \Omega \rightarrow \mathbb{R}$ es una variable aleatoria, si $A_x = \{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F}, \forall x \in \mathbb{R}$. Esta definición nos indica que $A_x \in \mathcal{F}, \forall x \in \mathbb{R}$, es decir, podemos calcular una probabilidad a A_x , esto es, existe $P(A_x)$. Por convención anotamos simplemente,

$$\{\omega \in \Omega : X(\omega) \leq x\} = \{X \leq x\}$$

2.1 Función de Distribución

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, y X una variable aleatoria, definimos la Función de Distribución (Acumulada) de la siguiente forma,

$$F_X : \mathbb{R} \rightarrow [0, 1]$$

$$x \rightarrow P(A_x) = P(X \leq x)$$

Propiedades

- $\lim_{x \rightarrow -\infty} F_X(x) = 0$
- $\lim_{x \rightarrow +\infty} F_X(x) = 1$
- F_X es una función no decreciente (puede ser constante o crecer, pero jamás decrecer).
- F_X es una función continua por la derecha, es decir que $\exists \lim_{h \rightarrow 0^+} F_X(x + h) = F_X(x), \forall x \in \mathbb{R}$
- $P(X = x) = F_X(x) - \lim_{t \rightarrow x^-} F_X(t) = 0$

Para F_X continua se tiene que $P(X = x) = 0, \forall x \in \mathbb{R}$, a los puntos donde $P(X = x) = 0$ se les denomina átomos. En la Figura 2.1 se aprecia la continuidad por la derecha para la función dada, con puntos de discontinuidad en los puntos A y C donde salta a los puntos B y D respectivamente.




Figure 2: Función a trozos continua por la derecha

2.1.1 Variable Aleatoria Continua

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y sea X una variable aleatoria, diremos que X es absolutamente continua si F_X es una función continua.

2.1.2 Variable Aleatoria Discreta

Si F_X es constante por trozos, diremos que X es discreta.

2.2 Función de Masa

Sea X una variable aleatoria discreta, entonces X tiene función de distribución constante por trozos, los puntos con saltos son átomos de la función o puntos de discontinuidad, dichos puntos se denominan como I , además se cumple que,

$$\sum_{k \in I} P(X = k) = 1$$

Con esto podemos definir la función de masa como

$$\begin{aligned} p_x : I &\rightarrow [0, 1] \\ k &\rightarrow p_x(k) = P(X = k) \end{aligned}$$

Por tanto se debe cumplir que,

$$\sum_{k \in I} P(X = k) = 1$$

Al conjunto I se le llama soporte de la variable aleatoria,

$$I_X = \text{Sop}(X)$$

La Función de Masa cumple la siguiente relación,

$$F_X(x) = P(X \leq x) = \sum_{k \in I, k \leq x} p_X(k)$$




Figure 3: Función de Masa

2.3 Distribución de Bernoulli

Distribución de Bernoulli modela un evento de éxito o fracaso, el soporte de dicha variable es $I = \{0, 1\}$, y se cumple lo siguiente,

$$p_X(k) = \begin{cases} p & \text{si } k = 1 \\ 1 - p & \text{si } k = 0 \\ 0 & \sim \end{cases}$$

Formalmente decimos $X \sim \text{Bernoulli}(p), p \in [0, 1]$

2.4 Distribución Binomial

Distribución Binomial modela la cantidad de éxitos en una cantidad dada de experimentos, formalmente decimos que $X \sim \text{Binomial}(n, p)$, con $n \in \mathbb{N}$ y $p \in [0, 1]$, además $I_X = \{0, 1, 2, \dots, \mathbb{N}\}$

$$p_X(k) = \binom{n}{k} p^k (1-p)^{n-k}, \forall k \in I_X$$

2.4.1 Aplicación Binomio de Newton

Sean $a, b \in \mathbb{R}, n \in \mathbb{N}$, entonces

$$(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}$$

Con lo anterior podemos escribir

$$\sum_{k \in I_X} p_X(k) = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = (p + (1-p))^{n-k} = 1^{n-k} = 1$$

2.5 Distribución Geométrica

Distribución Geométrica modela los intentos hasta que ocurre un éxito en el k -ésimo experimento, formalmente decimos $X \sim \text{geo}(p)$, con soporte en $I_X = \{1, 2, 3, \dots\} = \mathbb{N}$.

$$p_X(k) = (1-p)^{k-1} p$$

2.5.1 Aplicación Suma y Serie Geométrica

Sea $r \in \mathbb{R}$, tal que $r \in (-1, 1)$, entonces se cumple que,

$$\sum_{k=0}^n r^k = \frac{1-r^{n+1}}{1-r}$$
$$\sum_{k=0}^n r^k = \begin{cases} \frac{1}{1-r} & \text{si } r \in (-1, 1) \\ \infty & \sim \end{cases}$$

Con esto podemos aplicar lo siguiente

$$\sum_{k \in I} p_X(k) = \sum_{k=1}^{+\infty} (1-p)^{k-1} p = p \sum_{k=0}^{+\infty} (1-p)^k = p \sum_{k=0}^{+\infty} r^k = p \frac{1}{1-(r)} = \frac{p}{1-(1-p)} = \frac{p}{p} = 1$$

2.6 Distribución de Poisson

Distribución que modela un determinado número de eventos durante un periodo de tiempo, decimos que $X \sim \text{Poisson}(\lambda)$ con $\lambda > 0$, donde λ representa una tasa de ocurrencias por unidad temporal, luego $I = \{0, 1, 2, \dots\} = \mathbb{N}^*$.

$$p_X(k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

2.6.1 Aplicación Expansión de Taylor de Exponencial

$$e^x = \sum_{k=0}^{+\infty} \frac{x^k}{k!}$$
$$\sum_{k \in I} p_X(k) = \sum_{k=0}^{+\infty} \frac{e^{-\lambda} \lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{+\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1$$

2.7 Función de Probabilidad

Sea X una variable aleatoria absolutamente continua, es decir, que su F_X es continua, entonces tenemos que

$$\exists f_X : \mathbb{R} \rightarrow \mathbb{R}_+ : F_X(x) = \int_{-\infty}^{+\infty} f_X(t) dt$$
$$\frac{\partial F_X(x)}{\partial x} = f_X(x)$$

Se observa que como $\lim_{x \rightarrow +\infty} F_X(x) = 1$, entonces

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1$$

2.8 Distribución Uniforme

Sea $X \sim \text{Uniforme}(a, b)$, entonces,

$$f_X(x) = \begin{cases} \frac{1}{b-a} & \text{si } x \in [a, b] \\ 0 & \sim \end{cases}$$

2.8.1 Notación Indicatriz

$$\mathbb{1}_A(x) = \begin{cases} 1 & \text{si } x \in A \\ 0 & \sim \end{cases}$$
$$f_X(x) = \frac{1}{b-a} \mathbb{1}_A(x)$$

2.8.2 Cálculo de Función Distribución

Para el cálculo de la función de distribución tomaremos casos de la función de probabilidad, si $x < a$, entonces $F_X = 0$, luego, si $x \in [a, b]$, entonces

$$F_X(x) = \int_{-\infty}^x f_X(t)dt = \int_{-\infty}^a f_X(t)dt + \int_a^x f_X(t)dt$$

$$F_X(x) = \int_a^x \frac{1}{b-a}dt = \frac{1}{b-a}t \Big|_a^x = \frac{x-a}{b-a}$$

Si $x > b$, entonces la función queda de la siguiente forma,

$$\int_{-\infty}^x f_X(t)dt = 1$$

Lo anterior se esclarece al ver la forma de la función de probabilidad de la Figura 4 y la función de distribución de la Figura 5.




Figure 4: Función de Probabilidad distribución Uniforme




Figure 5: Función de Distribución - caso uniforme

2.9 Distribución Exponencial

La distribución exponencial modela tiempos de ocurrencia entre eventos, siendo un caso particular de la distribución Gamma, decimos $X \sim \exp(\lambda)$, con $\lambda > 0$.

$$f_X(x) = \lambda e^{-\lambda x} \mathbb{1}_{[0,+\infty)}(x)$$




Figure 6: Función de Probabilidad - caso exponencial

Para verificar que la función de densidad está bien definida tomamos,

$$\begin{aligned} \int_{-\infty}^{+\infty} f_X(x) dx &= \int_{-\infty}^{+\infty} \lambda e^{-\lambda x} \mathbb{1}_{[0,+\infty)}(x) dx = \int_0^{+\infty} \lambda e^{-\lambda x} dx \\ &= \lambda \frac{e^{-\lambda x}}{-\lambda} \Big|_0^{+\infty} = 1 \end{aligned}$$

Luego, se puede calcular,

$$F_X(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - e^{-\lambda x} & \text{si } x \geq 0 \end{cases}$$

2.9.1 Propiedad de Pérdida de Memoria

Una propiedad interesante de la distribución exponencial es la pérdida de memoria o muerte sin envejecimiento, para esto tomemos lo siguiente, sea $X \sim \exp(\lambda)$, con $\lambda > 0$, sean $s, t > 0$.

$$P(X > t + s / X > t) = P(X > s)$$

Para demostrar lo anterior tomemos lo siguiente,

$$\begin{aligned}\bar{F}_X(x) &= 1 - F_X(x) = e^{-\lambda x} \rightarrow P(X > x) = e^{-\lambda x} \\ P(X > t + s / X > t) &= \frac{P(X > t + s; X > t)}{P(X > t)} = \frac{P(X > t + s)}{P(X > t)} \\ &= \frac{\bar{F}_X(t + s)}{\bar{F}_X(t)} = \frac{e^{-\lambda(t+s)}}{e^{-\lambda t}} = e^{-\lambda s} = \bar{F}_X(s) = P(X > s) \\ P(X > t + s / X > t) &= P(X > s)\end{aligned}$$

2.9.2 Competencia de Tasas

Sean $X_1 \sim \exp(\lambda_1)$ y $X_2 \sim \exp(\lambda_2)$, con $X_1 \perp\!\!\!\perp X_2$, entonces se cumple que

$$P(X_1 \leq X_2) = \frac{\lambda_1}{\lambda_1 + \lambda_2}$$

3 Teorema de Probabilidades Totales - Continuo

Las variables aleatorias continuas no tienen átomos en su dominio, a diferencia de las variables discretas. Sean $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y X una variable aleatoria absolutamente continua, consideremos $B \in \mathcal{F}$.

$$P(B) = \int_{-\infty}^{+\infty} P(B/X = x) f_X(x) dx$$

4 Esperanza y Varianza

4.1 Esperanza Discreta

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad, y sea X una variable aleatoria discreta con soporte en un conjunto I , definimos la esperanza de X como,

$$E[X] = \sum_{k \in I} k p_X(k)$$

Como ejemplo de lo anterior tomemos la distribución de Poisson, sea $X \sim \text{Poisson}(\lambda)$, con $\lambda > 0$.

$$\begin{aligned}
E[X] &= \sum_{k \in I} k p_X(k) = \sum_{k=0}^{+\infty} k \frac{e^{-\lambda} \lambda^k}{k!} = \sum_{k=1}^{+\infty} k \frac{e^{-\lambda} \lambda^k}{k!} = \sum_{k=1}^{+\infty} \frac{e^{-\lambda} \lambda^k}{(k-1)!} \\
&= e^{-\lambda} \sum_{k=0}^{+\infty} \frac{\lambda^{k+1}}{k!} = e^{-\lambda} \lambda \sum_{k=0}^{+\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \lambda e^{\lambda} = \lambda
\end{aligned}$$

4.2 Esperanza Continua

Si X es una variable aleatoria absolutamente continua, entonces tomamos lo siguiente,

$$E[X] = \int_{-\infty}^{+\infty} x f_X(x) dx$$

Como ejemplo tomemos la distribución uniforme, sea $X \sim U(a, b)$, con $a, b > 0$, entonces,

$$\begin{aligned}
E[X] &= \int_{-\infty}^{+\infty} x f_X(x) dx = \int_{-\infty}^{+\infty} x \frac{1}{b-a} \mathbb{1}_{[a,b]}(x) dx \\
&= \int_a^b x \frac{1}{b-a} dx = \frac{1}{b-a} \frac{x^2}{2} \Big|_a^b = \frac{1}{2(b-a)} (b^2 - a^2) = \frac{a+b}{2}
\end{aligned}$$

4.3 Varianza

La varianza se utiliza como un concepto de dispersión de una distribución de una variable aleatoria. Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y sea X una variable aleatoria, definimos,

$$V(X) = E[(X - E[X])^2]$$

4.3.1 Propiedades de la Esperanza y Varianza

Sean X, Y variables aleatorias, y sea $\alpha \in \mathbb{R}$.

- $E[\alpha X + Y] = \alpha E[X] + E[Y]$
- $E[\alpha] = \alpha$
- $V[X] = E[X^2] - (E[X])^2$
- $V[\alpha X] = \alpha^2 V[X]$
- Si $X \perp Y$, entonces $V[X+Y] = V[X] + V[Y]$, además $E[XY] = E[X]E[Y]$

4.4 Teorema Esperanza y Varianza

$$E[g(x)] = \begin{cases} \sum_{k \in I} g(k)P_X(k) & \text{si } X \text{ es una variable aleatoria discreta} \\ \int_{-\infty}^{+\infty} g(x)f(x)dx & \text{si } X \text{ es una variable aleatoria continua} \end{cases}$$

5 Vectores Aleatorios

El estudio de vectores aleatorios busca entender como una cantidad finita de variables aleatorias interactúan entre si. Para el caso $n = 2$ diremos que el vector (X, Y) es un vector aleatorio si X e Y son vectores aleatorios. Con lo anterior podemos recibir información respecto a la interacción, así como también a las marginales.

5.1 Función de distribución conjunta

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad tal que el vector (X, Y) es aleatorio, se define,

$$F_{X,Y}(x, y) = P(X \leq x; Y \leq y) \\ \mathbb{R}^2 \rightarrow [0, 1]$$

5.2 Función de distribución marginal

Se define la distribución marginal de variables aleatorias en un vector aleatorio de la siguiente forma,

$$F_X(x) = \lim_{y \rightarrow +\infty} F_{X,Y}(x, y)$$

$$F_Y(y) = \lim_{x \rightarrow +\infty} F_{X,Y}(x, y)$$

Con lo anterior al hacer la variable $x_i \rightarrow +\infty$ hacemos que siempre se cumpla $X_i \leq x_i$, por lo que queda $(X_j \leq x_j) \cap \Omega = (X_j \leq x_j)$, con $j \neq i$.

5.3 Función de Densidad Conjunta

Sean X, Y variables aleatorias absolutamente continuas, definimos,

$$\int_{X,Y} \mathbb{R}^2 \rightarrow \mathbb{R}_+$$

Que es densidad conjunta del vector (X, Y) ssi:

$$F_{X,Y}(x, y) = \int_{-\infty}^y \int_{-\infty}^x f_{X,Y}(s, t) ds dt$$

Más aún,

$$P((X, Y) \in A) = \int \int_A f_{X,Y}(x, y) dx dy \quad \text{con } A \subseteq \mathbb{R}^2$$

Observamos además que,

$$\lim_{x, y \rightarrow +\infty} F_{X,Y}(x, y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx dy = 1$$

$$f_{X,Y}(x, y) = \frac{\partial}{\partial x} \left(\frac{\partial F_{X,Y}}{\partial y} \right)$$

5.4 Densidades Marginales

Sean (X, Y) variables aleatorias absolutamente continuas, definimos las funciones de densidad marginales de la forma,

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx$$

5.5 Función Conjunta de Masa

Sean X, Y variables aleatorias discretas, definimos:

$$P_{X,Y}(n, k) = P(X = n, Y = k)$$

$$I_X \times I_Y \rightarrow [0, 1]$$

Así,

$$F_{X,Y}(x, y) = P(X \leq x; Y \leq y) = \sum_{k \in I_Y} \sum_{n \in I_X} P_{X,Y}(n, k), \quad \forall k \leq y, n \leq x$$

Cumpliendo que,

$$\sum_{k \in I_Y} \sum_{n \in I_X} P_{X,Y}(n, k) = 1, \quad \forall k \leq y, n \leq x$$

5.6 Función de Masa Marginal

Sean X, Y un vector aleatorio discreto, definimos,

$$P_X(k) = \sum_{n \in I_Y} P_{X,Y}(n, k)$$
$$P_Y(n) = \sum_{k \in I_X} P_{X,Y}(n, k)$$

5.6.1 Ejemplo Discreto

Sean X, Y variables aleatorias tal que su función de masa conjunta viene dado por la siguiente tabla,

$P_{X,Y}(n, k)$	0	1
1	1/8	1/8
2	1/4	1/4
3	0	1/4

De la tabla anterior extraemos que $I_X = \{1, 2, 3\}$ e $I_Y = \{0, 1\}$, luego podemos calcular:

$$P(X \leq 1, Y \leq 2) = 1/8 + 1/8 = 1/4$$

$$P(X \leq 2, Y = 0) = 1/8 + 1/4$$

$$P_X(n) = P_X(1) + P_X(2) + P_X(3) = 1/4 + 1/2 + 1/4 = 1$$

$$P_Y(k) = P_Y(0) + P_Y(1) = 3/8 + 5/8 = 1$$

5.7 Variables Aleatorias Independientes

Sea (X, Y) un vector aleatorio, diremos que $X \perp\!\!\!\perp Y$ ssi:

$$P_{X,Y}(n, k) = P_X(n)P_Y(k), \quad \forall n \in I_X, \forall k \in I_Y$$

$$f_{X,Y}(x, y) = f_X(x)f_Y(y), \quad \forall x \in \mathbb{R}, \forall y \in \mathbb{R}$$

5.8 Densidad Condicional

Sean X, Y variables aleatorias absolutamente continuas, definimos la densidad condicional de la forma,

$$f_{X/Y}(x, y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

$$\mathbb{R}^2 \rightarrow \mathbb{R}^+$$

Analogamente,

$$f_{Y/X}(x, y) = \frac{f_{X,Y}(x, y)}{f_X(x)}$$

5.9 Función de Masa Condicional

Sean X, Y variables aleatorias discretas, se define la función de masa condicional de la forma,

$$P_{X/Y}(n, k) = \frac{P_{X,Y}(n, k)}{P_Y(k)}$$

$$P_{Y/X}(n, k) = \frac{P_{X,Y}(n, k)}{P_X(n)}$$

5.10 Esperanza Condicional

Sean X, Y variables aleatorias definimos las esperanzas condicionales de la siguiente forma,

$$E[X/Y] = \int_{-\infty}^{+\infty} x f_{X/Y}(x, y) dx$$

$$E[Y/X] = \int_{-\infty}^{+\infty} y f_{Y/X}(x, y) dy$$

El caso discreto queda de la siguiente forma

$$E[X/Y] = \sum_{n \in I_X} n P_{X/Y}(n, k)$$

$$E[Y/X] = \sum_{n \in I_X} k P_{Y/X}(n, k)$$

5.11 Probabilidades Totales para Esperanzas Condicionales

$$E[X] = \sum_{k \in I_Y} E[X/Y] P(Y = k)$$

$$E[X] = \int_{-\infty}^{+\infty} E[X/Y = y] f_Y(y) dy$$

Podemos notar que $E[X/Y]$ depende de Y , por tanto $E[X/Y]$ es una variable aleatoria.

$$E[E[X/Y]] = E[X]$$

$$\begin{aligned}
E[g(y)] &= \int_{-\infty}^{+\infty} g(y) f_Y(y) dy = \int_{-\infty}^{+\infty} \left[\int_{-\infty}^{+\infty} x f_{X/Y}(x, y) dx \right] f_Y(y) dy \\
&= \int_{-\infty}^{+\infty} \left[x \frac{f_{X,Y}(x, y)}{f_Y(y)} dx \right] f_Y(y) dy = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f_{X,Y}(x, y) dx dy \\
&= \int_{-\infty}^{+\infty} x f_{X,Y}(x, y) dy dx = \int_{-\infty}^{+\infty} x \left[\int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy \right] dx \\
&= \int_{-\infty}^{+\infty} x f_X(x) dx = E[X]
\end{aligned}$$

6 Procesos de Poisson

Un proceso estocásticos es una sucesión de variables aleatorias indexadas por un conjunto fijo. $(X_\alpha)_{\alpha \in A}$ donde para cada $\alpha \in A$, X_α es una variable aleatoria. Usualmente se tiene $A = \mathbb{N}$ si es tiempo discreto con X_α , y $A = \mathbb{R}^+$ si es tiempo continuo con $X(\alpha)$. Al escribir $\{X_\alpha\}$ nos referimos al proceso completo, si fuera X_α nos referimos a un X particular con α fijo.

6.1 Proceso de Conteo

Diremos que el proceso $\{N(t) : t \geq 0\}$ es de conteo, ssi:

- $\forall t \geq 0$, soporte($N(t)$) = $\mathbb{N}^*$
- $N(0) = 0$
- $\forall t \geq 0$, tal que $s \leq t$, entonces $N(s) \leq N(t)$

6.2 Incrementos Independientes

Consideremos $t_1, t_2, t_3, t_4 \geq 0$, tal que $t_1 \leq t_2 \leq t_3 \leq t_4$, los incrementos entre t_1 y t_2 son independientes de los incrementos entre t_3 y t_4 , entonces $N(t_2) - N(t_1) \perp N(t_4) - N(t_3)$. Lo importante es verificar que los incrementos son disjuntos e independientes.

6.3 Incrementos Estacionarios

Sea $\{N(t) : t \geq 0\}$ un proceso de conteo, diremos que el proceso completo tiene incrementos estacionarios si se cumple que $\forall t, s \geq 0$, la distribución de $N(t+s) - N(t)$ no depende de t , esto es,

$$N(t+s) - N(t) \sim N(s)$$

Con lo anterior decimos que la distribución no depende del inicio del intervalo sino del largo de este.

6.4 Proceso de Poisson Homogeneo

Sea $\mathcal{N} = \{N(t) : t \geq 0\}$ un proceso de conteo, diremos que $\mathcal{N}$ es un proceso de Poisson ssi:

- $\mathcal{N}$ tiene incrementos independientes.
- $\mathcal{N}$ tiene incrementos estacionarios.
- $\forall t \geq 0, N(t) \sim \text{Poisson}(\lambda t), \lambda \geq 0$ con λ parámetro fijo del proceso.

En lo anterior λ se interpreta como la cantidad de eventos que ocurren en un tiempo fijo t , con esto λ es la tasa de eventos medido en unidad de tiempo.

$$E[N(t)] = \lambda t$$

6.4.1 Ejemplo Proceso Poisson

Suponga que se busca modelar la cantidad de vehículos que pasan por una intersección. Estudios han mostrado que, en promedio, pasan 10 vehículos por hora, utilizando proceso de Poisson, determine la probabilidad que en las dos primeras horas pasen más de 25 autos.

$$E[N(t)] = \lambda t = 10 \rightarrow E[N(2t)] = 2\lambda = 20 \text{ vehículos / hora}$$

$$P(N(t) > 25) = 1 - P(N(t) \leq 25) = 1 - \sum_{k=0}^{25} \frac{20^k e^{-20}}{k!}$$

6.5 Tiempos entre Eventos

Consideremos un proceso de Poisson $\{N(t) : t \geq 0\}$ con tasa $\lambda > 0$, llamaremos T_i el tiempo que transcurre entre el evento $i - 1$ y el evento i .

$$S_n = \sum_{i=1}^n T_i, \forall n \geq 1$$

6.6 Distribución de los Tiempos

Para T_1 tenemos que encontrar una fórmula considerando

$$F_{T_1}(t) = P(T_1 \leq t)$$

Sin embargo, en este caso es más fácil estudiar

$$F_{T_1} = P(T_1 > t)$$

Notemos que $T_1 > t \longleftrightarrow N(t) = 0$, así, si $T_1 > t$ es equivalente a decir que han ocurrido cero eventos, así,

$$F_{T_1}(t) = P(N(t) = 0) = \frac{e^{-\lambda t}(\lambda t)^0}{0!} = e^{-\lambda t}$$

$$F_{T_1}(t) = 1 - e^{-\lambda t}$$

Por tanto, $T_1 \sim \exp(\lambda)$, generalizando lo anterior obtenemos que

$$\begin{aligned} P(T_i > t) &= P(N(S_{i-1} + t) - N(S_{i-1}) = 0) \\ &= \int_{-\infty}^{+\infty} P(N(S_{i-1} + t) - N(S_{i-1})) = 0 / S_{i-1} = s) f_{S_{i-1}}(s) ds \\ &= \int_{-\infty}^{+\infty} P(N(s + t) - N(s) = 0) f_{S_{i-1}}(s) ds \\ &= \int_{-\infty}^{+\infty} P(N(t) = 0) f_{S_{i-1}}(s) ds = e^{-\lambda t} \int_{-\infty}^{+\infty} f_{S_{i-1}}(s) ds = e^{-\lambda t} \end{aligned}$$

Por tanto, $T_i \sim \exp(\lambda)$, en lo que sigue las variables aleatorias $T_i \sim \exp(\lambda)$ y son independientes entre si, esto es, $T_i \perp T_j, \forall i \neq j$

6.7 Superposición de Procesos de Poisson

Sean $\{N_1(t) : t \geq 0\}$ y $\{N_2(t) : t \geq 0\}$, procesos de Poisson independientes con tasas $\lambda_1, \lambda_2 > 0$, definimos,

$$N(t) = N_1(t) + N_2(t)$$

Entonces $N(t)$ es proceso de Poisson con tasa $\lambda_1 + \lambda_2$. Para demostrar lo anterior consideremos $N_1(t)$ y $N_2(t)$ con soportes en los naturales, por tanto la suma de naturales queda en el conjunto de los naturales, además se cumple que:

- $N(0) = 0$, al ser $N_1(0)$ y $N_2(0)$ tenemos $0 + 0$, por tanto $N(0) = 0$.
- $\forall t \geq 0 / s \leq t \rightarrow N(s) \leq N(t)$, decimos que es un proceso creciente.

Sea $t, s \geq 0$,

$$\begin{aligned} N(s + t) - N(s) &= (N_1(s + t) + N_2(s + t)) - (N_1(s) + N_2(s)) \\ N_1(s + t) - N_1(s) &\sim \text{Poisson}(\lambda_1 t) \\ N_2(s + t) - N_2(s) &\sim \text{Poisson}(\lambda_2 t) \end{aligned}$$

Sabemos que la suma de variables aleatorias Poisson independientes es Poisson, por tanto la suma distribuye Poisson($(\lambda_1 + \lambda_2)t$), así se cumple que,

- $\{N(t) : t \geq 0\}$ tiene incrementos estacionarios.
- $N(t) \sim \text{Poisson}((\lambda_1 + \lambda_2)t)$

El resultado anterior es directamente generalizable para la suma de n procesos de Poisson independientes.

6.8 Procesos Bifurcados

Consideremos $\{N(t) : t > 0\}$ proceso de Poisson con tasa $\lambda > 0$. Supongamos que cada evento de este proceso se dirá de tipo 1 con probabilidad $p \in [0, 1]$ y tipo 2 con probabilidad $1-p$. Definamos $N_1(t)$ y $N_2(t)$ procesos que cuentan los eventos tipo 1 y tipo 2 hasta el tiempo t , respectivamente. Entonces $N_1(t)$ y $N_2(t)$ son procesos de Poisson independientes con tasas λp y $\lambda(1-p)$, respectivamente. Para demostrar esto demostraremos que $N_1(s+t) - N_1(t) \sim \text{Poisson}(\lambda ps)$, $\forall s, t \geq 0$

$$\text{Poisson}(\lambda ps) = \frac{e^{-\lambda ps} (\lambda ps)^k}{k!}$$

Tomando $k \in \mathbb{N}^*$

$$P(N_1(s+t) - N_1(t) = k) = \sum_{n=0}^{+\infty} P(N_1(s+t) - N_1(t) = k / N(s+t) - N(t) = n) \times$$

$$P(N(s+t) - N(t) = n), n \geq k$$

$$\sum_{n=k}^{+\infty} P(N_1(s+t) - N_1(t) = k / N(s+t) - N(t) = n) P(N(s+t) - N(t) = n)$$

$$\sum_{n=k}^{+\infty} \binom{n}{k} p^k (1-p)^{n-k} e^{-\lambda s} \frac{(\lambda s)^n}{n!}$$

$$\sum_{n=k}^{+\infty} \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} e^{-\lambda s} \frac{(\lambda s)^n}{n!}$$

$$\sum_{n=0}^{+\infty} \frac{(n+k)!}{k!(n!)} p^k (1-p)^n e^{-\lambda s} \frac{(\lambda s)^{n+k}}{(n+k)!} = \frac{p^k}{k!} e^{-\lambda s} \sum_{n=0}^{+\infty} \frac{(1-p)^n (\lambda s)^{n+k}}{n!}$$

$$= \frac{p^k e^{-\lambda s}}{k!} (\lambda s)^k \sum_{n=0}^{+\infty} \frac{(\lambda s(1-p))^{n+k}}{n!} = \frac{p^k e^{-\lambda s}}{k!} (\lambda s)^k e^{-\lambda s(1-p)}$$

$$P(N_1(s+t) - N_1(t) = k) = \frac{(\lambda ps)^k e^{-\lambda ps}}{k!}$$

6.9 Ejemplo Proceso Bifurcado

Personas llegan a un bar según proceso de Poisson de tasa 20 personas por hora. El guardia deja entrar al azar solo al 60% de las personas. Si el bar abre a las 9 pm.

- ¿Cuál es la probabilidad que las 10 pm no haya entrado nadie?
Sabemos que $X \sim \exp(\lambda)$, por tanto $F_X(t) = 1 - e^{-\lambda t}$

$$P(N_1(1) = 0) = e^{-12} \frac{12^0}{0!} = e^{-12}$$

- ¿Cuál es la probabilidad que la primera persona haya entrado antes de las 9:10 pm?

$$P(T_1 \leq 1/6) = F_{T_1}(1/6) = 1 - e^{-12(1/6)}$$

- ¿Si hasta las 11 pm han echado a 30 personas, ¿Cuál es la probabilidad que a esa misma hora hayan más personas dentro que afuera?

$$P(N_1(2) > N_2(2)/N_2(2) = 30) = P(N_1(2) > 30/N_2(2) = 30)$$

$$= P(N_1(2) > 30) = \sum_{k=31}^{+\infty} P(N_1(2) = k) = \sum_{k=31}^{+\infty} e^{-24} \frac{24^k}{k!}$$

6.10 Recapitulación Procesos de Poisson

Sea $\{N(t) : t > 0\}$ un proceso de Poisson tal que es proceso de conteo, tiene incrementos estacionarios e independientes y además $N(t) \sim \text{Poisson}(\lambda t)$. Si $T_i \sim \exp(\lambda)$ independientes, entonces $S_n \sim \text{gamma}(n, \lambda)$, con soporte $I_{S_n} = \mathbb{R}_+$

$$f_{S_n}(t) = \lambda e^{-\lambda t} \frac{(\lambda t)^{n-1}}{(n-1)!} \mathbb{1}_{[0, +\infty)}(t)$$

Supongamos que sabemos que hasta un cierto instante t ha ocurrido exactamente un evento, ¿Cuál es la distribución del tiempo en el que ocurrió dicho evento?

$$\text{sop}(T_1/N(t) = 1) = [0, t]$$

$$F_{T_1/N(t)=1}(s) = P(T_1 \leq s/N(t) = 1) = \frac{P(T_1 \leq s, N(t) = 1)}{P(N(t) = 1)}$$

$$F_{T_1/N(t)=1}(s) = 0, s < 0$$

$$F_{T_1/N(t)=1}(s) = \frac{P(T_1 \leq t, N(t) = 1)}{P(N(t) = 1)} = \frac{P(N(t) = 1)}{P(N(t) = 1)} = 1, s > t$$

Si $T_1 \leq s$, entre 0 y s ha ocurrido 1 evento, y entre s y t han ocurrido cero eventos, con esto,

$$\begin{aligned}
 F_{T_1/N(t)=1} &= \frac{P(N(s) \geq 1, N(t) = 1)}{P(N(t) = 1)} = \frac{P(N(s) = 1, N(t) = 1)}{P(N(t) = 1)} \\
 &= \frac{P(N(s) = 1)P(N(t) - N(s) = 0)}{P(N(t) = 1)} = \frac{P(N(s) = 1)P(N(t-s) - N(0) = 0)}{P(N(t) = 1)} \\
 &= \frac{\frac{e^{-\lambda s} \lambda s}{1!} \frac{e^{-\lambda(t-s)} (\lambda(t-s))^0}{0!}}{\frac{e^{-\lambda t} (\lambda t)^1}{1!}} = \frac{s}{t}
 \end{aligned}$$

Con lo anterior tenemos que $T_1/N(t) = 1 \sim U(0, t)$

6.10.1 Continuación ejemplo

Si sabemos que a la primera persona que echaron fue a las 9:15 hrs, ¿Cuál es la probabilidad que a esa persona la hayan echado entre las 9:06 hrs y las 9:08 hrs?

$$P(T_1/N(1/4) = 1) \sim U(0, 1/4) = \frac{1/30}{1/4} = \frac{4}{30} = \frac{2}{15}$$

7 Cadenas de Markov a Tiempo Discreto

Consideremos un proceso estocásticos que llamaremos $\{X_n : n = 0, 1, 2, \dots\}$, tal que $\forall n \in \mathbb{N}^* : \text{sop}(X_n) = I$ que se llamará conjunto de estados. Diremos que el proceso estocásticos es una Cadena de Markov a Tiempo Discreto (CDMD) ssi:

- **Homogeneidad (Estacionariedad):** La probabilidad $P(X_{n+1} = j/X_n = i)$ no depende de n , sino únicamente del estado actual o inicial i y el estado siguiente j , con esto podemos definir las probabilidades de transición.

$$P_{i,j} = P(X_{n+1} = j/X_n = i) = P(X_1 = j/X_0 = i), \forall n \in \mathbb{N}^*$$

- **Markovienidad (Pérdida de Memoria):** Solo importa el estado o dato más reciente que tenga el sistema.

$$\begin{aligned}
 P(X_{n+1} = j/X_n = i, X_{n-1} = i_{n-1}, \dots, X_1 = i_1, X_0 = i_0) &= \\
 &= P(X_{n+1} = j/X_n = i), \quad \forall n \in \mathbb{N}^*, \forall i, j \in I
 \end{aligned}$$

Para cierta etapa $n \in \mathbb{N}^*$, $X_n = i, \forall i \in I$ diremos que el sistema está en el estado i en el tiempo n .

Por ejemplo supongamos que un puerto puede estar abierto o cerrado dependiendo del clima. Se sabe que si un día el puerto está abierto, lo estará también mañana con probabilidad α . Además, si el puerto está cerrado, mañana estará cerrado con probabilidad β . Modelo la situación del puerto como una CDMD.

- Sea X_n el estado del puerto el día n .
- Sea $I = 0, 1$ el estado del puerto con cerrado (0) y abierto (1).
- $P_{00} = \beta$, $P_{01} = 1 - \beta$, $P_{10} = 1 - \alpha$, $P_{11} = \alpha$.

La representación gráfica del problema se presenta en la Figura 7, con los estados y las probabilidades de transición.




Figure 7: Cadena de Markov problema puerto

Es posible notar que la suma de las flechas que salen de cada nodo da 1, esto es una propiedad que ha de cumplirse para las CDMD, formalmente esto es,

$$\sum_{j \in I} P_{ij} = 1, \forall i \in I$$

Además, las probabilidades de transición suelen guardarse en una matriz que llamaremos matriz de transición donde,

$$P = (P_{ij})_{ij \in I} \in M_{|I| \times |I|}$$

La matriz del ejemplo anterior es la siguiente

$$P = \begin{pmatrix} \beta & 1-\beta \\ 1-\alpha & \alpha \end{pmatrix}$$

7.1 Transición en n etapas

Sea $\{X_n : n \geq 0\}$ una Cadena de Markov a Tiempo Discreto, definimos las probabilidades de transición en n etapas mediante,

$$P_{ij}^n = P(X_n = j / X_0 = i), \forall i, j \in I, \forall n \in \mathbb{N}^*$$

Por ejemplo considere la cadena de Markov Discreta de la Figura 8, para la cual calcule P_{14}^4




Figure 8: Ejemplo propuesto Cadena de Markov Discreta

$$P_{14}^4 = 1 - 2 - 3 - 4 - 5 = 0.3 \times 0.4 \times 1 \times 0.6$$

$$P_{14}^4 = 1 - 2 - 4 - 4 - 4 = 0.3 \times 0.1 \times 1 \times 1$$

$$P_{14}^4 = 1 - 2 - 1 - 2 - 4 = 0.3 \times 0.5 \times 0.3 \times 0.1$$

$$P_{14}^4 = 1 - 3 - 5 - 4 - 4 = 0.7 \times 1 \times 0.6 \times 1$$

$$P_{14}^4 = 0.5265$$

Hay que considerar que los eventos son disjuntos (cada paso es distinto a otro tomado).

$$P(X_4 = 5 / X_2 = 2, X_1 = 1)$$

En lo anterior se pide calcular la probabilidad que el sistema se encuentre en el estado 5 en el tiempo 4, dado que estuvo en el estado 2 en el tiempo 2 y en el estado 1 en el tiempo 1, aplicando la propiedad de markoveneidad podemos escribir,

$$P(X_4 = 5 / X_2 = 2) = P(X_2 = 5 / X_0 = 2) = P_{25}^2 = 0.4 \times 1$$

7.2 Teorema de Chapman - Kolmogorov

Consideremos una CDMD, entonces se cumple que, $\forall i, j \in I, \forall n, m \in \mathbb{N}^*$

$$P_{ij}^{n+m} = \sum_{k \in I} P_{ik}^n P_{kj}^m$$

Para demostrar lo anterior podemos condicionar con respecto a $\{X_n = k\}_{k \in I}$

$$\begin{aligned} P_{ij}^{n+m} &= P(X_{n+m} = j / X_0 = i) \\ &= \sum_{k \in I} P(X_{n+m} = j / X_n = k, X_0 = i) P(X_n = k / X_0 = i) \\ &= \sum_{k \in I} P(X_{n+m} = j / X_n = k) P_{ik}^n = \sum_{k \in I} P(X_m = j / X_0 = k) P_{ik}^n \\ &= \sum_{k \in I} P_{ik}^n P_{kj}^m \end{aligned}$$

7.3 Clasificación de Estados

Definimos la alcanzabilidad de estados, diciendo que $j \in I$ es alcanzable desde $i \in I$ ssi:

$$\exists n \in \mathbb{N}^* : P_{ij}^n > 0$$

Anotamos $i \rightarrow j$ si j es alcanzable desde i , con esto podemos definir la comunicación entre estados, diciendo que i comunica con j ssi:

$$i \rightarrow j \wedge j \rightarrow i$$

Anotamos lo anterior de la forma $i \longleftrightarrow j$, agregando como observación que la cantidad de pasos para la ida de un estado ($i \rightarrow j$) no tiene por qué coincidir con la cantidad de pasos de vuelta ($j \rightarrow i$)

7.4 Comunicación de Estados

Sean $i, j, k \in I$, definimos la propiedad de comunicación entre estados de la siguiente manera,

- $i \longleftrightarrow i$

Basta tomar $n = 0$ y por convenciencia utilizar

$$P_{ii}^0 = 1 > 0$$

- $i \longleftrightarrow j \iff j \longleftarrow i$

$$\begin{aligned}
i \longleftrightarrow j &\iff i \rightarrow j \wedge j \rightarrow i \\
&\iff j \rightarrow i \wedge i \rightarrow j \\
&\iff j \longleftrightarrow i
\end{aligned}$$

- $i \longleftrightarrow j \wedge j \longleftrightarrow k \Rightarrow i \longleftrightarrow k$

Supongamos que $i \longleftrightarrow j \wedge j \longleftrightarrow k$, demostremos que $i \rightarrow k$ utilizando por hipótesis lo siguiente

$$\begin{aligned}
i \rightarrow j &\iff \exists n \in \mathbb{N}^* : P_{ij}^n > 0 \\
j \rightarrow k &\iff \exists m \in \mathbb{N}^* : P_{jk}^m > 0
\end{aligned}$$

Utilizado Ch-K

$$P_{ik}^{n+m} = \sum_{\alpha \in I} P_{i\alpha}^n P_{\alpha k}^m \geq P_{ij}^n P_{jk}^m > 0$$

Se exhibe $n + m$ como los pasos en que $P_{ik}^{n+m} > 0$, el caso $k \rightarrow i$ es análogo.

7.4.1 Ejemplo Comunicación

Considere la CDMD de la Figura 9 a continuación, considere las proposiciones a continuación.




Figure 9: Ejemplo propuesto Comunicación de Estados

- $1 \longleftrightarrow 1 \implies V$

- $1 \longrightarrow 5 \implies V$
- $2 \longleftrightarrow 6 \implies F$
- $5 \longleftrightarrow 3 \implies F$
- $6 \longrightarrow 2 \implies F$
- $3 \longrightarrow 4 \implies V$
- $4 \longleftrightarrow 1 \implies F$

7.5 Clases de Estados

Sea una CDMD, entonces es posible particionar el conjunto de estados I en una familia $\{\mathcal{C}_k\}$ con $k \in \mathbb{N}$, tal que $\forall k \in \mathbb{N}, \forall i, j \in \mathcal{C}_k$, se cumple que $i \longleftrightarrow j$, de esta forma encontramos que,

- Elementos comunican entre si

$$\forall k \in \mathbb{N}, \forall i, j \in \mathcal{C}_k, i \longleftrightarrow j$$

- Clases disjuntas de comunicación

$$\forall k, k' \in \mathbb{N} : k \neq k', \forall i \in \mathcal{C}_k, j \in \mathcal{C}_{k'}, i \nleftrightarrow j$$

Los conjuntos $\mathcal{C}_k$ se llaman clases de comunicación, cumpliendo las siguientes propiedades.

- Unión de clases es todo el conjunto,

$$\cup_{k \in I} \mathcal{C}_k = I$$

- Son disjuntos

$$\cap_{k \in I} \mathcal{C}_k = \emptyset$$

7.5.1 Ejemplo Clases de Estados

Considere la siguiente CDMD de la Figura 10, determine las clases de comunicación del sistema.




Figure 10: Ejemplo Clases de Comunicación

$$\mathcal{C}_1 = \{1, 2, 4, 5\}$$

$$\mathcal{C}_2 = \{3, 6\}$$

7.6 Probabilidad de estado por primera vez en n pasos

Consideremos una CDMD y $i, j \in I, n \in \mathbb{N}^*$, definimos la probabilidad f_{ij}^n tal que comenzando en i el sistema esté en j por primera vez en n pasos, formalmente esto es,

$$f_{ij}^n = P(X_n = j, X_{n-1} \neq j, \dots, X_1 \neq j / X_0 = i)$$

Cabe mencionar que $f_{ij}^n \leq P_{ij}^n$.

7.7 Probabilidad de retorno por primera vez en n pasos

Definimos la probabilidad de retorno al estado por primera vez en una cantidad $n \in \mathbb{N}$ de pasos de la siguiente forma.

$$f_i^n = f_{ii}^n, \quad \forall i \in I, \forall n \in \mathbb{N}^*$$

7.8 Probabilidad de retorno

Definimos la probabilidad de retorno de un estado i al mismo estado i de la siguiente forma.

$$f_i = \sum_{n=1}^{+\infty} f_i^n$$

Esto se cumple ya que los eventos f_i son disjuntos.

7.8.1 Ejemplo probabilidad de retorno

Considere la CDMD mostrada en la Figura 11 a continuación, determine f_1 .




Figure 11: Ejemplo Probabilidades de Retorno

$$f_1 = f_1^{(1)} + f_1^{(2)} + f_1^{(3)} + \dots + f_1^{(n)}$$

$$f_1 = 0 + (0.6 \times 0.1) + (0.6 \times 0.2 \times 0.1) + \dots + f_1^{(n)} = 0.6 \times (0.2)^{n-2} \times 0.1$$

$$f_1 = \sum_{n=1}^{+\infty} f_1^{(n)} = \sum_{n=2}^{+\infty} 0.6 \times 0.2^{n-2} \times 0.1$$

$$f_1 = 0.06 \sum_{n=2}^{+\infty} 0.2^{n-2} = 0.06 \sum_{n=0}^{+\infty} 0.2^n$$

$$f_1 = 0.06 \frac{1}{1 - 0.2} = \frac{0.06}{0.8} = 0.075$$

7.9 Recurrencia y Transiencia

Dada una CDMD y un estado $i \in I$. Diremos que i es recurrente ssi:

$$f_i = 1$$

Por el contrario, $f_i < 1$ diremos que el estado es transiente. Por ejemplo en la cadena de la Figura 11 el estado 1 cumplía que $f_1 = 0.075 < 1$, por tanto ese estado (1) es transiente.

7.9.1 Visitas a un estado

Llamemos V_i a la variable aleatoria que cuenta el número de visitas al estado i , es claro que $\text{Soporte}(V_i) = \mathbb{N}^*$. Suponiendo que la cadena empieza en i , si i es recurrente (vuelvo siempre con certeza igual a 1), tenemos que,

$$V_i = +\infty \rightarrow P(V_i = +\infty) = 1$$

Si i fuese transiente, entonces se cumple que,

$$P(V_i = +\infty) = \lim_{n \rightarrow +\infty} f_i^n = 0$$

Definiendo como éxito la fuga del estado i (salgo y jamás regreso a i), y considerando la propiedad de pérdida de memoria, la cantidad de visitas corresponde al primer éxito en repeticiones de eventos tipo éxito-fracaso (fugarse o no).

$$V_i \sim \text{geo}(1 - f_i)$$

Para el ejemplo de la Figura 11, ¿Cuántas veces se visita en promedio el estado $i = 1$?

$$E[V_1] = \frac{1}{1 - f_1} = \frac{1}{1 - 0.075} \approx 1.081$$

$$V_1 \sim \text{geo}(1 - 0.075) \rightarrow V_1 \sim \text{geo}(p = 0.925)$$

7.9.2 Teorema de Caracterización de la Recurrencia

Consideremos una CDMD, entonces i es recurrente ssi:

$$\sum_{n=1}^{+\infty} P_{ii}^n \quad \text{diverge}$$

Para demostrar lo anterior notemos que:

$$E[V_i / X_0 = i] = \begin{cases} +\infty & \text{si } i \text{ es recurrente} \\ \frac{1}{1-f_i} & \text{si } i \text{ es transiente} \end{cases}$$

Por otra parte calculemos,

$$\begin{aligned}
E[V_i/X_0 = i] &= E\left[\sum_{n=0}^{+\infty} \mathbb{1}_{X_n=i}/X_0 = i\right] = \sum_{n=0}^{+\infty} E[\mathbb{1}_{X_n=i}/X_0 = i] \\
&= \sum_{n=0}^{+\infty} P(X_n = i/X_0 = i) = \sum_{n=0}^{+\infty} P_{ii}^n
\end{aligned}$$

La sumatoria anterior parte en 0 y la que vimos al inicio de la sección 7.9.2 parte en 1, esto no afecta la convergencia o divergencia de la caracterización, dado que,

$$\begin{aligned}
P_{ii}^0 &= 1 \\
\sum_{n=0}^{+\infty} P_{ii}^n &= 1 + \sum_{n=1}^{+\infty} P_{ii}^n
\end{aligned}$$

7.9.3 Recurrencia como propiedad de Clase

La recurrencia es una propiedad de clase, es decir, dentro de una clase de comunicación una de las siguientes aseveraciones se cumple,

- Todos los estados son recurrentes.
- Todos los estados son transientes.

Dicho de otro modo, dentro de una clase no pueden haber al mismo tiempo estados recurrentes y transientes. Para demostrar lo anterior sean $i, j \in I$ estados tal que i es recurrente e $i \longleftrightarrow j$, por demostrar que j es recurrente. Por hipótesis sabemos que $i \longleftrightarrow j$, es decir que,

$$\exists k, m \in \mathbb{N}^* / P_{ij}^k > 0, P_{ji}^m > 0$$

Sea $n \in \mathbb{N}$, entonces, por Ch-K dos veces se tiene que,

$$P_{jj}^{m+n+k} = \sum_{h \in I} \sum_{h' \in I} P_{jh}^m P_{hh'}^n P_{h'j}^k \geq P_{ji}^m P_{ii}^n P_{ij}^k$$

Sumando a ambos lados de la serie-inecuación,

$$\sum_{n=1}^{+\infty} P_{jj}^{m+n+k} \geq \sum_{n=1}^{+\infty} P_{ji}^m P_{ii}^n P_{ij}^k \geq P_{ji}^m P_{ij}^k \sum_{n=1}^{+\infty} P_{ii}^n$$

En lo anterior $\sum_{n=1}^{+\infty} P_{ii}^n = +\infty$ ya que i es recurrente y dado el teorema de caracterización de la recurrencia obtenemos,

$$\sum_{n=1}^{+\infty} P_{jj}^{m+n+k} \quad \text{diverge} \longrightarrow \sum_{n=1}^{+\infty} P_{jj}^n \quad \text{diverge}$$

7.10 Período de un Estado

Definimos el período de un estado $i \in I$ de la forma,

$$d_i = \text{mcd}\{n \in \mathbb{N} : P_{ii}^n > 0\}, d_i \in \mathbb{N}$$

En lo anterior mcd es el máximo común divisor del conjunto, osea, el entero más grande que divide a la serie de números.

- Si $d_i > 1$ diremos que el estado i es periódico con período d_i .
- Si $d_i = 1$ diremos que el estado i es aperiódico.

7.10.1 Ejemplo aplicación período de un estado

Considere la CDMD de la Figura 7.10.1 a continuación, obtenga d_1, d_4, d_5 y d_6 .




Figure 12: Ejemplo Período de un Estado

$$d_1 = \text{mcd}\{3, 6, 9, \dots\} = 3$$

$$d_4 = \text{mcd}\{3, 6, 9, \dots\} = 3$$

$$d_5 = \text{mcd}\{1, 2, 3, \dots\} = 1$$

Si incluye el 1 significa que siempre puedo volver,

$$d_6 = \text{mcd}\{2, 3, 4, \dots\} = 1$$

Obteniendo las clases de la cadena anterior se hacen más evidentes los periodos de cada estado, así encontramos,

$$\mathcal{C}_1 = \{1, 2, 3, 4\}$$

$$\mathcal{C}_2 = \{5, 6\}$$

Notar que los estados $\{1, 2, 3, 4\}$ tienen periodos iguales de 3, mientras que los estados $\{5, 6\}$ tienen periodos de 1, dado que el periodo es una propiedad de clase.

7.11 Tiempo esperado de retorno

Dado un estado $i \in I$ definimos el número de transiciones promedio para retornar a i de la forma,

$$\mathcal{T}_i = \sum_{n=1}^n n f_i^n$$




Figure 13: Ejemplo Tiempo Esperado de Retorno

Consideremos la CDMD de la Figura 7.11, calculemos $\mathcal{T}_1$.

$$f_1^1 = \frac{1}{2}$$

$$f_1^2 = 1 \times \frac{1}{4} = \frac{1}{4}$$

$$f_1^3 = 1 \times \frac{1}{2} \times 1 = \frac{1}{4}$$

$$f_1^4 = 0$$

...

$$f_1^n = 0, \forall n \geq 4$$

$$\mathcal{T}_1 = \sum_{n=1}^4 f_1^n = 1 \times \frac{1}{2} + 2 \times \frac{1}{4} + 3 \times \frac{1}{4} = \frac{7}{4}$$

Consideremos el ejemplo de la Figura 7.11 a continuación, obtengamos $\mathcal{T}_1$ de forma similar al ejemplo anterior.




Figure 14: Ejemplo 2 Tiempo Esperado de Retorno

$$\mathcal{T}_1 = \frac{1}{2}$$

$$f_1^2 = \frac{1}{2} \times \frac{3}{4} = \frac{3}{8}$$

Lo anterior presenta una debilidad al no considerar estados recurrentes y transientes, considerando que si es transiente puedo irme y volver en una cantidad infinita de pasos. Notamos que el estado 1 es transiente.

$$\mathcal{T}_1 = +\infty$$

Dado por el hecho que puedo irme por 3 y volver en una cantidad infinita de pasos.

7.12 Recurrencia Nula y Positiva

Sea i un estado recurrente, diremos que i es recurrente positivo si $\mathcal{T}_i < +\infty$. Por el contrario si $\mathcal{T}_i = +\infty$ diremos que i es recurrente nulo.

7.12.1 Propiedades de Recurrencia

Tanto la recurrencia nula o positiva son propiedades de clase, esto es, en una clase si hay un recurrente nulo, todos son recurrentes nulos.

7.12.2 Propiedad Cantidad Finita de Estados

Si una CDMD tiene una cantidad finita de estados, entonces todo recurrente es recurrente positivo, esto es, si la cadena es finita entonces recurrencia es recurrencia positiva.

7.13 Propiedades Limites

En esta sección nos interesa estudiar que pasa con el sistema cuando ha pasado mucho tiempo, intuitivamente nos interesa calcular lo siguiente,

$$\lim_{n \rightarrow +\infty} P_{ij}^n$$

Cuyo límite, en caso de existir, se denota por π_{ij} . Esta probabilidad corresponde a la probabilidad que comenzando en i en el sistema, este esté en j en el largo plazo. Para calcular estas probabilidades límite se puede obtener la matriz de transición en n pasos.

$$P^n = P \times P \times P \times P \times \dots \times P$$

Luego, identificar la coordenada (i, j) y calcular $\lim_{n \rightarrow +\infty} P_{ij}^n$, lo cual es en general complicado.

7.14 Probabilidades Estacionarias

Para CDMD tales que todos sus estados son recurrentes positivos y aperiódicos, si además la cadena tiene una sola clase de comunicación (matriz irreducible), entonces se cumple que la probabilidad límite $\lim_{n \rightarrow +\infty} P_{ij}^n$ existe y es independiente de i . Dichas probabilidades se denotan por π_j y se denominan probabilidades estacionarias, su cálculo se realiza mediante la resolución de un sistema de ecuaciones lineales,

$$\begin{aligned}\pi^t &= \pi^t P \\ \sum_{j \in I} \pi_j &= 1 \\ \pi_j &\geq 0, \quad \forall j \in I \\ \pi &= (\pi_1, \pi_2, \pi_3, \dots, \pi_j)^t\end{aligned}$$

7.14.1 Interpretación de las probabilidades estacionarias

Las probabilidades estacionarias se pueden interpretar de dos formas,

- La probabilidad que en el largo plazo el sistema esté en cada estado $i \in I$.
- La proporción del tiempo que el sistema esté en cada estado $i \in I$, esto último es importante para cadenas con "reward" por estado.

8 Cadenas de Markov a Tiempo Continuo

Consideremos un proceso estocástico $X = \{X(t) : t \geq 0\}$ tal que $\forall t \in \mathbb{R}_+$ el $\text{Sop}(X(t)) = I$ que llamaremos conjunto de estados. Al igual que para las CDMD I debe ser finito o numerable, diremos que X es una CDMC (Cadena de Markov a tiempo Continuo) ssi:

- Cumple con markoveneidad, esto es $\forall t, s \geq 0$, y $\forall i, j \in I$, tenemos

$$\begin{aligned} P(X(t+s) = j / X(t) = i, X(u) = f(u), u \in [0, t]) \\ = P(X(t+s) = j / X(t) = i), \quad f[0, t] \rightarrow I \end{aligned}$$

- Cumple con Homogeneidad, esto es $\forall t, s \geq 0$, $\forall i, j \in I$, entonces

$$P(X(t+s) = j / X(t) = i)$$

No depende de t , es decir que se cumple,

$$P(X(t+s) = j / X(t) = i) = P(X(s) = j / X(0) = i)$$

8.1 Tiempos de Permanencia

Definimos el tiempo de permanencia T_i para $i \in I$ como la variable aleatoria que cuenta el tiempo que transcurre desde que se llega al estado i hasta que se sale del estado i . Cabe mencionar que los tiempos de permanencia no dependen del tiempo en el que se llega (por homogeneidad).

8.2 Distribución Tiempos de Permanencia

Las variables aleatorias T_i son independientes y distribuyen exponenciales con tasas no necesariamente iguales, esto es $T_i \perp T_j$, $\forall i \neq j$, $T_i \sim \exp(v_i)$ con $v_i \neq v_j$ (no necesariamente iguales).

Para demostrar lo anterior basta mostrar que las variables aleatorias T_i cumplen con la propiedad de pérdida de memoria, notemos primero que $\text{sop}(T_i) = \mathbb{R}_+$, sean $t, s \geq 0$.

$$\begin{aligned} P(T_i > t + s / T_i > t) &= P(X(u) = i, \forall u \in [0, t + s] / X(u) = i, \forall u \in [0, t]) \\ &= P(X(u) = i, \forall u \in [t, t + s] / X(u) = i, \forall u \in [0, t]) \\ &= P(X(u) = i, \forall u \in [t, t + s] / X(t) = i) \\ &= P(X(u) = i, \forall u \in [0, s] / X(0) = i) \\ &= P(X(u) = i, \forall u \in [0, s]) \\ &= P(T_i \geq s) \end{aligned}$$

De esta forma para caracterizar por completo una CDMC es necesario conocer los siguientes elementos,

- Las tasas de permanencia v_i .
- Las probabilidades de transición de la CDMD subyacente (esqueleto) que anotaremos por P_{ij} y que cumple con $P_{ii} = 0, \forall i \in I$.

8.3 Tasas de Transición

Definimos las tasas de transición de la siguiente forma,

$$q_{ij} = v_i P_{ij}$$

Notamos que,

$$\sum_{j \in I} q_{ij} = \sum_{j \in I} v_i P_{ij} = v_i$$

8.4 Ejemplo Notable - Procesos de Nacimiento - Muerto

Este tipo de procesos permite caracterizar la cantidad de individuos que hay en cada instante t , es decir, se trata de una CDMC con conjunto de estados $I = \mathbb{N}^*$, y tasas de transición con la siguiente forma,

$$q_{i,i+1} = \lambda_i, i \in I \text{ Tasas de Nacimiento}$$

$$q_{i,i-1} = \mu_i, i \geq 1 \text{ Tasas de Muerte}$$

Su grafo asociado se presenta a continuación en la Figura 8.4




Figure 15: Cadena Proceso Nacimiento - Muerto

Con tasas de permanencia de la forma,

$$v_0 = \lambda_0$$

$$v_1 = \lambda_1 + \mu_1$$

...

$$v_i = \lambda_i + \mu_i, i \geq 1$$

Luego,

$$P_{01} = \frac{\lambda_0}{\lambda_0} = 1$$

$$P_{10} = \frac{\mu_1}{\lambda_1 + \mu_1}$$

$$P_{12} = \frac{\lambda_1}{\lambda_1 + \mu_1}$$

En general se tiene que,

$$P_{i,i-1} = \frac{\mu_i}{\mu_i + \lambda_i}, \quad P_{i,i+1} = \frac{\lambda_i}{\lambda_i + \mu_i}, \lambda \in I$$

8.5 Probabilidades de Transición Continuas

Definimos las probabilidades de transición continuas de la forma,

$$P_{ij}(t) = P(X(t) = j / X(0) = i), \mathbb{R}_+ \rightarrow [0, 1]$$

Estas probabilidades son la generalización de las probabilidades P_{ij}^n de las Cadenas de Markov Discretas.

8.6 Teorema Chapman - Kolmogorov continuo

$$P_{ij}(t+s) = \sum_{k \in I} P_{ik}(t)P_{kj}(s)$$

Algunas propiedades presentes derivadas de lo anterior son

$$\lim_{h \rightarrow 0^+} \frac{1 - P_{ii}(h)}{h} = v_i, \forall i \in I$$

$$\lim_{h \rightarrow 0^+} \frac{P_{ij}(h)}{h} = q_{ij}, \forall i, j \in I, i \neq j$$

A continuación demostraremos lo anterior,

$$P_{ii}(h) \sim P(T_i > h) = F_{T_i}^-(j) = e^{-v_i h}$$

$$\lim_{h \rightarrow 0^+} \frac{1 - P_{ii}(h)}{h} = \lim_{h \rightarrow 0^+} \frac{1 - e^{-v_i h}}{h} = v_i$$

Lo segundo se demuestra de forma similar,

$$P_{ij}(h) \sim P(T_i \leq h)P_{ij} = (1 - e^{-v_i h})P_{ij}$$

$$\lim_{h \rightarrow 0^+} = \lim_{h \rightarrow 0^+} \frac{(1 - e^{-v_i h})P_{ij}}{h} = P_{ij} \lim_{h \rightarrow 0^+} v_i e^{-v_i h} = v_i P_{ij} = q_{ij}$$

8.7 Ecuaciones Backward / Forward Kolmogorov

Bajo ciertas condiciones de regularidad se cumple lo siguiente $\forall i, j \in I$,

$$\text{Backward: } P'_{ij}(t) = \sum_{k \in I, k \neq i} q_{ik} P_{kj}(t) - v_i P_{ij}(t)$$

$$\text{Forward: } P'_{ij}(t) = \sum_{k \in I, k \neq j} q_{kj} P_{ik}(t) - v_j P_{ij}(t)$$

Suponiendo que existe el límite de $\lim_{t \rightarrow +\infty} P_{ij}(t)$ y no depende de t , tomando el límite de la ecuación Forward, se tiene,

$$\lim_{t \rightarrow +\infty} P'_{ij}(t) = \sum_{k \in I, k \neq j} q_{kj} \pi_k - v_j \pi_j$$

$$v_j \pi_j = \sum_{k \in I, k \neq j} q_{kj} \pi_k, \forall j \in I$$

$$\sum_{j \in I} \pi_j = 1, \pi_j \geq 0$$

Considere la Figura 8.7, obtenga ecuaciones para $j = 1$,




Figure 16: Ejemplo Ecuaciones Backward - Forward

$$2\pi_1 = 4\pi_2 + 7\pi_3$$

Para $j = 2$,

$$4\pi_2 = 2\pi_1 + 8\pi_3$$

Para $j = 3$,

$$5\pi_3 = 10\pi_1 + 3\pi_2$$

$$\pi_1 + \pi_2 + \pi_3 = 1$$

El sistema de ecuaciones a resolver es el siguiente,

$$2\pi_1 = 4\pi_2 + 7\pi_3$$

$$4\pi_2 = 2\pi_1 + 8\pi_3$$

$$5\pi_3 = 10\pi_1 + 3\pi_2$$

$$1 = \pi_1 + \pi_2 + \pi_3$$

Resolviendo se obtiene,

$$\pi_1 = \pi_2 = \pi_3 = 0$$

9 Sistemas de Espera

Los sistemas de espera o colas son procesos estocásticos en el cual entidades van llegando a un sistema compuesto por colas y cajas (servidores), para definir concretamente los sistemas de espera se deben, al menos, responder las siguientes preguntas.

- ¿Cómo llegan los clientes / entidades?
Puede ser determinístico (tasa conocida) o según una distribución (proceso de Poisson por ejemplo).
- ¿Cómo funciona la distribución física del sistema?
Condiciones y distribución de espera, espacios, estaciones, etc.
- ¿Cuál es el procedimiento o políticas de atención?
Cómo se escoge quién se atiende, distribución de tiempos de atención, cuántas cajas o servidores.

Así, un sistema de espera puede quedar definido por cinco parámetros,

$$A/B/S/C/D$$

En lo anterior cada parámetro significa lo siguiente,

- **A**: Proceso de llegada (tiempo entre dos llegadas sucesivas).
M: Markoviano (idea de pérdida de memoria), tiempo entre llegadas es exponencial, es decir, es un proceso de Poisson.
- **G**: General (otra distribución).
- **D**: Determinístico.

- B : Proceso de atención (M, G, D), si es M es exponencial. Esto determina el tiempo de atención en el servidor.
- S : Número de servidores de atención.
- C : Capacidad de la cola.
- D : Orden de atención (Sistema FIFO, LIFO, Prioridades, etc.).

9.1 Sistema M/M/1

Al denominar un sistema de espera como M/M/1 se hace implícito que el sistema tiene capacidad infinita, no se especifica el valor de C . Sean las llegadas un proceso de Poisson con tasa $\lambda > 0$ y tiempos de atención exponencial con tasa $\mu > 0$.




Figure 17: Diagrama Sistema M/M/1

Lo anterior es posible de ser modelado como una Cadena de Markov Continua (CDMC), sea $X(t)$ la cantidad de personas en el sistema (caja + cola) en el tiempo t , tenemos $I = \mathbb{N}^*$. Para las tasas instantáneas de transición basta darse cuenta que podemos modelar la cola M/M/1 como un proceso nacimiento-muerte con $\lambda_i = \lambda, \forall i > 0$ y $\mu_i = \mu, \forall i \geq 1$. El grafo asociado se representa en la Figura 9.1

En general los procesos de nacimiento-muerte son útiles para modelar colas y por tanto es interesante preguntarse por sus probabilidades estacionarias,




Figure 18: Representación Sistema M/M/1

Impongamos las condiciones de equilibrio de la forma,

$$\begin{aligned}
 n = 0, \quad & \lambda_0 \pi_0 = \lambda_1 \mu_1 \\
 n = 1, \quad & (\mu_1 + \lambda_1) \pi_1 = \lambda_0 \pi_0 + \mu_2 \pi_2 \\
 n = 2, \quad & (\mu_2 + \lambda_2) \pi_2 = \lambda_1 \pi_0 + \mu_3 \pi_3
 \end{aligned}$$

Para un n cualquiera (i),

$$n = i, \quad (\mu_i + \lambda_i) \pi_i = \lambda_{i-1} \pi_{i-1} + \mu_{i+1} \pi_{i+1} \quad \forall i \geq 1$$

De $n = 0$,

$$\pi_1 = \frac{\lambda_0}{\lambda_1} \pi_0$$

Reemplazando en $n = 1$

$$\begin{aligned}
 (\lambda_1 + \mu_1) \frac{\lambda_0}{\lambda_1} \pi_0 &= \lambda_0 \pi_0 + \mu_2 \pi_2 \\
 \pi_2 &= \left[\frac{(\lambda_1 + \mu_1) \lambda_0}{\mu_1 \mu_2} - \frac{\lambda_0}{\mu_2} \right] = \left[\frac{\lambda_1 \lambda_0}{\mu_2 \mu_1} \right] \pi_0
 \end{aligned}$$

Luego, si repetimos este proceso iterativamente,

$$\pi_i = \frac{\lambda_0 \lambda_1 \dots \lambda_{i-1}}{\mu_1 \mu_2 \dots \mu_i}, \quad \forall i \geq 1$$

Además se cumple que $\sum_{i=0}^{+\infty} \pi_i = 1$, así,

$$\pi_0 + \sum_{i=0}^{+\infty} \pi_i = \pi_0 + \sum_{i=1}^{+\infty} \frac{\lambda_0 \lambda_1 \dots \lambda_{i-1}}{\mu_1 \mu_2 \dots \mu_i} \pi_0 = 1$$

$$\pi_0 = \frac{1}{1 + \sum_{i=1}^{+\infty} \frac{\lambda_0 \lambda_1 \dots \lambda_{i-1}}{\mu_1 \mu_2 \dots \mu_i}}$$

Para que lo anterior se cumpla, la expresión $\sum_{i=1}^{+\infty} \frac{\lambda_0 \lambda_1 \dots \lambda_{i-1}}{\mu_1 \mu_2 \dots \mu_i}$ tiene que converger. Tomemos el caso M/M/1,

$$1 + \sum_{i=1}^{+\infty} \frac{\lambda_0 \lambda_1 \dots \lambda_{i-1}}{\mu_1 \mu_2 \dots \mu_i} = 1 + \sum_{i=1}^{+\infty} \left(\frac{\lambda}{\mu}\right)^i = \sum_{i=0}^{+\infty} \left(\frac{\lambda}{\mu}\right)^i$$

La serie anterior tiene convergencia ssi $\lambda < \mu$, osea que la atención es más rápida que la llegada de entidades al sistema, por serie geométrica tenemos,

$$\frac{1}{1 - \frac{\lambda}{\mu}} = \frac{\mu}{\mu - \lambda}$$

$$\pi_0 = \frac{\mu - \lambda}{\mu}$$

Luego,

$$\pi_i = \left(\frac{\lambda}{\mu}\right) \left(\frac{\mu\lambda}{\mu}\right), \forall i \geq 1$$

¿Cuál es la proporción del tiempo que la caja está vacía?

$$\pi_0 = \frac{\mu - \lambda}{\lambda}$$

¿Cuántas personas hay en promedio en el sistema?

$$L = \sum_{i=0}^{+\infty} i \pi_i$$

9.2 Teorema - ecuaciones de Little

A continuación definiremos algunas variables de interés en sistemas de espera,

- L : Número de entidades en el sistema (caja + cola).
- W : Tiempo promedio de un cliente en el sistema.

Sean L_q y L_w las variables anteriores solo en la cola, y sea ρ la utilización media de los servidores, bajo ciertas condiciones se cumple para los sistemas M/M/S que,

$$L = \lambda W$$

$$L_q = \lambda W_q$$

$$W = W_q + \frac{1}{\mu}$$

9.2.1 Aplicación Little a Sistema M/M/1

$$\pi_i = \left(\frac{\lambda}{\mu}\right)^i \left(\frac{\mu - \lambda}{\mu}\right), i \geq 0$$

Luego,

$$\begin{aligned} L &= \sum_{i=0}^{+\infty} i\pi_i = \sum_{i=1}^{+\infty} \left(\frac{\mu - \lambda}{\mu}\right) i \left(\frac{\lambda}{\mu}\right)^i = \frac{\mu - \lambda}{\mu} \sum_{i=0}^{+\infty} (i+1) \left(\frac{\lambda}{\mu}\right)^{i+1} \\ &= \frac{\mu - \lambda}{\mu} \left(\frac{\lambda}{\mu}\right) \left[\sum_{i=0}^{+\infty} i \left(\frac{\lambda}{\mu}\right)^i + \sum_{i=0}^{+\infty} \left(\frac{\lambda}{\mu}\right)^i \right] \\ &= \sum_{i=0}^{+\infty} \left(\frac{\lambda}{\mu}\right)^i = \frac{1}{1 - \frac{\lambda}{\mu}} = \frac{\mu}{\mu - \lambda} \end{aligned}$$

Luego,

$$\begin{aligned} L &= \frac{\lambda}{\mu} L + \frac{\lambda}{\mu} \rightarrow L \left(\frac{\mu - \lambda}{\mu}\right) = \frac{\lambda}{\mu} \\ L &= \frac{\lambda}{\mu} \frac{\mu}{\mu - \lambda} = \frac{\lambda}{\mu - \lambda} \end{aligned}$$

Por little se tiene que,

$$\begin{aligned} W &= \frac{L}{\lambda} = \frac{1}{\mu - \lambda} \\ W_q &= W - \frac{1}{\mu} = \frac{1}{\mu - \lambda} - \frac{1}{\mu} = \frac{\lambda}{\mu(\mu - \lambda)} \\ L_q &= \lambda W_q = \frac{\lambda^2}{\mu(\mu - \lambda)} \\ L - L_q &= \frac{\lambda}{\mu - \lambda} - \frac{\lambda^2}{\mu(\mu - \lambda)} = \frac{\lambda}{\mu} < 1 \end{aligned}$$

El promedio de la caja es máximo 1, por esto se tiene $L - L_q < 1$, luego

$$\rho = \frac{\lambda}{\mu}$$

9.3 Sistema M/M/S

El sistema M/M/S generaliza el sistema M/M/1 pasando de 1 servidor a S servidores, cabe destacar que si alguno de los S servidores no atiende exponencial el sistema cambia y la M (Markoviano) cambia a una G . El sistema se representa en la Figura 9.3 a continuación, cada uno de los S servidores tiene tiempos de atención que distribuyen exponencial, esto es Tiempo Servicio $_i \sim \exp(\mu)$, $\forall i \in \{1, \dots, S\}$. Cabe mencionar que este proceso no es un proceso bifurcado ya que la repartición no es aleatoria, esto es, la forma de entrada de las entidades a los servidores sigue alguna regla (FIFO, LIFO u otra similar).




Figure 19: Sistema M/M/S

El diagrama del sistema M/M/S se presenta en la Figura 9.3 a continuación, notar como hasta el elemento S las salidas aumentan el valor que acompaña a μ para luego quedarse fijo desde S en adelante, esto debido a que se ha alcanzado el límite los servidores que atienden a las entidades. Otro punto a recordar es que dado que los servidores distribuyen exponencial, esto es $t_i \sim \exp(\mu)$, entonces el $\min\{t_1, t_2\} \sim \exp(\mu + \mu)$, siendo esto generalizable para n variables exponenciales.




Figure 20: Diagrama M/M/S

9.3.1 Proceso Nacimiento - Muerto

$$\lambda_i = \lambda, \quad \forall i \geq 0 \in \mathbb{N}^*$$

$$\mu_i = \begin{cases} i\mu & i \in \{1, \dots, S\} \\ S\mu & \text{En otro caso} \end{cases}$$

$$\mu_0 = \frac{1}{1 + \sum_{i=1}^{+\infty} \frac{\lambda_0 \dots \lambda_{i-1}}{\mu_1 \dots \mu_i}}$$

$$\pi_i = \frac{\lambda_0 \dots \lambda_{i-1}}{\mu_1 \dots \mu_i} \pi_0$$

$$\pi_i = \begin{cases} \left(\frac{\lambda}{\mu}\right)^i \frac{1}{i!} \pi_0 & i \leq S \\ \left(\frac{\lambda}{\mu}\right)^i \frac{1}{S! S^{i-S}} \pi_0 & i > S \end{cases}$$