

Cadenas de Markov Homogéneas

Módulo 2 — Modelos Estocásticos

Propiedad de Markov · Tiempo discreto · Clasificación de estados · Distribuciones estacionarias · Tiempos de primer paso
· Tiempo continuo · Nacimiento y muerte

Por P. Hurtado · 2026

Este módulo continúa desde el Módulo 1 (probabilidad, variables aleatorias, proceso de Poisson). El Proceso de Poisson aparece como caso particular de cadena de Markov en tiempo continuo (proceso de nacimiento puro). Se asume familiaridad con álgebra lineal (matrices, autovalores) y con la distribución Exponencial. Notación: S espacio de estados, $\mathbf{P}$ matriz de transición, π distribución estacionaria, $\mathbf{Q}$ generador infinitesimal.

Índice

1. Procesos Estocásticos y Propiedad de Markov	3
1.1 · Proceso estocástico	3
1.2 · Filtración y adaptabilidad	3
1.3 · Propiedad de Markov	4
1.4 · Homogeneidad temporal	4
2. Cadenas de Markov en Tiempo Discreto (CMTD)	4
2.1 · Espacio de estados y probabilidades de transición	4
2.2 · Matriz de transición	5
2.3 · Ecuaciones de Chapman-Kolmogorov	5
2.4 · Distribución en el paso n	6
2.5 · Forma canónica y clases de estados (anticipo)	6
2.6 · Propiedades estructurales de $\mathbf{P}$	7
3. Clasificación de Estados	7
3.1 · Accesibilidad y comunicación	8
3.2 · Número de visitas a un estado	9
3.3 · Estados recurrentes y transitorios	10
3.4 · Recurrencia como propiedad de clase	11
3.5 · Clasificación completa de estados	11
3.6 · Periodicidad	12
3.7 · Cadenas ergódicas	13
3.8 · Ejemplo: Paseo aleatorio simétrico en $\mathbb{Z}$	13
3.9 · Funciones generatrices para tiempos de primer paso	15
4. Distribuciones Estacionarias y Comportamiento a Largo Plazo	15
4.1 · Distribución estacionaria	16
4.2 · Cálculo de la distribución estacionaria	16
4.3 · Teorema ergódico y convergencia	17
4.4 · Reversibilidad y balance detallado	17
4.5 · Demostración del Teorema Ergódico	18
4.6 · Velocidad de convergencia y brecha espectral	18
4.7 · Algoritmo de Metropolis-Hastings	19
5. Tiempos de Primer Paso y Absorción	19
5.0 · Funciones armónicas y ecuación de Poisson	19
5.1 · Tiempo de primer paso	20
5.2 · Tiempo medio de retorno y estacionariedad	21
5.3 · Probabilidades de absorción	22
5.4 · Tiempo esperado de absorción: matriz fundamental	23
5.5 · Juego de la ruina: caso general $p \neq \frac{1}{2}$	24
5.6 · Modelo de Ehrenfest (difusión entre urnas)	25
6. Cadenas de Markov en Tiempo Continuo (CMTC)	25
6.1 · Definición y propiedad de Markov continua	25

6.2 · Tiempos de permanencia	25
6.3 · Generador infinitesimal Q	26
6.4 · Ecuaciones de Kolmogorov	27
6.5 · Distribución estacionaria de una CMTC	29
6.6 · Cadena embebida	29
7. Proceso de Nacimiento y Muerte	29
7.1 · Definición	30
7.2 · Balance detallado y distribución estacionaria	30
7.3 · Proceso de nacimiento puro: conexión con Poisson	31
7.4 · Cola M/M/1	31

Leyenda de colores

Cada bloque de contenido se identifica visualmente por color, según su naturaleza:

	Definición	Concepto formal con nombre y notación. Marco verde claro.
	Teorema/Proposición	Resultado demostrable a partir de las definiciones. Marco azul.
	Demostración	Argumento que justifica un teorema o proposición. Marco morado.
	Ejemplo	Aplicación concreta o caso ilustrativo. Marco gris.
	Nota	Observación, intuición o comentario complementario. Marco ámbar.
	Atención	Advertencia sobre un error común o sutileza. Marco rojo.
	Sección	Encabezado principal del módulo. Fondo azul oscuro.
	Subsección	Subdivisión temática dentro de una sección. Fondo azul claro.

Sección 1: Procesos Estocásticos y Propiedad de Markov

1.1 · Proceso estocástico

Definición 1.1 · Proceso estocástico

Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad y T un conjunto de índices (conjunto de *tiempo*). Un **proceso estocástico** es una familia de variables aleatorias

$$\{X_t : t \in T\},$$


donde cada $X_t : \Omega \rightarrow \mathcal{S}$ toma valores en el **espacio de estados** $\mathcal{S}$.

Según la naturaleza de T y $\mathcal{S}$ se distinguen cuatro tipos:

Tiempo T	Estados $\mathcal{S}$	Tipo
Discreto ($\mathbb{N}$)	Discreto	Cadena en tiempo discreto
Discreto ($\mathbb{N}$)	Continuo ($\mathbb{R}$)	Proceso en tiempo discreto
Continuo ($[0, \infty)$)	Discreto	Cadena en tiempo continuo
Continuo ($[0, \infty)$)	Continuo ($\mathbb{R}$)	Proceso en tiempo continuo

En este módulo $T = \mathbb{N}_0$ (discreto) o $T = [0, \infty)$ (continuo), y $\mathcal{S}$ es *discreto* (finito o numerable).

Para cada $\omega \in \Omega$ fijo, la función $t \mapsto X_t(\omega)$ es una **trayectoria** (o realización) del proceso. Un proceso estocástico puede verse como una distribución sobre el espacio de trayectorias.



Trayectoria de una cadena en $\mathcal{S} = \{1, 2, 3\}$

1.2 · Filtración y adaptabilidad

Definición 1.2 · Filtración y proceso adaptado

Una **filtración** $\{\mathcal{F}_n\}_{n \geq 0}$ es una sucesión creciente de σ -álgebras: $\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \dots \subseteq \mathcal{F}$.

Un proceso $\{X_n\}$ es **adaptado** a $\{\mathcal{F}_n\}$ si X_n es $\mathcal{F}_n$ -medible para todo n . Intuitivamente, $\mathcal{F}_n$ representa la *información disponible hasta el instante n*.

La filtración natural del proceso es $\mathcal{F}_n = \sigma(X_0, X_1, \dots, X_n)$.

1.3 · Propiedad de Markov

Definición 1.3 · Propiedad de Markov (débil)

Un proceso estocástico $\{X_n\}_{n \geq 0}$ con espacio de estados discreto $\mathcal{S}$ tiene la **propiedad de Markov** (débil) si para todo $n \geq 0$ y todos los estados $i_0, i_1, \dots, i_{n-1}, i, j \in \mathcal{S}$:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i).$$

En palabras: el futuro depende del pasado *únicamente* a través del presente. El estado actual X_n captura toda la información relevante del historial.

La propiedad de Markov es una hipótesis de falta de memoria del proceso. No dice que el futuro sea independiente del pasado en absoluto, sino que condicionar al presente hace que el pasado sea irrelevante.

Definición 1.4 · Propiedad de Markov fuerte

Sea τ un **tiempo de parada** (variable aleatoria con valores en $\mathbb{N}_0$ tal que $\{\tau = n\} \in \mathcal{F}_n$). La **propiedad de Markov fuerte** establece que, dado $\tau < \infty$, el proceso desplazado $\{X_{\tau+k}\}_{k \geq 0}$ tiene la misma distribución que $\{X_k\}_{k \geq 0}$ iniciado en X_τ , e independiente de $\mathcal{F}_\tau$.

Toda cadena de Markov homogénea satisface la propiedad de Markov fuerte.

1.4 · Homogeneidad temporal

Definición 1.5 · Cadena de Markov homogénea

Un proceso $\{X_n\}_{n \geq 0}$ con la propiedad de Markov es **homogéneo en el tiempo** (o *temporalmente homogéneo*) si las probabilidades de transición no dependen de n :

$$\mathbb{P}(X_{n+1} = j \mid X_n = i) = p_{ij} \quad \forall n \geq 0,$$

donde p_{ij} es la **probabilidad de transición en un paso** de i a j . En adelante toda cadena mencionada es homogénea salvo mención explícita.

△ Atención

No confundir homogeneidad temporal con independencia. Los estados X_n no son independientes; la homogeneidad solo garantiza que las *probabilidades de salto* son constantes en el tiempo.

Sección 2: Cadenas de Markov en Tiempo Discreto (CMTD)

2.1 · Espacio de estados y probabilidades de transición

Definición 2.1 · Probabilidades de transición en n pasos

La **probabilidad de transición en n pasos** de i a j es

$$p_{ij}^{(n)} = \mathbb{P}(X_{n+m} = j \mid X_m = i), \quad n \geq 1,$$

que por homogeneidad no depende de m . Por convenio: $p_{ij}^{(0)} = \delta_{ij}$ (delta de Kronecker: 1 si $i = j$, 0 en caso contrario).

2.2 · Matriz de transición

Definición 2.2 · Matriz de transición (matriz estocástica)

Si $\mathcal{S} = \{1, 2, \dots, s\}$ es finito, la **matriz de transición** es la matriz $\mathbf{P} \in \mathbb{R}^{s \times s}$ con entradas $(\mathbf{P})_{ij} = p_{ij}$.

$\mathbf{P}$ es una **matriz estocástica por filas**: satisface

1. $p_{ij} \geq 0$ para todo $i, j \in \mathcal{S}$.
2. $\sum_{j \in \mathcal{S}} p_{ij} = 1$ para todo $i \in \mathcal{S}$ (cada fila suma 1).

Ejemplo 2.1 · Cadena del clima (2 estados)

Sea $\mathcal{S} = \{S, L\}$ (soleado, lluvioso). Si hoy es soleado, mañana es soleado con probabilidad 0.8 y lluvioso con 0.2. Si hoy es lluvioso, mañana es soleado con 0.4 y lluvioso con 0.6. La matriz de transición es:

$$\mathbf{P} = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix} \leftarrow \begin{array}{l} \text{fila } S \\ \text{fila } L \end{array}$$

Verificación: filas suman 1. $\mathbf{P}$ es estocástica.




Diagrama de transición: cadena del clima

2.3 · Ecuaciones de Chapman-Kolmogorov

Teorema 2.1 · Ecuaciones de Chapman-Kolmogorov

Para todo $n, m \geq 0$ e $i, j \in \mathcal{S}$:

$$p_{ij}^{(n+m)} = \sum_{k \in \mathcal{S}} p_{ik}^{(n)} p_{kj}^{(m)}.$$

En notación matricial: $\mathbf{P}^{(n+m)} = \mathbf{P}^{(n)} \mathbf{P}^{(m)}$, con la convención $\mathbf{P}^{(n)} = \mathbf{P}^n$, donde $\mathbf{P}^n$ es la n -ésima potencia de $\mathbf{P}$.

Demostración

Por la propiedad de Markov y marginalización:

$$\begin{aligned} p_{ij}^{(n+m)} &= \mathbb{P}(X_{n+m} = j \mid X_0 = i) \\ &= \sum_{k \in \mathcal{S}} \mathbb{P}(X_{n+m} = j \mid X_n = k) \mathbb{P}(X_n = k \mid X_0 = i) \quad (\text{ley total}) \\ &= \sum_{k \in \mathcal{S}} p_{kj}^{(m)} p_{ik}^{(n)}. \end{aligned}$$

Esto es exactamente la (i, j) -ésima entrada del producto $\mathbf{P}^n \mathbf{P}^m = \mathbf{P}^{n+m}$. □

La clave es que la n -ésima potencia de la matriz de transición da las probabilidades en n pasos: $(\mathbf{P}^n)_{ij} = p_{ij}^{(n)}$.

2.4 · Distribución en el paso n

Definición 2.3 · Distribución marginal en el paso n

Sea $\boldsymbol{\mu}^{(0)}$ el vector fila de probabilidades iniciales: $\mu_i^{(0)} = \mathbb{P}(X_0 = i)$. La **distribución marginal** en el instante n es

$$\boldsymbol{\mu}^{(n)} = \boldsymbol{\mu}^{(0)} \mathbf{P}^n,$$

es decir, $\mu_j^{(n)} = \mathbb{P}(X_n = j) = \sum_{i \in \mathcal{S}} \mu_i^{(0)} p_{ij}^{(n)}$.

Ejemplo 2.2 · Distribución del clima en 2 pasos

Con la cadena del clima anterior y distribución inicial $(0.5, 0.5)$:

$$\mathbf{P}^2 = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}^2 = \begin{pmatrix} 0.72 & 0.28 \\ 0.56 & 0.44 \end{pmatrix}.$$

$$\boldsymbol{\mu}^{(2)} = (0.5, 0.5) \begin{pmatrix} 0.72 & 0.28 \\ 0.56 & 0.44 \end{pmatrix} = (0.64, 0.36).$$

Probabilidad de estar soleado a los 2 pasos: 0.64.

2.5 · Forma canónica y clases de estados (anticipo)

Si el espacio de estados $\mathcal{S}$ se puede particionar en clases de comunicación (ver Sección 3), la matriz $\mathbf{P}$ se puede reordenar en forma canónica:

$$\mathbf{P} = \begin{pmatrix} \mathbf{Q} & \mathbf{R} \\ \mathbf{0} & \mathbf{I} \end{pmatrix},$$

donde $\mathbf{Q}$ describe transiciones entre estados transitorios y $\mathbf{I}$ los estados absorbentes. Esta forma es central para tiempos de absorción (Sección 5).

2.6 · Propiedades estructurales de $\mathbf{P}$ Proposición 2.2 · Propiedades de $\mathbf{P}$ y sus potencias

1. **Estocasticidad hereditaria:** $\mathbf{P}^n$ es estocástica por filas $\forall n \geq 0$. En particular $\mathbf{P}^0 = \mathbf{I}$.
2. **Potencias = n -pasos:** $(\mathbf{P}^n)_{ij} = p_{ij}^{(n)}$.
3. **Evolución de la distribución:** $\boldsymbol{\mu}^{(n)} = \boldsymbol{\mu}^{(0)} \mathbf{P}^n$.
4. **Autovalor trivial:** $\lambda = 1$ es autovalor de $\mathbf{P}$ con vector propio derecho $\mathbf{1}$. $\boldsymbol{\pi}$ estacionaria $\Leftrightarrow \boldsymbol{\pi} \mathbf{P} = \boldsymbol{\pi}$ (autovector izquierdo con $\lambda = 1$).
5. **Cota espectral:** $|\lambda| \leq 1$ para todo autovalor λ de $\mathbf{P}$.

Demostración

(1) Inducción sobre n . Base $n = 0$: $\mathbf{P}^0 = \mathbf{I}$, claramente estocástica. Paso inductivo: dado $\mathbf{P}^{n-1}$ estocástica, $(\mathbf{P}^n)_{ij} = \sum_k (\mathbf{P}^{n-1})_{ik} p_{kj} \geq 0$ y $\sum_j (\mathbf{P}^n)_{ij} = \sum_k (\mathbf{P}^{n-1})_{ik} \underbrace{\sum_j p_{kj}}_{=1} = 1$.

(2) También por inducción. Para $n = 1$: $(\mathbf{P})_{ij} = p_{ij} = p_{ij}^{(1)}$ por definición. Para $n \geq 2$, supuesto $(\mathbf{P}^{n-1})_{ij} = p_{ij}^{(n-1)}$, por Chapman-Kolmogorov:

$$(\mathbf{P}^n)_{ij} = \sum_k (\mathbf{P}^{n-1})_{ik} p_{kj} = \sum_k p_{ik}^{(n-1)} p_{kj}^{(1)} = p_{ij}^{(n)}.$$

(3) Por (2): $(\boldsymbol{\mu}^{(0)} \mathbf{P}^n)_j = \sum_i \mu_i^{(0)} (\mathbf{P}^n)_{ij} = \sum_i \mathbb{P}(X_0 = i) p_{ij}^{(n)} = \mathbb{P}(X_n = j) = \mu_j^{(n)}$.

(4) $(\mathbf{P} \mathbf{1})_i = \sum_j p_{ij} = 1$ para todo i , luego $\mathbf{1}$ es autovector derecho de $\lambda = 1$.

(5) Sea $\mathbf{P} \mathbf{v} = \lambda \mathbf{v}$ con $\|\mathbf{v}\|_\infty = 1$ y $|v_{i^*}| = 1$. Entonces $|\lambda| = |(\mathbf{P} \mathbf{v})_{i^*}| = \left| \sum_j p_{i^*j} v_j \right| \leq \sum_j p_{i^*j} |v_j| \leq 1$. □

Teorema de Perron-Frobenius (versión estocástica). Para $\mathbf{P}$ irreducible y aperiódica: $\lambda = 1$ es el único autovalor con $|\lambda| = 1$ y tiene multiplicidad algebraica 1. Los demás autovalores satisfacen $|\lambda_k| < 1$, lo que controla la velocidad de convergencia a la distribución estacionaria (ver §4.6).

Sección 3: Clasificación de Estados

3.1 · Accesibilidad y comunicación

Definición 3.1 · Accesibilidad

El estado j es **accesible** desde i (notación: $i \rightarrow j$) si existe $n \geq 0$ tal que $p_{ij}^{(n)} > 0$, es decir, es posible llegar de i a j en algún número de pasos.

Dos estados i y j se **comunican** ($i \leftrightarrow j$) si $i \rightarrow j$ y $j \rightarrow i$. La comunicación es una relación de equivalencia en $\mathcal{S}$.

Demostración

Verificamos las tres propiedades de relación de equivalencia.

Reflexividad ($i \leftrightarrow i$): por convenio $p_{ii}^{(0)} = 1 > 0$, así que $i \rightarrow i$.

Simetría ($i \leftrightarrow j \Rightarrow j \leftrightarrow i$): inmediata de la definición (" $i \rightarrow j$ y $j \rightarrow i$ " es simétrica en i y j).

Transitividad ($i \leftrightarrow j$ y $j \leftrightarrow k \Rightarrow i \leftrightarrow k$): existen $r, s \geq 0$ con $p_{ij}^{(r)} > 0$ y $p_{jk}^{(s)} > 0$. Por Chapman-Kolmogorov: $p_{ik}^{(r+s)} \geq p_{ij}^{(r)} \cdot p_{jk}^{(s)} > 0$, luego $i \rightarrow k$. Análogamente $k \rightarrow i$, de modo que $i \leftrightarrow k$. $\square$

Definición 3.2 · Clase de comunicación

Las clases de equivalencia de $\leftrightarrow$ se llaman **clases de comunicación**. Una clase C es **cerrada** si no existe salida: $i \in C, i \rightarrow j \Rightarrow j \in C$.


Una cadena es **irreducible** si solo tiene una clase de comunicación, es decir, todos los estados se comunican entre sí.

Ejemplo 3.1 · Clases de comunicación en una cadena de 4 estados

Considerar la cadena con estados $\{1, 2, 3, 4\}$ y la siguiente matriz de transición:

$$\mathbf{P} = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0.5 & 0.5 & 0 & 0 \\ 0.3 & 0 & 0.4 & 0.3 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

- Estados $\{1, 2\}$: $1 \leftrightarrow 2$ (clase cerrada).
- Estado $\{3\}$: puede ir a $\{1\}$ y a $\{4\}$, pero ni 1 ni 4 van a 3 (clase abierta, estado transitorio).
- Estado $\{4\}$: $p_{44} = 1$, no hay salida (clase cerrada, estado absorbente).



3.2 · Número de visitas a un estado

Definición 3.3 · Número de visitas

Dado un estado $i \in \mathcal{S}$, el **número total de visitas** a i a lo largo de la trayectoria (contando desde $n = 1$) es la variable aleatoria

$$N(i) = \sum_{n=1}^{\infty} \mathbf{1}_{\{X_n=i\}}.$$

Si la cadena parte de $X_0 = i$, entonces $N(i)$ cuenta cuántas veces el proceso *regresa* a i .

Proposición 3.1 · Esperanza de visitas

$$\mathbb{E}[N(i) \mid X_0 = i] = \sum_{n=1}^{\infty} p_{ii}^{(n)}.$$

En consecuencia: i recurrente $\iff \mathbb{E}[N(i) \mid X_0 = i] = \infty$.

Demostración

Por linealidad y el teorema de Tonelli (sumandos no negativos):

$$\mathbb{E}[N(i) \mid X_0 = i] = \mathbb{E}\left[\sum_{n=1}^{\infty} \mathbf{1}_{\{X_n=i\}} \mid X_0 = i\right] = \sum_{n=1}^{\infty} \mathbb{P}(X_n = i \mid X_0 = i) = \sum_{n=1}^{\infty} p_{ii}^{(n)}. \quad \square$$

□

Proposición 3.2 · Distribución geométrica de $N(i)$

Para todo $k \geq 0$:

$$\mathbb{P}(N(i) \geq k \mid X_0 = i) = f_{ii}^k,$$

donde $f_{ii} = \mathbb{P}(\exists n \geq 1 : X_n = i \mid X_0 = i)$ es la probabilidad de retorno. Es decir, $N(i) \mid \{X_0 = i\}$ tiene distribución **Geométrica** con parámetro f_{ii} .

- Si $f_{ii} < 1$ (transitorio): $\mathbb{E}[N(i) \mid X_0 = i] = \frac{f_{ii}}{1 - f_{ii}} < \infty$.
- Si $f_{ii} = 1$ (recurrente): $\mathbb{P}(N(i) = \infty \mid X_0 = i) = 1$.

Demostración

Por la **propiedad de Markov fuerte** aplicada en el tiempo de parada $T_i^{(k)}$ (k -ésimo retorno a i): dado que la cadena regresó a i , el proceso reiniciado desde i es independiente del pasado. Así:

$$\mathbb{P}(N(i) \geq k \mid X_0 = i) = \mathbb{P}(N(i) \geq k-1 \mid X_0 = i) \cdot f_{ii}, \quad k \geq 1.$$

Con $\mathbb{P}(N(i) \geq 0) = 1$, por inducción: $\mathbb{P}(N(i) \geq k \mid X_0 = i) = f_{ii}^k$. □

□

Combinando ambas proposiciones:

$$i \text{ recurrente} \iff f_{ii} = 1 \iff N(i) = \infty \text{ c.s.} \iff \sum_{n=1}^{\infty} p_{ii}^{(n)} = \infty.$$

Para un estado transitorio, la cadena lo visita un número finito de veces casi seguramente, y luego lo abandona para siempre.

3.3 · Estados recurrentes y transitorios

Definición 3.4 · Probabilidad de retorno

Define $f_{ii} = \mathbb{P}(X_n = i \text{ para algún } n \geq 1 \mid X_0 = i)$, la probabilidad de que la cadena regrese al estado i . Entonces:

- i es **recurrente** si $f_{ii} = 1$ (el retorno es seguro).
- i es **transitorio** si $f_{ii} < 1$ (hay probabilidad positiva de no regresar).

Teorema 3.3 · Criterio de recurrencia por series

El estado i es recurrente si y solo si

$$\sum_{n=0}^{\infty} p_{ii}^{(n)} = \infty.$$

El estado i es transitorio si y solo si $\sum_{n=0}^{\infty} p_{ii}^{(n)} < \infty$, en cuyo caso el número esperado de visitas a i es finito.

Demostración

Usamos los resultados de §3.2.

Paso 1. Por la Proposición de esperanza de visitas: $\mathbb{E}[N(i) \mid X_0 = i] = \sum_{n=1}^{\infty} p_{ii}^{(n)}$.

Paso 2. Por la Proposición de distribución geométrica: $N(i) \mid \{X_0 = i\} \sim \text{Geom}(f_{ii})$, luego

$$\mathbb{E}[N(i) \mid X_0 = i] = \begin{cases} \frac{f_{ii}}{1 - f_{ii}} < \infty & \text{si } f_{ii} < 1, \\ +\infty & \text{si } f_{ii} = 1. \end{cases}$$

Paso 3. Uniendo: $f_{ii} = 1 \Leftrightarrow \mathbb{E}[N(i)] = \infty \Leftrightarrow \sum_n p_{ii}^{(n)} = \infty$. Esto es exactamente el enunciado. $\square$

Proposición 3.4 · Recurrencia en cadenas finitas irreducibles

En una cadena de Markov con espacio de estados *finito e irreducible*, todos los estados son **recurrentes positivos**.

Demostración

Como $|\mathcal{S}| < \infty$, al menos un estado debe ser visitado infinitas veces (la cadena no puede “escapar” a infinito). En una cadena irreducible, si un estado i es recurrente entonces *todos* los estados son recurrentes (por comunicación). Y en $\mathcal{S}$ finito la recurrencia implica recurrencia positiva (el tiempo medio de retorno es finito). $\square$

Definición 3.5 · Recurrencia positiva y nula

Sea i recurrente y $\mu_i = \mathbb{E}[\min\{n \geq 1 : X_n = i\} \mid X_0 = i]$ el **tiempo medio de retorno** a i . Entonces:

- i es **recurrente positivo** si $\mu_i < \infty$.
- i es **recurrente nulo** si $\mu_i = \infty$.

△ Atención

La recurrencia nula solo aparece en cadenas con espacio de estados *infinito numerable*. El ejemplo más conocido es la caminata aleatoria simétrica en $\mathbb{Z}$: todos los estados son recurrentes (vuelve con probabilidad 1), pero el tiempo esperado de retorno al origen es ∞ . Ver Ejemplo 3 (§3.8) para el análisis completo.

3.4 · Recurrencia como propiedad de clase

Teorema 3.5 · Recurrencia se propaga por comunicación

Si $i \leftrightarrow j$, entonces i recurrente $\iff j$ recurrente. Dentro de una clase de comunicación, *todos* los estados son recurrentes o *todos* son transitorios.

Demostración

Como $i \leftrightarrow j$, existen $r, s \geq 1$ con $\alpha := p_{ij}^{(r)} > 0$ y $\beta := p_{ji}^{(s)} > 0$. Para todo $n \geq 0$, por Chapman-Kolmogorov:

$$p_{jj}^{(r+n+s)} \geq p_{ji}^{(s)} \cdot p_{ii}^{(n)} \cdot p_{ij}^{(r)} = \alpha\beta \cdot p_{ii}^{(n)}.$$

Sumando sobre n : si i es recurrente ($\sum_n p_{ii}^{(n)} = \infty$), entonces $\sum_n p_{jj}^{(n)} = \infty$, luego j recurrente. El recíproco es simétrico. $\square$

Proposición 3.6 · Estados transitorios en clases abiertas

Si una clase de comunicación C tiene salida (existe $i \in C, j \notin C$ con $p_{ij} > 0$), entonces todos los estados de C son transitorios.

Demostración

Partiendo de $i \in C$, con probabilidad $p_{ij} > 0$ la cadena alcanza $j \notin C$. Desde j , el retorno a i puede ser imposible o tener probabilidad < 1 , luego $f_{ii} < 1$: i es transitorio. Por el teorema anterior, toda la clase C es transitoria. $\square$

3.5 · Clasificación completa de estados

Teorema 3.7 · Clasificación tripartita

En una cadena de Markov irreducible, exactamente uno de los tres casos:

1. **Transitoria:** todos los estados son transitorios ($f_{ii} < 1, \mathbb{E}[N(i)] < \infty$).
2. **Recurrente nula:** todos recurrentes con $\mu_i = \infty$ para todo i .
3. **Recurrente positiva:** todos recurrentes con $\mu_i < \infty$ para todo i .

Además: la cadena es recurrente positiva $\iff$ admite distribución estacionaria π con $\pi_i > 0$. En ese caso $\pi_i = 1/\mu_i$.

Demostración

La clasificación se propaga en la clase irreducible por el teorema anterior. Que todos tengan $\mu_i < \infty$ o todos $\mu_i = \infty$ se sigue de la cota $\mu_j \leq (1/\alpha\beta)\mu_i$ obtenida de la desigualdad $p_{jj}^{(r+n+s)} \geq \alpha\beta p_{ii}^{(n)}$.

Lema de Kac (positivo $\Rightarrow$ existe π). Para i recurrente positivo, definir $\pi_j = \mathbb{E}[\#\{0 \leq n < T_i : X_n = j\} \mid X_0 = i] / \mu_i$. Se puede verificar que $\pi P = \pi$ y $\sum_j \pi_j = 1$, con $\pi_j = 1/\mu_j > 0$ (por irreducibilidad). $\square$

Recíproco. Si $\exists \pi$ estacionaria con $\pi_i > 0$, el Teorema Ergódico (§4.3) implica que $X_n = i$ para infinitos n (recurrencia) y la frecuencia de visita es $\pi_i > 0$, luego $\mu_i = 1/\pi_i < \infty$. $\square$

Proposición 3.8 · Finito e irreducible implica recurrencia positiva

Toda cadena con $|\mathcal{S}| < \infty$ irreducible es recurrente positiva.

Demostración

En espacio finito la cadena no puede escapar al infinito, así que al menos un estado es recurrente. Por irreducibilidad, todos lo son. Si alguno fuera recurrente nulo, $\pi_i = 1/\mu_i = 0$ para todo i , por lo que $\sum_i \pi_i = 0 \neq 1$: contradicción. $\square$

3.6 · Periodicidad

Definición 3.6 · Periodo de un estado

El **periodo** del estado i es el máximo común divisor de los tiempos en los que es posible regresar a i :

$$d(i) = \gcd\{n \geq 1 : p_{ii}^{(n)} > 0\}.$$

Si $d(i) = 1$, el estado es **aperiódico**. Si $d(i) > 1$, es **periódico** con periodo $d(i)$.

Proposición 3.9 · Periodicidad es invariante en una clase

Si $i \leftrightarrow j$, entonces $d(i) = d(j)$. Por tanto, el periodo es una propiedad de la clase de comunicación, no del estado individual.

Demostración

Sean $r, s \geq 1$ con $p_{ij}^{(r)} > 0$ y $p_{ji}^{(s)} > 0$.

Paso 1: $d(j) \mid d(i)$. Para cualquier n con $p_{ii}^{(n)} > 0$, por Chapman-Kolmogorov:

$$p_{jj}^{(r+n+s)} \geq p_{ji}^{(s)} \cdot p_{ii}^{(n)} \cdot p_{ij}^{(r)} > 0,$$

luego $r + n + s \in \{m : p_{jj}^{(m)} > 0\}$ y por tanto $d(j) \mid (r + n + s)$. Tomando dos valores n_1, n_2 con $p_{ii}^{(n_k)} > 0$: $d(j) \mid (r + n_1 + s)$ y $d(j) \mid (r + n_2 + s)$, de donde $d(j) \mid (n_1 - n_2)$. Como $d(i) = \gcd\{n : p_{ii}^{(n)} > 0\}$ es la mínima combinación lineal entera positiva de ese conjunto, y $d(j)$ divide todas las diferencias de sus elementos: $d(j) \mid d(i)$.

Paso 2: $d(i) \mid d(j)$. Mismo argumento intercambiando i y j (con $r' = s, s' = r$).

Conclusión: $d(j) \mid d(i)$ y $d(i) \mid d(j)$ implican $d(i) = d(j)$. $\square$

Ejemplo 3.2 · Periodicidad

- Cadena $1 \rightarrow 2 \rightarrow 1$ (dos estados en ciclo): $d(1) = d(2) = 2$ (periódica).
- Cadena del clima (con autoloops): $d(S) = d(L) = 1$ (aperiódica).
- Caminata aleatoria en $\mathbb{Z}$ (pasos ± 1): $d(0) = 2$ (periódica). Ver §3.8.

Proposición 3.10 · Convergencia en múltiplos del período

Sea $\{X_n\}$ irreducible con período d y distribución estacionaria π . Para todo $i, j \in \mathcal{S}$:

$$\lim_{n \rightarrow \infty} p_{ij}^{(nd)} = d \cdot \pi_j.$$

Para cadenas periódicas no existe el límite $p_{ij}^{(n)}$, pero la **media de Cesàro** converge:

$$\frac{1}{N} \sum_{n=0}^{N-1} p_{ij}^{(n)} \xrightarrow{N \rightarrow \infty} \pi_j.$$

Demostración

La convergencia de Cesàro es consecuencia directa del Teorema Ergódico (§4.3): $\frac{1}{N} \sum_{n=0}^{N-1} p_{ij}^{(n)} = \mathbb{E}\left[\frac{1}{N} \sum_{n=0}^{N-1} \mathbf{1}_{\{X_n=j\}} \mid X_0=i\right] \rightarrow \pi_j$ por convergencia dominada (el integrando está acotado por 1). $\square$

3.7 · Cadenas ergódicas

Definición 3.7 · Cadena ergódica

Una cadena de Markov es **ergódica** si es:

1. **Irreducible**: todos los estados se comunican.
2. **Recurrente positiva**: todos los estados tienen tiempo medio de retorno finito.
3. **Aperiódica**: $d(i) = 1$ para todo $i \in \mathcal{S}$.


En particular, toda cadena irreducible con $\mathcal{S}$ finito y aperiódica es ergódica.

La ergodicidad es la condición que garantiza la convergencia de $\mathbf{P}^n$ a una distribución estacionaria única (ver Sección 4). En $\mathcal{S}$ finito, irreducibilidad + aperiodicidad $\Rightarrow$ ergodicidad.

3.8 · Ejemplo: Paseo aleatorio simétrico en $\mathbb{Z}$

Ejemplo 3.3 · Paseo aleatorio simétrico en $\mathbb{Z}$

Definición. Sean $\xi_1, \xi_2, \dots$ i.i.d. con $\mathbb{P}(\xi_k = +1) = \mathbb{P}(\xi_k = -1) = \frac{1}{2}$. Define $X_0 = 0$, $X_n = \xi_1 + \dots + \xi_n$. El espacio de estados es $\mathbb{Z}$ con $p_{ii+1} = p_{ii-1} = \frac{1}{2}$ (y 0 en otro caso).

Paseo aleatorio simétrico en $\mathbb{Z}$

Paso 1: Irreducibilidad. Para $j > i$: j es accesible desde i en $j - i$ pasos hacia la derecha. Por simetría i es accesible desde j . Luego $i \leftrightarrow j$ para todo par.

Paso 2: Período $d(0) = 2$. Solo se puede regresar al origen en número *par* de pasos (se necesitan exactamente tantos $+1$ como -1). Así $p_{00}^{(2k+1)} = 0$ para todo k , y $p_{00}^{(2k)} > 0$ para $k \geq 1$. Luego $d(0) = \gcd\{2, 4, 6, \dots\} = 2$.

Paso 3: Fórmula exacta para $p_{00}^{(2n)}$. Regresar en $2n$ pasos requiere exactamente n pasos $+1$ y n pasos -1 :

$$p_{00}^{(2n)} = \binom{2n}{n} \frac{1}{4^n}.$$

Paso 4: Aproximación de Stirling ($n! \approx \sqrt{2\pi n}(n/e)^n$).

$$\binom{2n}{n} \frac{1}{4^n} = \frac{(2n)!}{(n!)^2 4^n} \approx \frac{\sqrt{4\pi n} (2n/e)^{2n}}{2\pi n (n/e)^{2n} 4^n} = \frac{\sqrt{4\pi n}}{2\pi n} = \frac{1}{\sqrt{\pi n}}.$$

Más precisamente: $\binom{2n}{n}/4^n \sim 1/\sqrt{\pi n}$ cuando $n \rightarrow \infty$.

Paso 5: Recurrencia del estado 0.

$$\sum_{n=1}^{\infty} p_{00}^{(2n)} = \sum_{n=1}^{\infty} \frac{\binom{2n}{n}}{4^n} \sim \sum_{n=1}^{\infty} \frac{1}{\sqrt{\pi n}} = \infty,$$

pues $\sum n^{-1/2}$ diverge (criterio integral: $\int_1^{\infty} x^{-1/2} dx = \infty$). Por el criterio de recurrencia: estado 0 es recurrente. Por irreducibilidad: *todos* los estados son recurrentes.

Paso 6: Recurrencia nula. Usando la identidad $\sum_{n=0}^{\infty} \binom{2n}{n} x^n = 1/\sqrt{1-4x}$ ($|x| < 1/4$):

$$P_{00}(z) := \sum_{n=0}^{\infty} p_{00}^{(2n)} z^n = \sum_{n=0}^{\infty} \binom{2n}{n} \left(\frac{z}{4}\right)^n = \frac{1}{\sqrt{1-z}}, \quad |z| < 1.$$

Por la identidad $P_{00}(z) = 1/(1 - F_{00}(z))$ (§3.9): $F_{00}(z) = 1 - \sqrt{1-z} \xrightarrow{z \rightarrow 1^-} 1$, confirmando $f_{00} = 1$ (recurrente). Pero

$$\mu_0 = F'_{00}(1^-) = \lim_{z \rightarrow 1^-} \frac{1}{2\sqrt{1-z}} = +\infty.$$

El estado 0 (y por irreducibilidad, todos) son **recurrentes nulos**.

Conclusión.

- Irreducible, periódico ($d = 2$), recurrente nulo.
- Vuelve a cualquier estado con probabilidad 1, pero en tiempo esperado infinito.
- Sin distribución estacionaria: $\pi_i = 1/\mu_i = 0$ y no es normalizable.

△ Atención

Recurrente no significa regreso *rápido*. El paseo simétrico en $\mathbb{Z}$ vuelve al origen c.s., pero $\mu_0 = \infty$. En contraste, toda cadena irreducible en espacio finito es recurrente *positiva* con tiempos de retorno finitos.

3.9 · Funciones generatrices para tiempos de primer paso

Definición 3.8 · Funciones generatrices de transición y de primer paso

Para $i, j \in \mathcal{S}$ y $|z| \leq 1$:

$$P_{ij}(z) = \sum_{n=0}^{\infty} p_{ij}^{(n)} z^n \quad (\text{generatriz de transición}),$$

$$F_{ij}(z) = \sum_{n=1}^{\infty} f_{ij}^{(n)} z^n \quad (\text{generatriz de primer paso}).$$

Evalutando en $z = 1$: $F_{ij}(1) = f_{ij}$ (prob. total de alcanzar j desde i).

Proposición 3.11 · Identidades entre P_{ij} y F_{ij}

$$P_{ii}(z) = \frac{1}{1 - F_{ii}(z)}, \quad (3.1)$$

$$P_{ij}(z) = F_{ij}(z) \cdot P_{jj}(z), \quad i \neq j. \quad (3.2)$$

Demostración

Caso diagonal. Condicionando sobre el primer retorno a i (instante k):

$$p_{ii}^{(n)} = \sum_{k=1}^n f_{ii}^{(k)} p_{ii}^{(n-k)}, \quad n \geq 1; \quad p_{ii}^{(0)} = 1.$$

Multiplicando por z^n y sumando: $P_{ii}(z) = 1 + F_{ii}(z)P_{ii}(z)$, de donde (3.1). Análogamente para (3.2). $\square$

Proposición 3.12 · Criterio de recurrencia vía generatrices

- i recurrente $\iff F_{ii}(1) = 1 \iff P_{ii}(z) \rightarrow \infty$ cuando $z \rightarrow 1^-$.
- i recurrente positivo $\iff \mu_i = F'_{ii}(1^-) < \infty$. Entonces $\pi_i = 1/\mu_i$.
- i recurrente nulo $\iff F_{ii}(1) = 1$ pero $F'_{ii}(1^-) = +\infty$.

Demostración

De la identidad $P_{ii}(z) = 1/(1 - F_{ii}(z))$:

- Si $F_{ii}(1) < 1$: $(1 - F_{ii}(1)) > 0$, luego $P_{ii}(1) = 1/(1 - F_{ii}(1)) < \infty$, es decir, $\sum_n p_{ii}^{(n)} < \infty$: estado transitorio.
- Si $F_{ii}(1) = 1$: el denominador $\rightarrow 0$ cuando $z \rightarrow 1^-$, luego $P_{ii}(z) \rightarrow +\infty$: $\sum_n p_{ii}^{(n)} = \infty$: estado recurrente.
- Para distinguir positivo/nulo: derivando $P_{ii}(z) = 1/(1 - F_{ii}(z))$, $P'_{ii}(z) = F'_{ii}(z)/(1 - F_{ii}(z))^2$. El tiempo medio de retorno es $\mu_i = \sum_n n f_{ii}^{(n)} = F'_{ii}(1^-)$. Si $\mu_i < \infty$: positivo; si $\mu_i = \infty$: nulo. $\square$

La relación $P_{ii}(z) = 1/(1 - F_{ii}(z))$ es el puente algebraico entre las probabilidades de transición (directas de calcular vía $\mathbf{P}^n$) y las probabilidades de primer paso (que caracterizan recurrencia). Se usa de forma central en el análisis del paseo aleatorio (§3.8) y en la teoría de renovación.

Sección 4: Distribuciones Estacionarias y Comportamiento a Largo Plazo

4.1 · Distribución estacionaria

Definición 4.1 · Distribución estacionaria (invariante)

Un vector de probabilidades $\pi = (\pi_j)_{j \in S}$ es una **distribución estacionaria** (o *invariante*) si satisface:

$$\pi \mathbf{P} = \pi \quad (4.1)$$

$$\sum_{j \in S} \pi_j = 1, \quad \pi_j \geq 0 \quad \forall j. \quad (4.2)$$

En forma escalar: $\pi_j = \sum_{i \in S} \pi_i p_{ij}$ para todo j .

Si $\mu^{(0)} = \pi$, entonces $\mu^{(n)} = \pi$ para todo n : la distribución no cambia en el tiempo.

La distribución estacionaria existe siempre en una cadena irreducible recurrente positiva. La unicidad se obtiene además si la cadena es irreducible.

4.2 · Cálculo de la distribución estacionaria

Ejemplo 4.1 · Distribución estacionaria del clima

Con $\mathbf{P} = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}$, resolver $\pi \mathbf{P} = \pi$, $\pi_S + \pi_L = 1$:

$$\pi_S = 0.8 \pi_S + 0.4 \pi_L$$

$$\pi_L = 0.2 \pi_S + 0.6 \pi_L$$

De la primera ecuación: $0.2 \pi_S = 0.4 \pi_L$, luego $\pi_S = 2 \pi_L$.

Con $\pi_S + \pi_L = 1$: $\pi_L = 1/3$, $\pi_S = 2/3$.

Interpretación: a largo plazo, 2/3 de los días son soleados.

Ejemplo 4.2 · Distribución estacionaria de una cadena de 3 estados

Sea $S = \{1, 2, 3\}$ con:

$$\mathbf{P} = \begin{pmatrix} 0 & 0.5 & 0.5 \\ 0.3 & 0.4 & 0.3 \\ 0.6 & 0 & 0.4 \end{pmatrix}.$$

Las ecuaciones $\pi \mathbf{P} = \pi$ con $\pi_1 + \pi_2 + \pi_3 = 1$ dan:

$$\pi_1 = 0.3 \pi_2 + 0.6 \pi_3$$

$$\pi_2 = 0.5 \pi_1 + 0.4 \pi_2 \Rightarrow 0.6 \pi_2 = 0.5 \pi_1$$

$$\pi_3 = 0.5 \pi_1 + 0.3 \pi_2 + 0.4 \pi_3 \Rightarrow 0.6 \pi_3 = 0.5 \pi_1 + 0.3 \pi_2$$

Resolviendo: $\pi_2 = \frac{5}{6} \pi_1$, $\pi_3 = \frac{5}{6} \pi_1 - \frac{1}{2} \pi_2 = \frac{5}{12} \pi_1$.

Normalizando $\pi_1(1 + 5/6 + 5/12) = 1$: $\pi_1 = 12/27$, $\pi_2 = 10/27$, $\pi_3 = 5/27$.

4.3 · Teorema ergódico y convergencia

Teorema 4.1 · Convergencia para cadenas ergódicas

Sea $\{X_n\}$ una cadena de Markov ergódica (irreducible, recurrente positiva, aperiódica) con distribución estacionaria única π . Entonces para todo $i, j \in \mathcal{S}$:

$$\lim_{n \rightarrow \infty} p_{ij}^{(n)} = \pi_j,$$

independientemente del estado inicial i . En notación matricial: $\mathbf{P}^n \xrightarrow{n \rightarrow \infty} \mathbf{\Pi}$, donde $\mathbf{\Pi}$ es la matriz cuyas filas son todas iguales a π .

Demostración

Descomposición espectral (caso $|\mathcal{S}| < \infty$).

Paso 1. Por la cota espectral (§2.6, propiedad 5), los autovalores λ_k de $\mathbf{P}$ satisfacen $|\lambda_k| \leq 1$. Para una cadena ergódica (irreducible + aperiódica + finita), el Teorema de Perron-Frobenius garantiza que $\lambda_1 = 1$ es simple y $|\lambda_k| < 1$ para $k \geq 2$.

Paso 2. Si $\mathbf{P}$ es diagonalizable con $\mathbf{P} = \sum_{k=1}^s \lambda_k \mathbf{v}_k \mathbf{u}_k^\top$ (donde $\mathbf{v}_k, \mathbf{u}_k$ son vectores propios derechos e izquierdos), entonces:

$$\mathbf{P}^n = \sum_{k=1}^s \lambda_k^n \mathbf{v}_k \mathbf{u}_k^\top.$$

Paso 3. El término $k = 1$ da $\lambda_1^n = 1$ con $\mathbf{v}_1 = \mathbf{1}$ y $\mathbf{u}_1^\top = \pi$, produciendo $\mathbf{1}\pi = \mathbf{\Pi}$. Los términos $k \geq 2$ tienen $|\lambda_k^n| = |\lambda_k|^n \rightarrow 0$, luego:

$$\mathbf{P}^n - \mathbf{\Pi} = \sum_{k=2}^s \lambda_k^n \mathbf{v}_k \mathbf{u}_k^\top \xrightarrow{n \rightarrow \infty} 0,$$

es decir, $p_{ij}^{(n)} = (\mathbf{P}^n)_{ij} \rightarrow \pi_j$ para todo par i, j . $\square$

Este teorema garantiza que, sin importar dónde comience la cadena, la distribución marginal converge a π . Si la cadena es periódica, el límite $p_{ij}^{(n)}$ puede no existir, pero la media Cesàro converge: $\frac{1}{N} \sum_{n=0}^{N-1} p_{ij}^{(n)} \rightarrow \pi_j$.

Teorema 4.2 · Teorema ergódico (frecuencias de visita)

Sea $\{X_n\}$ irreducible y recurrente positiva. Para todo $j \in \mathcal{S}$ y toda trayectoria (con probabilidad 1):

$$\frac{1}{N} \sum_{n=0}^{N-1} \mathbf{1}_{\{X_n=j\}} \xrightarrow{N \rightarrow \infty} \pi_j.$$

La proporción de tiempo que la cadena pasa en el estado j converge (c.s.) a π_j . Además, $\pi_j = 1/\mu_j$ (recíproco del tiempo medio de retorno).

Demostración

Demostración completa en §4.5 via la Ley Fuerte de los Grandes Números. Esquema: los tiempos entre retornos a j son i.i.d. con media μ_j (propiedad de Markov fuerte), luego la LFGN da $V_j(N)/N \rightarrow 1/\mu_j$ c.s., que coincide con π_j por la unicidad de la distribución estacionaria. $\square$

4.4 · Reversibilidad y balance detallado

Definición 4.2 · Condición de balance detallado

Una distribución π satisface el **balance detallado** respecto a $\mathbf{P}$ si

$$\pi_i p_{ij} = \pi_j p_{ji} \quad \forall i, j \in \mathcal{S}.$$

Si existe tal π , la cadena es **reversible** (en equilibrio, no se puede distinguir si el tiempo avanza hacia adelante o hacia atrás).

Proposición 4.3 · Balance detallado implica estacionariedad

Si π satisface el balance detallado respecto a $\mathbf{P}$ y $\sum_j \pi_j = 1$, entonces π es distribución estacionaria.

Demostración

$$\sum_i \pi_i p_{ij} = \sum_i \pi_j p_{ji} = \pi_j \sum_i p_{ji} = \pi_j \cdot 1 = \pi_j. \text{ Luego } \pi \mathbf{P} = \pi. \quad \square$$

△ Atención

El recíproco es falso: existen distribuciones estacionarias que no satisfacen balance detallado (cadenas no reversibles). Balance detallado es una condición *suficiente* para estacionariedad, no necesaria.

4.5 · Demostración del Teorema Ergódico*Demostración*

(del Teorema de frecuencias de visita, §4.3.)

Sea $\{X_n\}$ irreducible y recurrente positiva. Fijamos $j \in \mathcal{S}$ y sea $0 < T_j^{(1)} < T_j^{(2)} < \dots$ la sucesión de tiempos de retorno a j (partiendo de $X_0 = j$). Por la **propiedad de Markov fuerte**, los tiempos entre retornos $\Delta_k = T_j^{(k)} - T_j^{(k-1)}$ son **i.i.d.** con media $\mu_j = \mathbb{E}[\Delta_1] < \infty$.

Sea $V_j(N) = \#\{n \in \{0, \dots, N-1\} : X_n = j\}$. La relación $T_j^{(V_j(N))} \leq N-1 < T_j^{(V_j(N)+1)}$ divide por $V_j(N)$:

$$\frac{T_j^{(V_j(N))}}{V_j(N)} \leq \frac{N-1}{V_j(N)} < \frac{T_j^{(V_j(N)+1)}}{V_j(N)}.$$

Por la **Ley Fuerte de los Grandes Números** aplicada a $\{\Delta_k\}$: $T_j^{(k)}/k \rightarrow \mu_j$ c.s., luego los dos extremos tienden a μ_j . Por tanto $N/V_j(N) \rightarrow \mu_j$ c.s., es decir:

$$\frac{V_j(N)}{N} = \frac{1}{N} \sum_{n=0}^{N-1} \mathbf{1}_{\{X_n=j\}} \xrightarrow{N \rightarrow \infty} \frac{1}{\mu_j} = \pi_j \quad \text{c.s.} \quad \square$$

□

La propiedad de Markov fuerte convierte los tiempos de retorno en una sucesión i.i.d., permitiendo aplicar la LFGN. El Teorema Ergódico vale para cadenas periódicas también (no requiere aperiodicidad).

4.6 · Velocidad de convergencia y brecha espectral**Teorema 4.4 · Convergencia exponencial para cadenas finitas ergódicas**

Sea $\{X_n\}$ ergódica con $|\mathcal{S}| = s$ y autovalores $1 = \lambda_1 > |\lambda_2| \geq \dots \geq |\lambda_s|$. Entonces existe $C > 0$ tal que:

$$\max_{i,j \in \mathcal{S}} |p_{ij}^{(n)} - \pi_j| \leq C \rho^n, \quad \rho := |\lambda_2| < 1.$$

Demostración

Si $\mathbf{P}$ es diagonalizable: $\mathbf{P} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^{-1}$ con $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_s)$, luego $\mathbf{P}^n = \mathbf{V} \mathbf{\Lambda}^n \mathbf{V}^{-1}$. La componente de $\lambda_1 = 1$ da $\boldsymbol{\Pi}$ (límite); los restantes $s-1$ términos decaen a tasa ρ^n . □

Definición 4.3 · Brecha espectral y tiempo de mezcla

La **brecha espectral** es $\gamma = 1 - \rho \in (0, 1]$. El **tiempo de mezcla** con precisión $\varepsilon > 0$ es $t_{\text{mix}}(\varepsilon) = \min\{n : \max_{i,j} |p_{ij}^{(n)} - \pi_j| \leq \varepsilon\}$. De la cota: $t_{\text{mix}}(\varepsilon) \leq \lceil \log(C/\varepsilon) / \log(1/\rho) \rceil$.

Ejemplo 4.3 · Brecha espectral de la cadena del clima

$\mathbf{P} = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}$: $\text{tr}(\mathbf{P}) = 1.4$, $\det(\mathbf{P}) = 0.40$. Autovalores: $\lambda_1 = 1$, $\lambda_2 = 0.4$. Brecha espectral $\gamma = 0.6$.
Convergencia: $|p_{ij}^{(n)} - \pi_j| \leq C \cdot 0.4^n \rightarrow 0$ exponencialmente. En $n = 10$ pasos: $0.4^{10} \approx 10^{-4}$, prácticamente en régimen estacionario.

4.7 · Algoritmo de Metropolis-Hastings

Motivación (MCMC). A menudo se desea muestrear de una distribución objetivo π difícil de evaluar directamente (por ejemplo en inferencia bayesiana). El truco: construir una cadena de Markov reversible con π como estacionaria.

Definición 4.4 · Algoritmo de Metropolis-Hastings

Dada una cadena propuesta con q_{ij} (cualquier matriz estocástica) y objetivo π , la cadena resultante tiene:

$$p_{ij} = q_{ij} \cdot \min\left(1, \frac{\pi_j q_{ji}}{\pi_i q_{ij}}\right), \quad i \neq j; \quad p_{ii} = 1 - \sum_{k \neq i} p_{ik} \quad (\text{rechazo}).$$

Proposición 4.5 · Correctitud: balance detallado respecto a π

$\pi_i p_{ij} = \pi_j p_{ji}$ para todo $i \neq j$, luego π es estacionaria.

Demostración

$\pi_i p_{ij} = \pi_i q_{ij} \cdot \min(1, \pi_j q_{ji} / \pi_i q_{ij}) = \min(\pi_i q_{ij}, \pi_j q_{ji}) = \pi_j p_{ji}$ (por simetría de $\min$). $\square$

Metropolis-Hastings es la base de los métodos **MCMC** (Markov Chain Monte Carlo): permite simular distribuciones de alta dimensión sin conocer la constante de normalización, siendo fundamental en estadística bayesiana, física estadística y machine learning. El **muestreo de Gibbs** es el caso especial en que la tasa de aceptación es 1 (siempre se acepta la propuesta).

Sección 5: Tiempos de Primer Paso y Absorción**5.0 · Funciones armónicas y ecuación de Poisson****Definición 5.1 · Función armónica**

Sea $A \subseteq \mathcal{S}$ (frontera). Una función $h : \mathcal{S} \rightarrow \mathbb{R}$ es **armónica** en $\mathcal{S} \setminus A$ si:

$$h(i) = \sum_{j \in \mathcal{S}} p_{ij} h(j) = \mathbb{E}[h(X_1) \mid X_0 = i] \quad \forall i \in \mathcal{S} \setminus A.$$

Es decir, $h(i)$ es el valor esperado de h en el siguiente paso. Análogamente, h es **superarmónica** si $h(i) \geq \mathbb{E}[h(X_1) \mid X_0 = i]$ (el proceso $\{h(X_n)\}$ es supermartingala).

Teorema 5.1 · Principio del máximo discreto

Si h es armónica en todo $\mathcal{S}$ (sin frontera) y $|\mathcal{S}| < \infty$, entonces h es constante en cada clase de comunicación cerrada.

Demostración

Sea $i^* = \arg \max_{i \in C} h(i)$ en una clase cerrada C . Como $h(i^*) = \sum_j p_{i^*j} h(j)$ y $h(j) \leq h(i^*)$ para $j \in C$ (la clase es cerrada, luego $p_{i^*j} = 0$ si $j \notin C$), la igualdad requiere $h(j) = h(i^*)$ para todo j con $p_{i^*j} > 0$. Por irreducibilidad de C , esto se extiende a toda la clase. $\square$

Proposición 5.2 · Problemas de absorción como problemas armónicos

1. Las **probabilidades de absorción** $h_i^{(a)} = \mathbb{P}(X_{T_A} = a \mid X_0 = i)$ son armónicas en $S \setminus A$, con condiciones de frontera $h_a^{(a)} = 1$ y $h_b^{(a)} = 0$ ($b \in A, b \neq a$).
2. El **tiempo esperado de absorción** $t_i = \mathbb{E}[T_A \mid X_0 = i]$ satisface la **ecuación de Poisson** (armónica inhomogénea):

$$t_i = 1 + \sum_{j \notin A} p_{ij} t_j, \quad i \notin A, \quad t_a = 0 \quad \forall a \in A.$$

Demostración

(1) Por la propiedad de Markov en el primer paso: $h_i^{(a)} = \sum_j p_{ij} h_j^{(a)}$ (armonicidad).

(2) Condicionando en X_1 : $t_i = 1 + \sum_j p_{ij} \mathbb{E}[T_A \mid X_0 = j] = 1 + \sum_{j \notin A} p_{ij} t_j$ (los términos $j \in A$ contribuyen 0 porque $t_a = 0$). $\square$

5.1 · Tiempo de primer paso**Definición 5.2 · Tiempo de primer paso (hitting time)**

El **tiempo de primer paso** al estado j , partiendo de i , es:

$$T_j = \min\{n \geq 1 : X_n = j\}, \quad T_j = \infty \text{ si nunca se llega a } j.$$

Es un tiempo de parada respecto a la filtración natural. La **probabilidad de primer paso en n pasos** de i a j es:

$$f_{ij}^{(n)} = \mathbb{P}(T_j = n \mid X_0 = i), \quad f_{ij} = \mathbb{P}(T_j < \infty \mid X_0 = i) = \sum_{n=1}^{\infty} f_{ij}^{(n)}.$$

Proposición 5.3 · Relación entre $p_{ij}^{(n)}$ y $f_{ij}^{(n)}$

Para $n \geq 1$:

$$p_{ij}^{(n)} = \sum_{k=1}^n f_{ij}^{(k)} p_{jj}^{(n-k)}.$$

Esto es una convolución: llegar de i a j en n pasos = llegar por primera vez en k pasos, y luego regresar de j a j en los $n - k$ restantes.

Demostración

Particionamos el evento $\{X_n = j\} \cap \{X_0 = i\}$ según el instante del primer arribo a j :

$$\{X_n = j, X_0 = i\} = \bigsqcup_{k=1}^n \{T_j = k, X_n = j, X_0 = i\},$$

donde $T_j = \min\{m \geq 1 : X_m = j\}$ (uniones disjuntas por el valor de T_j). Para cada $k \in \{1, \dots, n\}$, condicionando en $\{T_j = k, X_0 = i\}$ y aplicando la **propiedad de Markov fuerte** en el tiempo $T_j = k$:

$$\mathbb{P}(X_n = j \mid T_j = k, X_0 = i) = \mathbb{P}(X_{n-k} = j \mid X_0 = j) = p_{jj}^{(n-k)}.$$

Luego, por probabilidad total:

$$p_{ij}^{(n)} = \mathbb{P}(X_n = j \mid X_0 = i) = \sum_{k=1}^n \underbrace{\mathbb{P}(T_j = k \mid X_0 = i)}_{=f_{ij}^{(k)}} \cdot p_{jj}^{(n-k)}. \quad \square$$

$\square$

5.2 · Tiempo medio de retorno y estacionariedad

Teorema 5.4 · Tiempo medio de retorno y distribución estacionaria

Sea $\{X_n\}$ irreducible y recurrente positiva, con distribución estacionaria π . Entonces para todo $j \in \mathcal{S}$:

$$\pi_j = \frac{1}{\mu_j}, \quad \text{donde } \mu_j = \mathbb{E}[T_j \mid X_0 = j].$$

Los estados más frecuentemente visitados tienen tiempo medio de retorno más corto.

Demostración

Paso 1. Fijamos j y suponemos $X_0 = j$. Por la **propiedad de Markov fuerte**, los tiempos entre retornos consecutivos $\Delta_k = T_j^{(k)} - T_j^{(k-1)}$ son i.i.d. con media $\mu_j < \infty$.

Paso 2. Sea $V_j(N) = \#\{0 \leq n < N : X_n = j\}$. Como se demuestra en §4.5, la Ley Fuerte de los Grandes Números aplicada a los Δ_k da:

$$\frac{V_j(N)}{N} \xrightarrow{N \rightarrow \infty} \frac{1}{\mu_j} \quad \text{c.s.}$$

Paso 3. Por el Teorema Ergódico (§4.3), esa misma frecuencia converge a π_j . Por unicidad del límite: $\pi_j = 1/\mu_j$.

Validez para $X_0 \neq j$: desde cualquier estado inicial, la cadena alcanza j en tiempo finito (recurrencia positiva) y la frecuencia a largo plazo es la misma. $\square$

Ejemplo 5.1 · Tiempo de retorno en la cadena del clima

Con $\pi_S = 2/3$ y $\pi_L = 1/3$:

$$\mu_S = \frac{1}{\pi_S} = \frac{3}{2} = 1.5 \text{ días}, \quad \mu_L = \frac{1}{\pi_L} = 3 \text{ días}.$$

En promedio, el tiempo entre dos días lluviosos consecutivos es de 3 días.

5.3 · Probabilidades de absorción

Definición 5.3 · Estado absorbente y probabilidad de absorción

Un estado a es **absorbente** si $p_{aa} = 1$ (una vez alcanzado, no se escapa). Dado un conjunto de estados absorbentes $A \subset \mathcal{S}$ y un estado transitorio $i \notin A$, la **probabilidad de absorción** en $a \in A$ partiendo de i es:

$$h_i^{(a)} = \mathbb{P}(X_{T_A} = a \mid X_0 = i),$$

donde $T_A = \min\{n \geq 0 : X_n \in A\}$.

Teorema 5.5 · Sistema de ecuaciones para probabilidades de absorción

Las probabilidades $h_i^{(a)}$ satisfacen el sistema lineal:

$$h_i^{(a)} = p_{ia} + \sum_{k \notin A} p_{ik} h_k^{(a)}, \quad i \notin A,$$

con condición de frontera $h_a^{(a)} = 1$ y $h_b^{(a)} = 0$ para $b \in A$, $b \neq a$.

Demostración

Condicionamos en el primer paso desde $i \notin A$:

$$\begin{aligned} h_i^{(a)} &= \mathbb{P}(X_{T_A} = a \mid X_0 = i) \\ &= \sum_{j \in \mathcal{S}} p_{ij} \mathbb{P}(X_{T_A} = a \mid X_1 = j) \quad (\text{probabilidad total sobre el primer paso}) \\ &= \underbrace{p_{ia} \cdot 1}_{\text{si } j=a \in A} + \underbrace{\sum_{\substack{b \in A, b \neq a \\ \text{si } j \in A, j \neq a}} p_{ib} \cdot 0}_{\text{si } j \in A, j \neq a} + \underbrace{\sum_{\substack{k \notin A \\ \text{si } j \notin A}} p_{ik} h_k^{(a)}}_{\text{si } j \notin A} \\ &= p_{ia} + \sum_{k \notin A} p_{ik} h_k^{(a)}. \end{aligned}$$

El segundo término usa la **propiedad de Markov**: si $X_1 = k \notin A$, la probabilidad de absorción en a es la misma que partiendo de k . $\square$

5.4 · Tiempo esperado de absorción: matriz fundamental

Definición 5.4 · Forma canónica y matriz fundamental

Ordenando los estados como (transitorios, absorbentes), la matriz de transición toma la forma canónica:

$$\mathbf{P} = \begin{pmatrix} \mathbf{Q}_T & \mathbf{R} \\ \mathbf{0} & \mathbf{I} \end{pmatrix},$$

donde $\mathbf{Q}_T$ es la submatriz de transición entre estados transitorios y $\mathbf{R}$ las probabilidades de ir de transitorio a absorbente.

La **matriz fundamental** es $\mathbf{N} = (\mathbf{I} - \mathbf{Q}_T)^{-1}$. La entrada n_{ij} = número esperado de visitas al estado transitorio j partiendo de i (antes de la absorción).

Proposición 5.6 · Tiempo esperado de absorción

El vector de tiempos esperados de absorción $\mathbf{t}$ (con $t_i = \mathbb{E}[T_A \mid X_0 = i]$) satisface:

$$\mathbf{t} = \mathbf{N} \mathbf{1} = (\mathbf{I} - \mathbf{Q}_T)^{-1} \mathbf{1},$$

donde $\mathbf{1}$ es el vector de unos. Las probabilidades de absorción en cada estado absorbente forman la matriz $\mathbf{B} = \mathbf{N} \mathbf{R}$.

Demostración

Paso 1: $\mathbf{N} = (\mathbf{I} - \mathbf{Q}_T)^{-1}$. Sea $m_{ij} = \mathbb{E}[V_j \mid X_0 = i]$ el número esperado de visitas al estado transitorio j antes de la absorción. Condicionando en el primer paso:

$$m_{ij} = \delta_{ij} + \sum_{k \notin A} (Q_T)_{ik} m_{kj}.$$

En notación matricial: $\mathbf{M} = \mathbf{I} + \mathbf{Q}_T \mathbf{M}$, de donde $(\mathbf{I} - \mathbf{Q}_T) \mathbf{M} = \mathbf{I}$ y $\mathbf{M} = (\mathbf{I} - \mathbf{Q}_T)^{-1} = \mathbf{N}$. (La inversa existe porque $\mathbf{Q}_T^n \rightarrow \mathbf{0}$: todos los estados transitorios tienen absorción casi segura.)

Paso 2: $\mathbf{t} = \mathbf{N} \mathbf{1}$. El tiempo de absorción es la suma de las visitas a todos los estados transitorios: $T_A = \sum_{j \notin A} V_j$. Por linealidad:

$$t_i = \mathbb{E}[T_A \mid X_0 = i] = \sum_{j \notin A} \mathbb{E}[V_j \mid X_0 = i] = \sum_j \mathbf{N}_{ij} = (\mathbf{N} \mathbf{1})_i. \quad \square$$

□

Ejemplo 5.2 · Juego de la ruina ($N = 4$)

Un jugador tiene k fichas ($k \in \{0, 1, 2, 3, 4\}$) y en cada ronda gana o pierde una con probabilidad $p = 0.5$ y $1 - p = 0.5$. Los estados $\{0, 4\}$ son absorbentes (ruina o victoria). Los estados transitorios son $\{1, 2, 3\}$.


$$\mathbf{Q}_T = \begin{pmatrix} 0 & 0.5 & 0 \\ 0.5 & 0 & 0.5 \\ 0 & 0.5 & 0 \end{pmatrix}, \quad \mathbf{I} - \mathbf{Q}_T = \begin{pmatrix} 1 & -0.5 & 0 \\ -0.5 & 1 & -0.5 \\ 0 & -0.5 & 1 \end{pmatrix}.$$

Calculando la inversa: $\mathbf{N} = \frac{1}{4} \begin{pmatrix} 3 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 3 \end{pmatrix}.$

Tiempo esperado de absorción: $\mathbf{t} = \mathbf{N} \mathbf{1}$: $t_1 = (3 + 2 + 1)/4 = 3/2 \dots$

Corrigiendo: $t_1 = 3$, $t_2 = 4$, $t_3 = 3$ (se verifica que desde el estado central se espera más tiempo antes de arruinarse o ganar).

Probabilidad de ruina desde estado k : $h_k^{(0)} = (4 - k)/4$. Desde estado 2: $h_2^{(0)} = 0.5$.

Juego de la ruina con $N = 4$: estados absorbentes $\{0, 4\}$ **5.5 · Juego de la ruina: caso general $p \neq \frac{1}{2}$** **Ejemplo 5.3 · Ruina del apostador con probabilidad p arbitraria**

Planteamiento. Jugador con k fichas ($1 \leq k \leq N - 1$), gana con prob. p , pierde con $q = 1 - p$. Sea $h_k = \mathbb{P}(\text{ruina} \mid X_0 = k)$. Por armonicidad (§5.0):

$$h_k = p h_{k+1} + q h_{k-1}, \quad k = 1, \dots, N-1, \quad h_0 = 1, \quad h_N = 0.$$

Ecuación de diferencias. La ecuación característica $qr^2 - r + p = 0$ tiene raíces $r = 1$ y $r = \rho := q/p$.

Caso $p = q = \frac{1}{2}$ (raíz doble $r = 1$): $h_k = A + Bk$. Con $h_0 = 1, h_N = 0$:

$$h_k = \frac{N-k}{N}.$$

Caso $p \neq q$ (raíces distintas): $h_k = A + B\rho^k$. Con $A + B = 1$ y $A + B\rho^N = 0$:

$$h_k = \frac{\rho^k - \rho^N}{1 - \rho^N}, \quad \rho = \frac{q}{p}.$$

Tiempo esperado de absorción. La ecuación de Poisson da $t_k = 1 + p t_{k+1} + q t_{k-1}$, $t_0 = t_N = 0$. Soluciones:

$$t_k = \begin{cases} k(N-k) & p = \frac{1}{2}, \\ \frac{k}{q-p} - \frac{N}{q-p} \cdot \frac{1-\rho^k}{1-\rho^N} & p \neq \frac{1}{2}. \end{cases}$$

p	$h_5^{(N=10)}$	$t_5^{(N=10)}$
0.4 ($\rho = 1.5$)	$\frac{1.5^5 - 1.5^{10}}{1 - 1.5^{10}} \approx 0.870$	≈ 19.5
0.5	0.500	25.0
0.6 ($\rho = 2/3$)	$\frac{(2/3)^5 - (2/3)^{10}}{1 - (2/3)^{10}} \approx 0.130$	≈ 19.5

Límite $N \rightarrow \infty$ (rival con capital infinito):

$$h_k \xrightarrow{N \rightarrow \infty} \begin{cases} 1 & \text{si } p \leq \frac{1}{2}, \\ \left(\frac{q}{p}\right)^k & \text{si } p > \frac{1}{2}. \end{cases}$$

Si $p > 1/2$: probabilidad positiva de sobrevivir indefinidamente. Si $p \leq 1/2$: la ruina es cierta.

5.6 · Modelo de Ehrenfest (difusión entre urnas)

Ejemplo 5.4 · Modelo de Ehrenfest

Planteamiento. N bolas en dos urnas A y B . En cada paso se elige una bola al azar y se transfiere a la otra urna. Estado: X_n = número de bolas en A .

Transiciones: $p_{kk+1} = (N - k)/N$ y $p_{kk-1} = k/N$. Proceso de nacimiento y muerte discreto.

Irreducibilidad y período. Irreducible (todo k alcanzable desde cualquier otro). Periódico con $d = 2$ (la paridad de X_n cambia en cada paso, pues $p_{kk} = 0$).

Distribución estacionaria (balance detallado). $\pi_k (N - k)/N = \pi_{k+1} (k + 1)/N$ implica $\pi_{k+1}/\pi_k = (N - k)/(k + 1) = \binom{N}{k+1}/\binom{N}{k}$. Iterando desde π_0 :

$$\pi_k = \binom{N}{k} \pi_0. \quad \text{Normalizando: } \sum_{k=0}^N \binom{N}{k} \pi_0 = 2^N \pi_0 = 1.$$

$$\pi_k = \binom{N}{k} \frac{1}{2^N} \sim \text{Binomial}(N, \frac{1}{2}).$$

Tiempo de retorno al estado 0: $\mu_0 = 1/\pi_0 = 2^N$. Para $N = 100$: $\mu_0 = 2^{100} \approx 10^{30}$ pasos. A 10^{10} pasos/seg: $\approx 3 \times 10^{12}$ años de espera.

Brecha espectral. Los autovalores de $\mathbf{P}$ son $\lambda_k = 1 - 2k/N$ ($k = 0, \dots, N$). Brecha espectral $\gamma = 2/N$; tiempo de mezcla $t_{\text{mix}} = O(N \log N)$.

Segunda ley de la termodinámica. La cadena es recurrente positiva (espacio finito e irreducible), luego matemáticamente regresa al estado 0. Pero $\mu_0 = 2^N$ es *inobservable* para $N \sim 10^{23}$ (número de Avogadro). La irreversibilidad termodinámica no es imposibilidad matemática, sino probabilidad astronómicamente pequeña.

Sección 6: Cadenas de Markov en Tiempo Continuo (CMTC)

6.1 · Definición y propiedad de Markov continua

Definición 6.1 · Cadena de Markov en tiempo continuo (CMTC)

Un proceso estocástico $\{X(t)\}_{t \geq 0}$ con espacio de estados discreto $\mathcal{S}$ es una **cadena de Markov en tiempo continuo** si satisface la propiedad de Markov:

$$\mathbb{P}(X(t+s) = j \mid X(s) = i, \{X(u)\}_{0 \leq u < s}) = \mathbb{P}(X(t+s) = j \mid X(s) = i)$$

para todo $t, s \geq 0$ e $i, j \in \mathcal{S}$. La cadena es **homogénea** si la probabilidad de transición $p_{ij}(t) = \mathbb{P}(X(t+s) = j \mid X(s) = i)$ no depende de s .

6.2 · Tiempos de permanencia

Teorema 6.1 · Distribución exponencial de los tiempos de permanencia

En una CMTC homogénea, el tiempo que el proceso permanece en el estado i antes de saltar es una variable aleatoria $\tau_i \sim \text{Exp}(q_i)$, donde $q_i \geq 0$ es la **tasa de salida** del estado i .

Esto se sigue de la propiedad de falta de memoria de la Exponencial: la única distribución continua sin memoria es la Exponencial.

Si $q_i = 0$, el estado i es absorbente (la cadena nunca sale de él). El tiempo esperado en el estado i es $\mathbb{E}[\tau_i] = 1/q_i$.

6.3 · Generador infinitesimal $\mathbf{Q}$

Definición 6.2 · Generador infinitesimal (Q-matrix)

La **Q-matrix** o **generador infinitesimal** $\mathbf{Q} = (q_{ij})$ tiene entradas:

- $q_{ij} \geq 0$ para $i \neq j$: **tasa de transición** de i a j .
- $q_{ii} = -\sum_{j \neq i} q_{ij} = -q_i \leq 0$: la diagonal es la tasa de salida negativa.

Propiedades: cada fila de $\mathbf{Q}$ suma 0, i.e., $\mathbf{Q}\mathbf{1} = \mathbf{0}$.


Relación con $\mathbf{P}(t)$:

$$\lim_{h \rightarrow 0^+} \frac{p_{ij}(h) - \delta_{ij}}{h} = q_{ij}.$$

Ejemplo 6.1 · Q-matrix para una cadena de 2 estados

Sea $\mathcal{S} = \{0, 1\}$, tasa de ir de 0 a 1: λ , tasa de 1 a 0: μ .

$$\mathbf{Q} = \begin{pmatrix} -\lambda & \lambda \\ \mu & -\mu \end{pmatrix}.$$



6.4 · Ecuaciones de Kolmogorov

Teorema 6.2 · Ecuación regresiva de Kolmogorov (*backward*)

Partiendo del estado i en $t = 0$, condicionamos en el **primer salto**:

$$p'_{ij}(t) = -q_i p_{ij}(t) + \sum_{k \neq i} q_{ik} p_{kj}(t) = \sum_{k \in S} q_{ik} p_{kj}(t), \quad (6.1)$$

o en forma matricial:

$$\mathbf{P}'(t) = \mathbf{Q} \mathbf{P}(t), \quad \mathbf{P}(0) = \mathbf{I}.$$

Teorema 6.3 · Ecuación progresiva de Kolmogorov (*forward*)

Condicionamos en el **último salto** antes de llegar al estado j en t :

$$p'_{ij}(t) = -q_j p_{ij}(t) + \sum_{k \neq j} p_{ik}(t) q_{kj} = \sum_{k \in S} p_{ik}(t) q_{kj}, \quad (6.2)$$

o en forma matricial:

$$\mathbf{P}'(t) = \mathbf{P}(t) \mathbf{Q}, \quad \mathbf{P}(0) = \mathbf{I}.$$

La solución común es la **exponencial matricial**:

$$\mathbf{P}(t) = e^{t\mathbf{Q}} = \sum_{k=0}^{\infty} \frac{(t\mathbf{Q})^k}{k!}.$$

Demostración

Ecuación regresiva. Aplicamos Chapman-Kolmogorov con el intervalo pequeño $h > 0$ al inicio del recorrido:

$$p_{ij}(t+h) = \sum_{k \in S} p_{ik}(h) p_{kj}(t).$$

Por la definición del generador (derivada de $\mathbf{P}(t)$ en $t=0$):

$$p_{ii}(h) = 1 - q_i h + o(h), \quad p_{ik}(h) = q_{ik} h + o(h) \quad (k \neq i).$$

Sustituyendo y separando el término $k=i$:

$$p_{ij}(t+h) = (1 - q_i h) p_{ij}(t) + \sum_{k \neq i} q_{ik} h p_{kj}(t) + o(h).$$

Restando $p_{ij}(t)$, dividiendo por h y tomando $h \rightarrow 0^+$:

$$p'_{ij}(t) = -q_i p_{ij}(t) + \sum_{k \neq i} q_{ik} p_{kj}(t) = \sum_k \underbrace{q_{ik}}_{\substack{q_{ii} = -q_i \\ q_{ik} \geq 0, k \neq i}} p_{kj}(t).$$

En notación matricial: $\mathbf{P}'(t) = \mathbf{Q} \mathbf{P}(t)$.

Ecuación progresiva. Colocamos ahora el intervalo pequeño al *final*:

$$p_{ij}(t+h) = \sum_{k \in S} p_{ik}(t) p_{kj}(h).$$

Con $p_{jj}(h) = 1 - q_j h + o(h)$ y $p_{kj}(h) = q_{kj} h + o(h)$ para $k \neq j$:

$$p_{ij}(t+h) = p_{ij}(t)(1 - q_j h) + \sum_{k \neq j} p_{ik}(t) q_{kj} h + o(h).$$

Tomando el límite:

$$p'_{ij}(t) = -q_j p_{ij}(t) + \sum_{k \neq j} p_{ik}(t) q_{kj} = \sum_k p_{ik}(t) q_{kj},$$

es decir, $\mathbf{P}'(t) = \mathbf{P}(t) \mathbf{Q}$.

Solución matricial. Ambas EDOs $\mathbf{P}' = \mathbf{Q} \mathbf{P}$ y $\mathbf{P}' = \mathbf{P} \mathbf{Q}$ con $\mathbf{P}(0) = \mathbf{I}$ tienen la misma solución $e^{t\mathbf{Q}}$ porque $\mathbf{Q}$ y $e^{t\mathbf{Q}}$ conmutan. La serie converge uniformemente en compactos. $\square$

Interpretación probabilística.

- **Regresiva (backward):** descompone el trayecto $i \rightarrow j$ en $[0, t]$ según lo que ocurre en el primer instante infinitesimal. Con probabilidad $1 - q_i h$ el proceso permanece en i ; con probabilidad $q_{ik} h$ salta a k y luego debe llegar a j desde k en tiempo t . Conveniente para calcular probabilidades de absorción y tiempos de primer paso (se ancla en el estado inicial).
- **Progresiva (forward):** descompone el trayecto según el último salto en $[t, t+h]$. Conveniente para obtener la distribución de $X(t)$ a partir de la distribución en $t=0$ (se ancla en el estado final j).
- Para $|S|$ finito o tasas acotadas, ambas ecuaciones tienen la misma solución única. En espacios infinitos con posible explosión, la ecuación regresiva siempre tiene solución mínima única; la progresiva puede tener múltiples soluciones.

Ecuación de Kolmogorov para la distribución marginal. Si $\alpha(t)$ es el vector fila con $\alpha_j(t) = \mathbb{P}(X(t) = j)$, multiplicando la ecuación progresiva por la distribución inicial:

$$\alpha'(t) = \alpha(t) \mathbf{Q}, \quad \alpha(0) = \alpha^{(0)}.$$

En estado estacionario $\alpha'(t) = \mathbf{0}$, lo que recupera la condición $\pi \mathbf{Q} = \mathbf{0}$ (§6.5).

Ejemplo 6.2 · Solución explícita para 2 estados

Con la $\mathbf{Q}$ -matrix anterior ($\lambda, \mu > 0$), los autovalores de $\mathbf{Q}$ son 0 y $-(\lambda + \mu)$. La solución es:

$$\mathbf{P}(t) = \frac{1}{\lambda + \mu} \begin{pmatrix} \mu + \lambda e^{-(\lambda + \mu)t} & \lambda(1 - e^{-(\lambda + \mu)t}) \\ \mu(1 - e^{-(\lambda + \mu)t}) & \lambda + \mu e^{-(\lambda + \mu)t} \end{pmatrix}.$$

Cuando $t \rightarrow \infty$: $\mathbf{P}(t) \rightarrow \frac{1}{\lambda + \mu} \begin{pmatrix} \mu & \lambda \\ \mu & \lambda \end{pmatrix}$, que es la distribución estacionaria $\pi_0 = \mu/(\lambda + \mu)$, $\pi_1 = \lambda/(\lambda + \mu)$.

6.5 · Distribución estacionaria de una CMTC

Definición 6.3 · Distribución estacionaria (tiempo continuo)

Un vector π es distribución estacionaria de una CMTC si:

$$\pi Q = 0, \quad \sum_{j \in \mathcal{S}} \pi_j = 1, \quad \pi_j \geq 0.$$

En forma escalar: $\sum_{i \neq j} \pi_i q_{ij} = \pi_j q_j$ para todo j (flujo de entrada = flujo de salida en cada estado).

El balance detallado en tiempo continuo es $\pi_i q_{ij} = \pi_j q_{ji}$. Si se satisface, π es estacionaria y la cadena es reversible.

6.6 · Cadena embebida

Definición 6.4 · Cadena de saltos (cadena embebida)

Dada una CMTC $\{X(t)\}$, la **cadena de saltos** (o *cadena embebida*) es el proceso $\{Y_n\}_{n \geq 0}$ que registra *solo el estado* en el momento del n -ésimo salto, sin tomar en cuenta el tiempo transcurrido.

La cadena de saltos es una CMTD con probabilidades de transición:

$$\hat{p}_{ij} = \frac{q_{ij}}{q_i} \quad (i \neq j), \quad \hat{p}_{ii} = 0.$$

Así, una CMTC puede describirse como: tiempos de espera $\text{Exp}(q_i)$ en cada estado i , seguidos de saltos según $\hat{p}_{ij}$.

△ Atención

La distribución estacionaria π de la CMTC y la de la cadena embebida $\hat{\pi}$ *no coinciden* en general. La distribución estacionaria de la CMTC pondera además el tiempo de permanencia en cada estado: $\pi_i \propto \hat{\pi}_i / q_i$.

Sección 7: Proceso de Nacimiento y Muerte

7.1 · Definición


Definición 7.1 · Proceso de nacimiento y muerte

Un proceso de nacimiento y muerte es una CMTC con espacio de estados $\mathcal{S} = \{0, 1, 2, \dots\}$ (finito o infinito numerable) donde solo se permiten saltos de un estado al inmediatamente adyacente:

- **Tasa de nacimiento:** $\lambda_i = q_{i,i+1} \geq 0$ (salto de i a $i+1$).
- **Tasa de muerte:** $\mu_i = q_{i,i-1} \geq 0$ (salto de i a $i-1$), con $\mu_0 = 0$.
- $q_i = \lambda_i + \mu_i$ (tasa total de salida del estado i).

La Q-matrix tiene la estructura tridiagonal:

$$Q = \begin{pmatrix} -\lambda_0 & \lambda_0 & 0 & 0 & \dots \\ \mu_1 & -(\lambda_1 + \mu_1) & \lambda_1 & 0 & \dots \\ 0 & \mu_2 & -(\lambda_2 + \mu_2) & \lambda_2 & \dots \\ \vdots & \vdots & \vdots & \ddots & \ddots \end{pmatrix}.$$



Proceso de nacimiento y muerte: solo saltos al estado adyacente

7.2 · Balance detallado y distribución estacionaria

Teorema 7.1 · Distribución estacionaria del proceso de nacimiento y muerte

En un proceso de nacimiento y muerte, el balance detallado simplifica a:

$$\pi_i \lambda_i = \pi_{i+1} \mu_{i+1}, \quad i = 0, 1, 2, \dots$$

(flujo entre estados i e $i+1$ se equilibra en ambas direcciones). Iterando la recursión desde $i = 0$:

$$\pi_n = \pi_0 \prod_{k=0}^{n-1} \frac{\lambda_k}{\mu_{k+1}}, \quad n \geq 1.$$

La constante π_0 se determina por normalización: $\pi_0 = \left(1 + \sum_{n=1}^{\infty} \prod_{k=0}^{n-1} \frac{\lambda_k}{\mu_{k+1}}\right)^{-1}$. La distribución estacionaria existe si y solo si la suma converge.

Demostración

Las ecuaciones de balance global para el estado j son $\lambda_{j-1}\pi_{j-1} + \mu_{j+1}\pi_{j+1} = (\lambda_j + \mu_j)\pi_j$. En un proceso de nacimiento y muerte, se puede verificar que el balance detallado $\pi_i\lambda_i = \pi_{i+1}\mu_{i+1}$ es una solución (por inducción en i). Despejando: $\pi_{i+1} = (\lambda_i/\mu_{i+1})\pi_i$, y aplicando recursivamente se obtiene la fórmula producto. $\square$

7.3 · Proceso de nacimiento puro: conexión con Poisson

Proposición 7.2 · Proceso de Poisson como nacimiento puro

Si $\mu_i = 0$ para todo i (no hay muertes) y $\lambda_i = \lambda$ constante (tasa de nacimiento homogénea), el proceso de nacimiento y muerte se reduce al **Proceso de Poisson** con intensidad λ .

En este caso no existe distribución estacionaria (el proceso crece indefinidamente): $\sum_{n=0}^{\infty} (\lambda/0)^n$ diverge.

Las probabilidades $p_n(t) = \mathbb{P}(X(t) = n \mid X(0) = 0)$ satisfacen las ecuaciones de Kolmogorov: $p'_n(t) = -\lambda p_n(t) + \lambda p_{n-1}(t)$, con solución $p_n(t) = e^{-\lambda t} (\lambda t)^n / n!$ (distribución Poisson).

7.4 · Cola M/M/1

Definición 7.2 · Cola M/M/1

Una **cola M/M/1** modela un sistema de espera con:

- Llegadas: proceso de Poisson con tasa λ (interarribos $\text{Exp}(\lambda)$).
- Servicio: tiempo de servicio $\text{Exp}(\mu)$.
- Un solo servidor, capacidad ilimitada, disciplina FIFO.

El número de clientes $X(t)$ es un proceso de nacimiento y muerte con $\lambda_i = \lambda$ y $\mu_i = \mu$ para $i \geq 1$, $\mu_0 = 0$.

El **factor de carga** es $\rho = \lambda/\mu$.

Teorema 7.3 · Distribución estacionaria de M/M/1

La cola M/M/1 tiene distribución estacionaria si y solo si $\rho < 1$ (la tasa de llegadas es menor que la de servicio). Cuando se cumple:

$$\pi_n = (1 - \rho) \rho^n, \quad n = 0, 1, 2, \dots$$

Distribución geométrica con parámetro $1 - \rho$. Las medidas de rendimiento son:

$$\mathbb{E}[L] = \frac{\rho}{1 - \rho} \quad (\text{número medio en el sistema})$$

$$\mathbb{E}[L_q] = \frac{\rho^2}{1 - \rho} \quad (\text{número medio en cola})$$

$$\mathbb{E}[W] = \frac{1}{\mu - \lambda} \quad (\text{tiempo medio en el sistema})$$

$$\mathbb{E}[W_q] = \frac{\rho}{\mu - \lambda} \quad (\text{tiempo medio en cola})$$

donde se han usado las **leyes de Little**: $\mathbb{E}[L] = \lambda \mathbb{E}[W]$ y $\mathbb{E}[L_q] = \lambda \mathbb{E}[W_q]$.

Demostración

Aplicando la fórmula del proceso de nacimiento y muerte con $\lambda_i = \lambda$, $\mu_i = \mu$:

$$\pi_n = \pi_0 \prod_{k=0}^{n-1} \frac{\lambda}{\mu} = \pi_0 \rho^n.$$

Normalizando: $\pi_0 \sum_{n=0}^{\infty} \rho^n = 1 \Rightarrow \pi_0 = 1 - \rho$ (requiere $\rho < 1$).

El número medio: $\mathbb{E}[L] = \sum_{n=0}^{\infty} n(1 - \rho)\rho^n = (1 - \rho) \cdot \frac{\rho}{(1 - \rho)^2} = \frac{\rho}{1 - \rho}$. □

Ejemplo 7.1 · Cola de un cajero automático

Clientes llegan a un ATM según un Proceso de Poisson con $\lambda = 4$ clientes/hora. El tiempo de servicio es $\text{Exp}(\mu = 6)$ clientes/hora. Factor de carga: $\rho = 4/6 = 2/3 < 1$.

- Probabilidad de que el ATM esté vacío: $\pi_0 = 1 - 2/3 = 1/3 \approx 33\%$.
- Número medio de clientes en el sistema: $\mathbb{E}[L] = (2/3)/(1/3) = 2$.
- Tiempo medio total en el sistema: $\mathbb{E}[W] = 1/(6 - 4) = 0.5$ horas = 30 min.
- Tiempo medio esperando en cola: $\mathbb{E}[W_q] = (2/3)/(6 - 4) = 1/3$ hora = 20 min.

△ Atención

Si $\rho \geq 1$ la cola *no tiene régimen estacionario*: la línea de espera crece indefinidamente y el sistema se satura. La condición $\rho < 1$ es indispensable para que exista distribución estacionaria.

Leyes de Little (intuitivas): En un sistema estable con tasa de entrada λ :

- $\mathbb{E}[L] = \lambda \mathbb{E}[W]$: el número promedio en el sistema es la tasa de llegadas por el tiempo promedio que cada cliente pasa en el sistema.
- $\mathbb{E}[L_q] = \lambda \mathbb{E}[W_q]$: análogamente para la cola.

Las leyes de Little son universales: no dependen de la distribución de llegadas ni de servicio, solo de la estabilidad del sistema.

Conexiones clave del módulo

- Proceso de Poisson $\Rightarrow$ CMTC de nacimiento puro con $\lambda_i = \lambda$ constante
- Balance detallado $\pi_i q_{ij} = \pi_j q_{ji} \Rightarrow$ reversibilidad $\Rightarrow \pi$ fácil de calcular
- Proceso de nacimiento y muerte: $\pi_n = \pi_0 \prod_{k=0}^{n-1} (\lambda_k / \mu_{k+1})$
- CMTC $\leftrightarrow$ cadena embebida (saltos) + tiempos de espera $\text{Exp}(q_i)$
- Recurrencia $\Leftrightarrow \sum_n p_{ii}^{(n)} = \infty$ (criterio de recurrencia)
- Teorema ergódico: $p_{ij}^{(n)} \rightarrow \pi_j$ para cadena ergódica finita
- $\pi_j = 1/\mu_j$ (la distribución estacionaria es el recíproco del tiempo medio de retorno)
- Cola M/M/1 estable $\Leftrightarrow \rho = \lambda/\mu < 1$, con $\pi_n = (1 - \rho)\rho^n$